

Humboldt-Universität zu Berlin  
Mathematisch-Naturwissenschaftliche Fakultät  
Institut für Physik

Masterarbeit

# **Eignung von rekurrenten Deep Learning Methoden zur Analysen von Biosignalen**

Oruç Kahriman  
550966  
01.03.1993  
[kahrimao@physik.hu-berlin.de](mailto:kahrimao@physik.hu-berlin.de)

**Studiengang:** Master of Science in Physik

**Prüfer/in:** Prof. Dr. Niels Wessel – HU Berlin,  
Prof. Dr. Robert Jäschke - HU Berlin

**Betreuer/in:** Dipl.-Inf. Jan F. Krämer – HU Berlin,  
M.Sc. Karsten Berg - HU Berlin

**Beginn am:** 06. März 2023

**Beendet am:** 07. September 2023



# 1 Abstract

Die Herzratenvariabilität ist ein Resultat der dynamischen Wechselwirkung zwischen den Störungen des Herzkreislaufes und der Antwort der regulatorischen Mechanismen. Zum besseren Verständnis dieser Wechselwirkung werden Modelle formuliert mit deren Unterstützung klinische Anwendungen entwickelt werden können. Die Parameter der Modelle werden aus EKGs ermittelt, welche aufwendig aufbereitet werden müssen.

In dieser Arbeit werden EKGs in ein neuronales Netz eingespeist und die Netze werden auf die Ausgabe des HRV-Parameters forbidden words hin trainiert. Die Transformationen im neuronalen Netz können die Vorverarbeitung der Daten und die Zwischenschritte zur Berechnung der Parameter abbilden und automatisieren. Die Automation vereinfacht den Einsatz der Modelle auf weitere Datensätze. Zur Verifizierung der Berechnung durch das neuronale Netz wird die Analyse im Artikel „Cardiac Autonomic Dysfunction and Incidence of de novo Atrial Fibrillation: Heart Rate Variability vs. Heart Rate Complexity [WBK+20] für den Vergleich genutzt.

Der Encoder der Modelle besteht aus Faltungsschichten und die nachfolgenden Schichten bestehen größtenteils aus LSTM- und Attention-Schichten. Es werden neben der Hauptaufgabe, den Parameter forbidden words nachzubilden, verschiedene Kombinationen an Pseudo-Aufgaben gestellt. Im Experiment hat sich herausgestellt, dass ein Attention-Modell mit der Pseudo-Aufgabe, die symbolische Dynamik nachzubilden, die Analyse der Studie hinreichend genau reproduzieren kann. Die vorhergesagten FW-Werte aus dem Modell haben eine MAPE von 12,7 % auf dem Testdatensatz, wobei einige der anderen Pseudo-Aufgaben-Kombinationen kleinere MAPE aufweisen. Jedoch fällt der Mann-Whitney-U-Test nur auf den vorhergesagten Werten aus dem Modell mit der Pseudo-Aufgaben-Kombination „SymbolC, forbword“ mit einer Statistik von 21 positiv aus und die Nullhypothese der Ununterscheidbarkeit der beiden Gruppen kann abgelehnt werden. Die erfolgreiche Reproduktion der Analyse zeigt, dass neuronale Netze zur Automation der Vorverarbeitung in der HRV-Analyse geeignet sind.

Der Code ist open-source und frei verfügbar für das eigenständige Experimentieren unter diesem [Link](#).



# Inhaltsverzeichnis

<b>1 Abstract</b>	<b>iii</b>
<b>2 Einleitung</b>	<b>1</b>
<b>3 Anatomie und Physiologie</b>	<b>3</b>
3.1 Kardiologie . . . . .	3
3.2 Autonomes Nervensystem . . . . .	5
3.3 Lunge . . . . .	6
3.4 Die kardiovaskuläre Regulation . . . . .	10
<b>4 Statistische Methoden</b>	<b>11</b>
4.1 Herzratenvariabilität . . . . .	11
4.2 Cardiac Autonomic Dysfunction and Incidence of de novo Atrial Fibrillation . . . . .	14
4.3 Maschinelles Lernen . . . . .	14
<b>5 Aufbau</b>	<b>27</b>
5.1 Daten . . . . .	27
5.2 NN-Architektur . . . . .	31
5.3 Kostenfunktion . . . . .	32
5.4 Training . . . . .	34
5.5 Mann-Whitney-U-Test . . . . .	34
<b>6 Experiment</b>	<b>37</b>
6.1 Pseudo-Aufgaben . . . . .	37
6.2 LSTM vs. Attention . . . . .	39
6.3 Gewichtete Kostenfunktion . . . . .	40
6.4 Unverzweigte Architektur . . . . .	40
6.5 Faltungskerngröße . . . . .	41
6.6 Weight decay . . . . .	42
6.7 Kanal 2 . . . . .	44
6.8 Gewichtetes Loss des Merkmals SymbolsC . . . . .	45
6.9 finale Modellarchitektur . . . . .	46
<b>7 Diskussion</b>	<b>49</b>
<b>8 Ausblick</b>	<b>53</b>
<b>Literaturverzeichnis</b>	<b>55</b>



# Abbildungsverzeichnis

2.1	Altersaufbau der deutschen Bevölkerung in den Jahren 1990 und 2021 [Bun23] . . . . .	1
3.1	Schematische Darstellung des Herzens . . . . .	3
3.2	Herzschlag im EKG [Hel23] . . . . .	5
3.4	Schematische Darstellung der Lunge . . . . .	7
3.3	Barorezeptoren in Aorta und Halsschlagader [LLY+16] . . . . .	7
3.5	Feststellung einer RSA [Ras86] . . . . .	9
3.6	Konstruktion des Koordigramms [RMK+14] . . . . .	9
3.7	Kardiovaskuläre Regulation nach Berger und Saul aus der Vorlesung der AG CVP [ASBC89] . . . . .	10
4.1	Auswirkung von Artefakten auf Spektralanalyse [WBK21b] . . . . .	12
4.2	Vergleich von unterschiedlichen Filtern [WBK21b] . . . . .	12
4.3	Schematische Darstellung des Tachogramms und dessen Fouriertransformation .	13
4.4	Poincaré-Diagramm [Fra23] . . . . .	14
4.5	Visualisierung des Erlernen von Repräsentationen am Beispiel der Klassifikation von Tieren an Bilder [Beh23] . . . . .	16
4.6	beispielhaftes neuronales Netz [Glo13] . . . . .	18
4.7	Beispiele für ein künstliches Neuron und eine Aktivierungsfunktion . . . . .	18
4.8	schematische Losslandschaft [Roe23] . . . . .	19
4.9	beispielhafte zweidimensionale Faltungsschicht [Knu] . . . . .	21
4.10	Die Ur-RNN-Schicht [Jor97] . . . . .	22
4.11	Eine LSTM Einheit [Jor97] . . . . .	23
4.12	Schematische Darstellung eines Heads in einer multi-head-self-attention-Schicht [Num23] . . . . .	24
4.13	Schematische Darstellung des Inductive Transfer anhand von Galaxie-Klassifikationen in astronomischen Bildern [UCK+11] . . . . .	26
5.1	10 Sekunden langes EKG aus dem Datenset ReactDX . . . . .	28
5.2	32 Sekunden lange Zeitreihe der Vorhersage eines Attention-Modells und der Vorgabe des Tachogramms für ein Beispiel aus dem Datenset Icentia11k . . . . .	29
5.3	32 Sekunden lange Zeitreihe der Vorhersage eines Attention-Modells und der Vorgabe der symbolischen Dynamik für ein Beispiel aus dem Datenset Icentia11k	30
5.4	Schematische Darstellung der verzweigten Netzarchitektur . . . . .	31
5.5	Schematische des Encoders und des Kerns . . . . .	33
5.6	Verteilung des Parameters FW in den Gruppen . . . . .	35
5.7	Tabelle der Mann-Whitney-U-Tests an sieben Tagen der Messungen . . . . .	36
6.1	Mittlerer absoluter prozentualer Fehler (MAPE) der Vorhersage des Parameters forbidden words für unterschiedliche Pseudo-Aufgaben-Kombinationen . . . . .	38

## Abbildungsverzeichnis

---

6.2	Mittlerer absoluter prozentualer Fehler (MAPE) der Vorhersage des Parameters forbidden words für LSTM- und Attention-Modelle . . . . .	39
6.3	Mittlerer absoluter prozentualer Fehler (MAPE) der Vorhersage des Parameters forbidden words von Modellen mit ungewichteter und gewichteter Kostenfunktion	40
6.4	Mittlerer absoluter prozentualer Fehler (MAPE) der Vorhersage des Parameters forbidden words von Modellen mit unverzweigte und verzweigter Architektur . .	41
6.5	Mittlerer absoluter prozentualer Fehler (MAPE) der Vorhersage des Parameters forbidden words von Modellen mit unterschiedlich großen Faltungskernen in den Faltungsschichten . . . . .	42
6.6	Mittlerer absoluter prozentualer Fehler (MAPE) der Vorhersage des Parameters forbidden words von Modellen mit Adam- und AdamW-Optimizer . . . . .	43
6.7	Mittlerer absoluter prozentualer Fehler (MAPE) der Vorhersage des Parameters forbidden words von Modellen mit Adam- und AdamW-Optimizer . . . . .	43
6.8	10 Sekunden langes EKG aus dem Datenset ReactDX . . . . .	44
6.9	Mittlerer absoluter prozentualer Fehler (MAPE) der Vorhersage des Parameters forbidden words von Modellen mit Trainingsdaten aus Kanal 1 und Kanal 2 . .	45
6.10	Mittlerer absoluter prozentualer Fehler (MAPE) der Vorhersage des Parameters forbidden words von Modellen mit und ohne Gewichtung des Losses des Merkmals SparseCategoricalCrossentropy . . . . .	46
6.11	Mittlerer absoluter prozentualer Fehler (MAPE) der Vorhersage des Parameters forbidden words von Modellen der finalen Architektur . . . . .	47
6.12	Heatmap der vorhergesagten Werte in Abhängigkeit vom echten Wert des Parameters FW . . . . .	47
6.13	untere Statistik des Mann-Whitney-U-Tests der vorhergesagten und vorgegebenen FW-Werte . . . . .	48

# Akronyme

**ANS** autonomes Nervensystem. 5

**EKG** Elektrokardiogramm. iii, vii, viii, 2, 4, 5, 11, 14, 27, 28, 31, 32, 34, 37, 44, 45, 51, 53

**FW** forbidden words. iii, vii, viii, 14, 30, 31, 32, 34, 35, 36, 37, 38, 39, 40, 41, 42, 43, 45, 46, 47, 48

**GPU** grafische Prozessoreinheit. 2, 32, 39

**HRV** Herzratenvariabilität. iii, 2, 4, 11, 13, 14, 28, 29, 30, 31, 32, 34, 51, 53

**ICD** implantierbarer Kardioverter-Defibrillator. 27

**LSTM** Long-Short-Term-Memory. v, vii, viii, 2, 22, 23, 37, 39

**MAPE** mittlerer absoluter prozentualer Fehler. iii, viii, 31, 34, 38, 39, 40, 41, 42, 43, 44, 45, 46, 47, 48, 49

**NN** neuronales Netz. 34

**PSM** Propensity Score Matching. 27

**SGD** stochastischer Gradientenabstieg. 34

**SNR** Signal-zu-Rausch-Verhältnis. 27, 38, 40

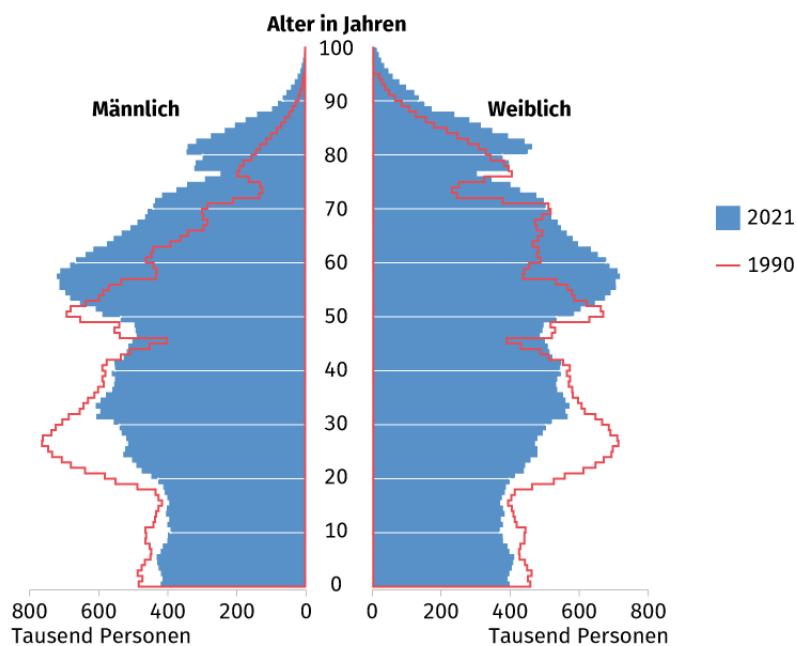
**VHF** Vorhofflimmern. 4, 6, 14, 27

## 2 Einleitung

Mit der fortschreitenden Alterung der Gesellschaft und der Erhöhung des Renteneintrittalters wird die gesundheitliche Überwachung von und Diagnose an Risikopatienten immer wichtiger. Der demografische Wandel hat in Deutschland die Zahl der Personen im Alter über 70 Jahren zwischen 1990 und 2021 von 8 auf 13 Millionen erhöht [Bun23], womit diese Altersgruppe etwa 6,5 % der Bevölkerung ausmacht. Diese Entwicklung wird sich in den nächsten zwei Jahrzehnten durch den Renteneintritt der Babyboom-Generation der Jahrgänge 1955 bis 1970 verschärfen [Bun23], wie in Abbildung 2.1 zu sehen ist. Der Anstieg des Anteils an Personen im hohen Alter wird eine höhere Belastung des Gesundheitssystems mit sich bringen, da die Anzahl an Risikopatienten steigen und gleichzeitig der Anteil der erwerbstätigen Bevölkerung sinken wird. Eine Verringerung des Personalaufwands kann durch automatisierte und effizientere Überwachung der Gesundheit und genauere Vorhersagen über die Krankheitsverläufe der Patienten bewirkt werden.

**Altersaufbau der Bevölkerung 2021**

im Vergleich zu 1990



© Statistisches Bundesamt (Destatis), 2022

**Abbildung 2.1.** Altersaufbau der deutschen Bevölkerung in den Jahren 1990 und 2021 [Bun23]

## 2 Einleitung

---

Die zentrale Rolle des Herzens im menschlichen Körper setzt das Organ unterschiedlichsten Einflüssen aus, wodurch Beeinträchtigungen der Gesundheit einer Person sich oft in einem veränderten Herzrhythmus zeigen [Her19]. Die Beobachtung des Herzrhythmuses ermöglicht einerseits eine kostengünstige, nicht-invasive Überwachung der Gesundheit andererseits können verschiedene Diagnose-Test auf den gleichen Datensatz angewendet werden.

Die Forschung an der Herzratenvariabilität beschäftigt sich mit der Entwicklung von Modellen und messbaren Parametern, um diese Ziele zu erreichen. Mit dem technologischen Fortschritt wurden und werden die Modelle der kardiovaskulären Regulation komplexer und erlauben neue Blickwinkel auf den Gesundheitszustand von Patienten. Die Entwicklung des Pulsoximeters durch Karl Matthes im Jahre 1935 ermöglichte eine einfachere Messung der Herzrate als durch die Aufnahme eines EKGs. Im Jahre 1936 stellten Anrep, Pascual und Rössler die Theorie auf, dass die Sinusarrhythmie der Herzrate durch die neuronale Regulation aus dem Hirnstamm verursacht wird und dass der gleiche Teil des Hirnstamms den Atemzyklus steuert [APR36]. Diese Idee gehört zu den ersten Analysen der Kopplungen im autonomen Nervensystem. [Her19]. Das erste EKG-Gerät zur ambulanten Überwachung wurde von Norman Holter im Jahre 1947 entwickelt und eröffnete die Möglichkeit Patienten über lange Zeiträume hinweg aufzunehmen [Her19]. In den 1970er Jahren wurde die schnelle Fourier-Transformation in die HRV-Analyse eingeführt und erlaubte die Darstellung der Leistungsspektren im Signal der Herzrate [Her19]. Die Peaks in den Spektren lassen sich mit dem Einfluss unterschiedlicher Teile des autonomen Nervensystems in Verbindung bringen. Eine Studie konnte im Jahr 1978 zeigen, dass Patienten, die einen Herzinfarkt erlitten hatten und eine verringerte HRV aufwiesen, an einer höheren Sterblichkeit litten. Die HRV wird bis heute zur Einschätzung der Sterblichkeit an Risikopatienten und Nicht-Risikopatienten angewandt [Her19]. Die Arbeitsgruppe um Glass führte in den 80er Jahren Methoden aus der nicht-linearen Dynamik in die Analyse der HRV ein [Her19]. Die Vielzahl an Methoden erlaubt es unterschiedliche Interaktionen des Herzens mit dem restlichen Körper zu untersuchen.

Zur erfolgreichen Analyse der HRV gehört die aufwendige Vorverarbeitung der aufgenommenen Daten. Dies beinhaltet die Erkennung der R-Zacke im EKG, die Berechnung und Bereinigung des Tachogramms, die Fourier-Transformation in den Frequenzraum und die Abbildung der symbolischen Dynamik. Insbesondere die Bereinigung von Artefakten im Tachogramm ist aufwendig und bedarf viel Erfahrung im Umgang mit Zeitreihen. Mit den Erfolgen des maschinellen Lernens der letzten zehn Jahre und dem Zugang an Rechenkapazität ist die Anwendung von neuronalen Netzen auf HRV-Daten potentiell eine weitere Methode der Analyse und der Automation. Auf Grund der Ähnlichkeit der Daten in der Domäne der HRV und der linguistischen Datenverarbeitung lassen sich die Architekturen und Entwicklung der neuronalen Netze für die Analyse von Sprache auf die Analyse von HRV-Zeitreihen übertragen. Zu den erfolgreichsten neuronalen Netzen in der Verarbeitung von Sprache gehören die Long-Short-Term-Memory- und Attention-Netzwerke [She20; VSP+17]. Die Flexibilität und der schnelle Einsatz dieser Modelle erlaubt kurzfristige Tests von Thesen und lässt auf neue Anwendungen im Alltag hoffen.

Die neuronalen Netze werden in der Programmiersprache Python codiert, wobei die Pakete Tensorflow und Keras die benötigten Funktionen liefern. Zur Archivierung und Ordnung der trainierten Modelle wird das Paket MLFlow genutzt. Die Kalkulationen werden hauptsächlich von der CUDA-fähigen GPU NVIDIA GeForce RTX 3080 ausgeführt.

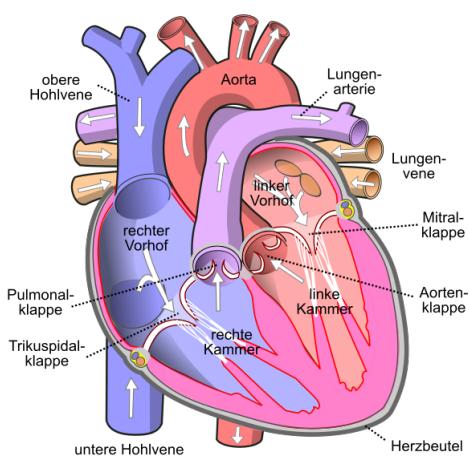
# 3 Anatomie und Physiologie

## 3.1 Kardiologie

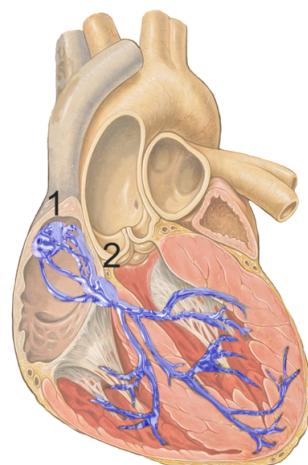
### 3.1.1 Das Herz

Die Aufgabe des Herzens ist es den Blutkreislauf aufrecht zu erhalten und damit den Transport von Sauerstoff, Nährstoffen und Abfallstoffen im Gewebe zu gewährleisten. Dafür ist das Herz mit Muskelgewebe und Herzklappen ausgestattet, die den Blutfluss in und aus dem Herzen steuern. Das Muskelgewebe bildet zwei Ventrikel und zwei Vorhöfe, wobei die linke und rechte Seite des Herzens durch eine Muskelwand streng getrennt sind. Auf diese Weise mischt sich sauerstoffarmes Blut nicht mit sauerstoffreichem Blut und die Effizienz des Stofftransports wird gesteigert. Die Herzklappen fungieren als Ventile und verhindern einen Rückfluss in die Vorhöfe und aus den Arterien. Die Gefäßstruktur im Herzen ist in Abbildung 3.1a schematisch dargestellt.

Der Kreislauf beginnt mit dem Abpumpen von sauerstoffarmen Blut vom rechten Ventrikel über die Lungenarterie in die Lunge. In den Kapillaren der Lunge findet dann ein Gasaustausch statt und das sauerstoffreiche Blut fließt über die Lungenvene in den linken Vorhof. Anschließend wird das Blut vom linken Vorhof in das Ventrikel und über die Aorta in den Körper gepumpt. Nachdem das Blut über die Arterien in den Körper geleitet wurde, wird es über die Venen in den rechten Vorhof geführt. Abschließend wird das Blut aus dem rechten Vorhof in den rechten Ventrikel transportiert, womit der Kreislauf geschlossen wird.



(a) Gefäßstruktur [Jak23]



(b) Erregungsleitungssystem [Heu23]

**Abbildung 3.1.** Schematische Darstellung des Herzens

### 3 Anatomie und Physiologie

---

Die Koordination der Herzmuskeln für einen Herzschlag wird über spezialisierte Muskelzellen aufrecht gehalten. Das primäre elektrische Signal für einen Herzschlag wird in den Schrittmacherzellen des Sinusknoten erzeugt, welche im rechten Vorhof angesiedelt sind. In der Abbildung 3.1b ist die Position mit einer „1“ markiert. Dieses Signal wird rhythmisch und spontan erzeugt, wobei Einflüsse aus dem Parasympathikus und dem Sympathikus die Rate des Signals beeinflussen. Mehr dazu ist im Kapitel 3.4 zu finden. Das elektrische Signal breitet sich über die beiden Vorhöfe aus und wird über den Atrioventrikulknoten an die Kammern geleitet. Die Kammern sind mit spezialisierten Herzmuskelzellen zur schnelleren Fortleitung des Signals durchzogen, welche das His-Bündel und die Tawara-Schenkel und Purkinje-Fasern bilden.

#### 3.1.2 Vorhofflimmern

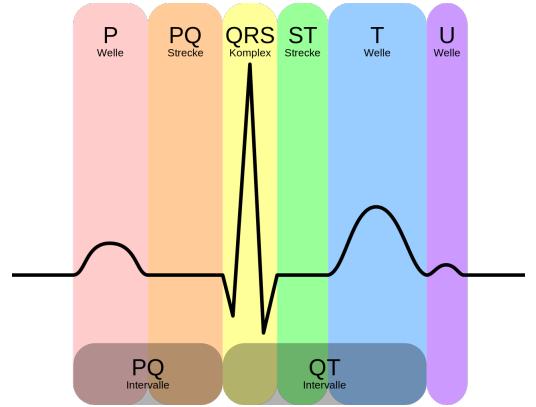
Die Vorhöfe des Herzens dienen zur Erhöhung des Schlagvolumens der Herzkammern, indem sie ca. 150ms vor den Kammern kontrahieren und die Kammern mit zusätzlichem Blut füllen. Bei einem Vorhofflimmern (VHF) ist die Stimulation der Vorhöfe durch ungerichtete elektrische Erregungen gestört, wodurch eine ungeordnete Tätigkeit der Herzvorhöfe ausgelöst wird. Diese ungeregelte Stimulation kann in vorübergehender oder permanenter Form vorliegen, wobei die Wände der Vorhöfe 300 bis 600 Mal pro Minute kontrahieren.

In Deutschland sind 2,5% der Menschen mittleren Alters von Vorhofflimmern betroffen, wo bei der Anteil betroffener Personen mit dem Alter zunimmt [SWW+12]. Damit sind VHF die am meisten auftretende Arrhythmie der Herzrate und werden mit einem erhöhtem Risiko von Schlaganfällen, Herzversagen und wahrscheinlich Demenz in Verbindung gebracht [MBG+16]. Die größten Risikofaktoren für VHF sind arterielle Hypertonie, Adipositas, Diabetes mellitus und chronische Niereninsuffizienz [KBK+16]. Nach derzeitigem Wissenstand kann nur die Hälfte der Vorhofflimmern Ereignisse durch Herzkreislauferkrankungen und deren Risikofaktoren erklärt werden [ANW+17], womit das unvollständige Verständnis um das Auftreten von Vorhofflimmern quantifiziert wird [BCB+09]. Dysfunktionen der autonomen Regulation der Herzrate sind mögliche Risikofaktoren für Vorhofflimmern, [Cou94] daher wird vermutet, dass die Herzratenvariabilität kurz vor dem Einsetzen eines Vorhofflimmerns Hinweise auf die zugrundeliegende Mechanik geben sollte [WBK+20].

#### 3.1.3 Der Herzschlag im EKG

Eine etablierte Methode, das Herz zu untersuchen, ist das Elektrokardiogramm. Das erste EKG wurde 1882 von Augustus Waller an seinem Hund aufgenommen. Willem Einthoven verbesserte das Messverfahren mit Hilfe des Saitengalvanometers, womit das Signal erstmals fotografisch aufgenommen werden konnte. Er erhielt für seine Erfindung und Forschung am Elektrokardiogramm (EKG) 1924 den Nobelpreis für Medizin [JCK18]. Heutzutage wird die Projektion des elektrischen Signals im Herzen auf die Haut mit Elektroden vermessen und digital in einer Zeitreihe abgespeichert. Die Positionierung der Elektroden auf der Haut erlaubt unterschiedliche Ableitungen durch das Herz zu messen, die verschiedene Informationen liefern können. Daher werden Aufnahmen oft mit mehreren Elektrodenpaaren durchgeführt und die Kanäle werden parallel in Zeitreihen dargestellt. In Abbildung 3.2 ist ein Herzschlag in einer EKG schematisch dargestellt.

Die P-Welle ist die Projektion der Erregung des Sinusknotens und der Ausbreitung des elektrischen Signals über beide Vorhöfe. In dieser Phase kontrahieren die Vorhöfe und die Ventrikel werden mit zusätzlichem Blut gefüllt. Während der PQ-Strecke wird das Signal an den AV-Knoten geleitet und durch diesen verzögert, um die Ventrikel nicht zu früh zu kontrahieren. Der QRS-Komplex entsteht dann aus der Weiterleitung des Signals an die Ventrikel und führt zur Kontraktion selbiger. In der ST-Strecke sind die Ventrikel vollständig kontrahiert und das Blut wird aus dem Herzen getrieben. Die T-Welle markiert die Repolarisierung der Zellen, die Entspannung der Ventrikel und die Öffnung der Herzklappen.



**Abbildung 3.2.** Herzschlag im EKG [Hel23]

## 3.2 Autonomes Nervensystem

Die Unterteilung des Nervensystems in autonom und somatisch bezieht sich auf die willkürliche Kontrolle der zugeordneten Funktionen. Wobei die Trennung grob zu verstehen ist, da einige Ausnahmen in den jeweiligen Systemen bewusst bzw. unbewusst kontrolliert werden können. Dem autonomen Nervensystem (ANS) werden die Vitalfunktionen wie Herzschlag, Atmung, Verdauung und Stoffwechsel zugeordnet. Darüber hinaus kontrolliert das ANS Organe, wie Drüsen, Blutgefäße, die inneren Augenmusken und Sexualorgane. Durch den Einfluss des ANS auf ein breites Spektrum von lebenswichtigen Funktionen wird selbigem eine große Bedeutung für die Gesundheit beigemessen. Jedoch sind die komplexen Mechanismen des ANS noch nicht vollständig verstanden und Gegenstand aktueller Forschung [JCK18; VSH+15]. Das ANS ist in drei weitere Nervensysteme unterteilt: der Sympathikus, der Parasympathikus und das enterische Nervensystem. Das sympathische Nervensystem wird mit einer nach außen gerichteten Aktionsfähigkeit assoziiert und dient dem Parasympathikus als Gegenspieler, welches mit einer trophotropen Wirkung auf die Organe in Verbindung gebracht wird. Die Wechselwirkung beider Systeme hat großen Einfluss auf die Herzrate und Eingriffe in dieses System erlauben eine begrenzte Steuerung der Herzrate. Das enterische Nervensystem durchzieht den gesamten Magen-Darm-Trakt mit etwa 100 Millionen Nervenzellen und kontrolliert den Verdauungsprozess. [KKMS21]

### 3.2.1 Parasympathikus

Im Hirnstamm und im Kreuzmark befinden sich die Zentren des Parasympathikus, weshalb es auch als kraniosakrales System bezeichnet wird. Aus dem Hirnstamm heraus steuert der Parasympathikus die inneren Augenmusken, die Tränen- und Speicheldrüsen und über den Nervus vagus die meisten inneren Organe, wozu das Herz zählt. Die Nerven im Kreuzmark innervieren den Dickdarm, die Harnblase und die Genitalien.

Die trophotrope Wirkung des Parasympathikus auf das Herz zeigt sich im Abfall der Herzrate. Dies wird durch eine niedrigere Erregungsrate im Sinusknoten, eine höhere Erregungsschwelle der Zellen im Herzen und eine langsamere Signalsausbreitung im Erregungsleitsystem erreicht.

### 3 Anatomie und Physiologie

---

#### 3.2.2 Sympathikus

Das sympathische Nervensystem wird auch thorako-lumbales System genannt und geht von Brust- und Lendenmark aus. Der Sympathikus bewirkt eine Leistungsteigerung in dem die Herztätigkeit, der Blutdruck, die Muskelspannung, die Glykolyse und der Stoffwechsel gesteigert werden. Bei Aktivierung des thorako-lumbalen Systems werden die unter Stress nicht notwendigen Organe wie der Darm, die Nieren und die Haut schlechter und akut wichtige Organe besser durchblutet. Des Weiteren beeinflusst das sympathische System die Lunge, die Blase, die Geschlechtsorgane und die inneren Augenmuskeln. [KKMS21]

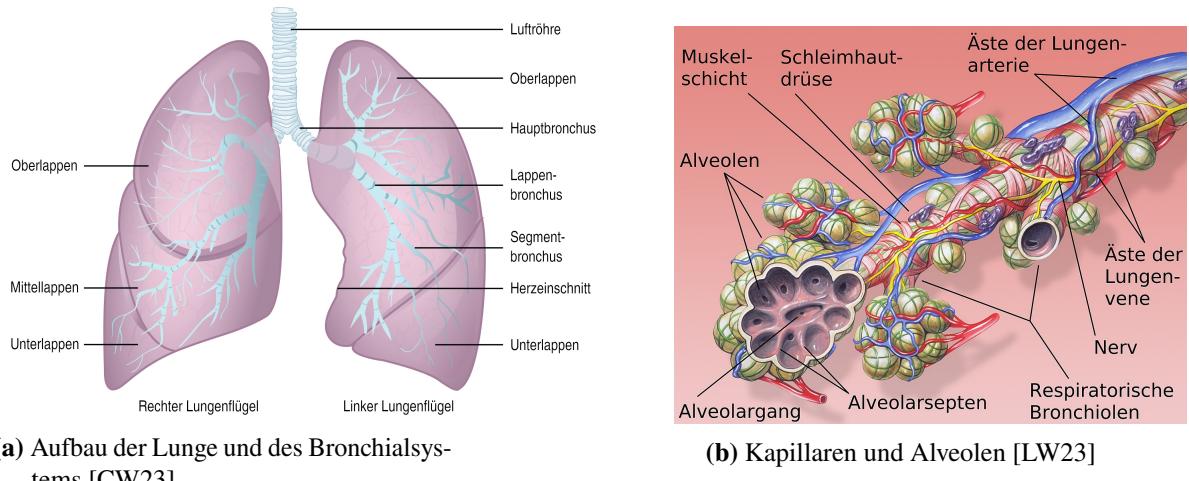
#### 3.2.3 Barorezeptoren

Der Blutdruck im menschlichen Körper beträgt in den größeren Arterien 120/80 mmHg und sinkt von Arterie über Kapillare zu Venen ab. Der Fluss des Blutes wird durch diesen Gradienten am Laufen gehalten. Daher ist die Aufrechterhaltung des Druckes durch Herzschläge von lebenswichtiger Bedeutung. Ein zu geringer Arterienblutdruck oder ein schwacher Gradient des Druckes führt zu einer Unterversorgung der Organe und zu Symptomen wie Konzentrationsschwäche, rasche Ermüdbarkeit, Tachykardien und Ohnmachtsanfällen. Insbesondere die schlechte Versorgung des Gehirns mit Sauerstoff gilt als Ursache für schwere Symptome und Schäden. [KKMS21] Ähnliche Symptome finden sich auch bei Patienten mit chronisch hohem Blutdruck, wobei arterielle Hypertonie unbehandelt ein Risikofaktor unter anderem für Atherosklerose [Hen23], Schlaganfälle, chronische Niereninsuffizienz, Vorhofflimmern und koronare Herzkrankheit (KHK) darstellt [Her19].

Um den Blutdruck stabil auf einem gesunden Niveau zu halten, wird der Zeitpunkt der nächsten Herzschläge angepasst werden. Hierzu geben Barorezeptoren in den Arterien dem Nervus vagus Signale über den Blutdruck und dessen Ableitungen erster und zweiter Ordnung. Falls der Blutdruck zu gering ist, wird der Parasympathikus über den Nervus vagus gehemmt und daraus folgt eine Steigerung der Herzrate. Dem Prinzip der negativen Rückkopplung folgend wird bei hohem Blutdruck von den Barorezeptoren eine Verringerung der Herzrate bewirkt. Die wichtigsten Barorezeptoren sitzen in der Aorta und dem Karotissinus, sprich am Herzen und an der Halsschlagader. Die Rezeptoren arbeiten mechanisch und reagieren auf die Dehnung des Blutgefäßes [LLY+16]. Eine schematische Darstellung der Rezeptoren und deren Verbindung zum autonomen Nervensystem finden Sie in der Abbildung 3.3.

### 3.3 Lunge

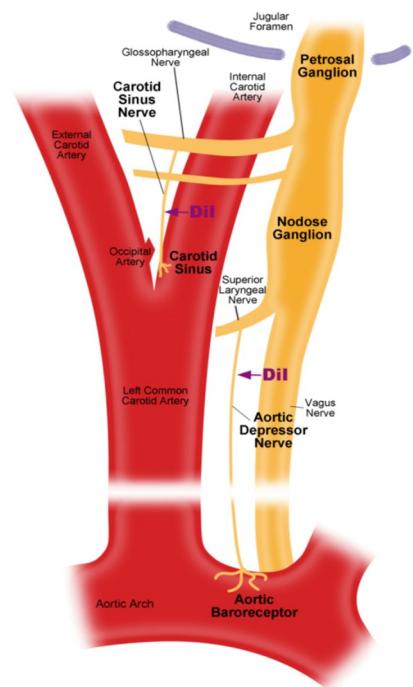
Im Modell der kardiovaskulären Regulation nach Berger und Saul übt die Atmung neuronalen und mechanischen Einfluss auf die Herzrate aus. Mit Atmung in diesem Fall ist die äußere Respiration in der Lunge gemeint, welche den Gasaustausch zwischen Luft und Blut bewirkt. Die innere Atmung in den Zellen wirkt über die Änderung des Verhältnisses zwischen Kohlendioxid und Sauerstoff auf die Atemfrequenz und -volumen. Der theoretische Unterbau beschäftigt sich mit der äußeren Atmung, da der Einfluss der innere Atmung auf die Herzrate über die äußere Atmung wirkt.



**Abbildung 3.4.** Schematische Darstellung der Lunge

Die Lunge eines erwachsenen Menschen fasst 5 bis 6 Liter Luft und führt 10 bis 20 Atemzüge pro Minute aus. Die Einatmungsphase dauert üblicherweise 1 bis 2,5 Sekunden und die Dauer der Ausatmung beträgt 2 bis 3,5 Sekunden. Das Organ besteht aus zwei Lungenflügeln, welche wiederum in Lungenlappen unterteilt sind. Der rechte Lungenflügel besitzt drei Lappen und ist größer als der linke Flügel. Der linke Lungenflügel teilt sich den Raum mit dem Herzen und besitzt nur zwei Lungenlappen. Diese Nähe begünstigt die mechanische Kopplung der Bewegungen beider Organe. Die Lungenlappen sind nochmals unterteilt in Lungensegmente, welche mit Arterien und Venen durchzogen sind. Die Blutgefäße der Segmente sind direkt mit dem Herzen verbunden. In diesen Segmenten befinden sich die Kapillaren und Lungenbläschen, welche den Gasaustausch vollziehen. Die Lungenbläschen, auch genannt Alveolen, sind der einzige Teil des Bronchialsystems in dem Gas mit dem Blut ausgetauscht wird. Die 300 Millionen Alveolen haben einen Durchmesser von etwa 200 µm. Der Gasaustausch geschieht an der Blut-Luft-Schranke zwischen Lungenbläschen und Kapillaren, welches aus mehreren Schichten besteht und etwa 1 µm dick ist. Der Austausch ist aus physikalischer Sicht eine Gasdiffusion durch die dünne, luftdurchlässige Trennschicht. Die Alveolen werden von Ästen des Bronchialsystems mit Luft versorgt. Die Verzweigungen fügen sich zu immer dickeren Ästen zusammen und enden in den Luftröhre. Die Kapillaren führen entlang der Äste zu den Lungenarterien und -venen.

Die neuronalen Impulse der Atmung stammen aus der ventralen respiratorischen Gruppe (VRG) im verlängerten Markhirn des unteren Hirnstamms. Als Teil des parasympathischen Systems gibt die VRG die Signale der drei Atemphasen autonom ab, wird jedoch durch Reize der Retikulärforma-



**Abbildung 3.3.** Barorezeptoren in Aorta und Halsschlagader [LLY+16]

### **3 Anatomie und Physiologie**

---

tion angetrieben. In der Retikulärformation sind inspiratorisch aktive Neurone und expiratorisch aktive Neurone zu finden. Das Gleichgewicht der Aktivität beider Neuronentypen beeinflusst das Aussenden von Signalen zur Ein- und Ausatmung. Die Retikulärformation, auch bekannt unter der lateinischen Bezeichnung *Formatio reticularis*, erhält Signale aus den Barorezeptoren und Chemorezeptoren der Blutgefäße und dem Nervus Vagus über die Lungenausdehnung. Die willentliche Steuerung der Atmung wird ebenfalls über den Nervus vagus geleitet. Die Signale hemmen und enthemmen je nach Zustand die beiden Neuronentypen in der *Formatio reticularis* und steuern auf diese Weise die Atemfrequenz und -volumen. [Ras86]

#### **3.3.1 Atmung**

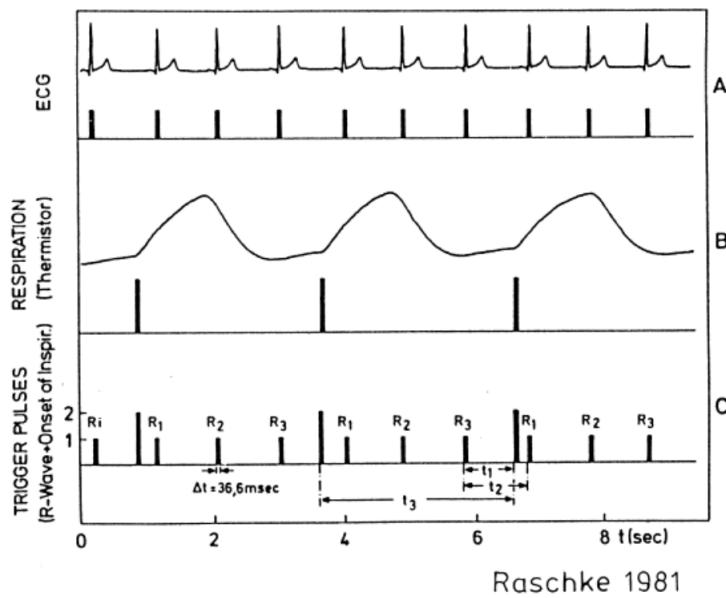
Die Atembewegung wird in drei Phasen aufgeteilt die Inspirationsphase, Postinspirationsphase und die Expirationsphase. Die Lunge besitzt keine Muskeln und wird durch die Erweiterung und Verkleinerung des Thoraxvolumens dekomprimiert und komprimiert. Die Lunge ist von der Pleura pulmonalis umhüllt, die über den Pleuraspalt mit der Pleura parietalis des Brustkorbs verbunden ist. Die mechanische Bindung der beiden Pleura wird durch den Unterdruck und der Flüssigkeit im Pleuraspalt hervorgerufen.

In der Inspirationsphase werden dem Zwerchfell und den äußeren Zwischenrippenmuskeln Kontraktion signalisiert und Luft wird in die Lunge eingesogen. Die Vergrößerung des Thoraxvolumens steißbeinwärts wird Bauchatmung genannt und wird vom Zwerchfell hervorgerufen. Die Zwischenrippenmuskeln erweitern bei Kontraktion den Brustkorb durch das Anheben der Rippen. In der Postinspirationsphase lässt die neuronale Aktivierung der Muskeln des Zwerchfells und der Zwischenrippen nach und die Muskeln entspannen sich. Die elastische Energie der Ausdehnung kann sich hierdurch entladen und die Verkleinerung des Thoraxvolumens setzt ein. Der Großteil der Expiration der verbrauchten Luft wird in dieser passiven Ausatmung ausgeführt. Die Expirationsphase wird durch die Aktivierung der expiratorischen Muskeln gekennzeichnet. Durch die Kontraktion dieser Muskeln wird das Zwerchfell angehoben, wodurch sich der Druck im Thorax erhöht. Die stärkere Entleerung der Lunge verstärkt zwar den Austausch der verbrauchten Luft, benötigt jedoch viel Energie und ist schwierig zu kontrollieren. Daher wird die aktive Expirationsphase nur unter körperlicher Aktivität und Stress genutzt.

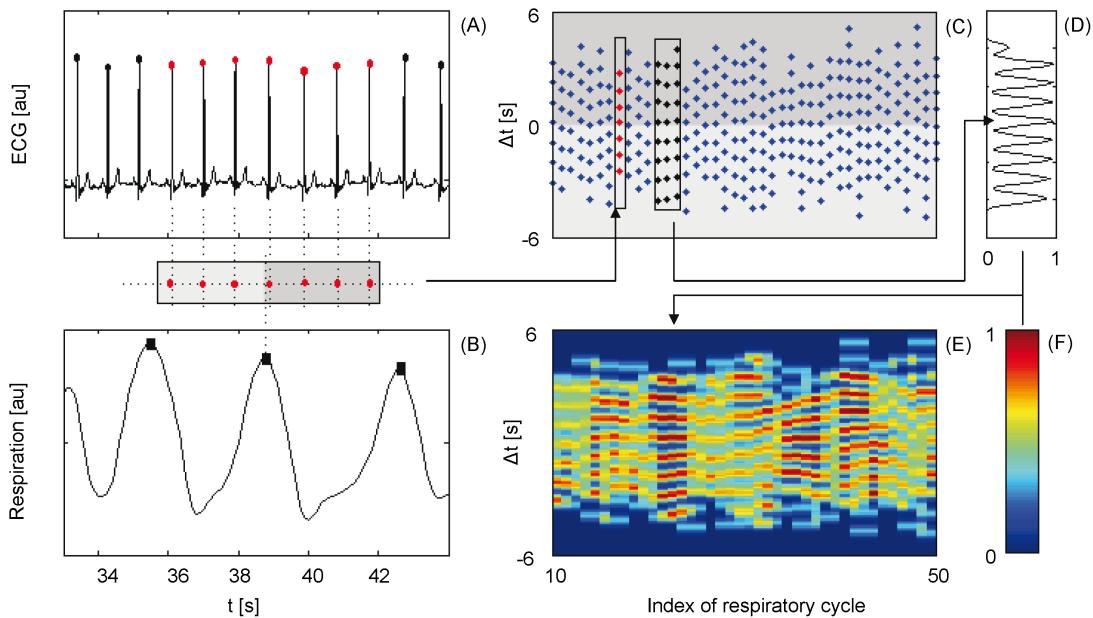
#### **3.3.2 Kardiorespiratorische Koordination**

Bei diesem Phänomen treten Herzschläge vermehrt in gleichem zeitlichem Abstand zum Beginn der Inspirationsphase ein. Im Gegensatz zur RSA wird die kardiorespiratorische Koordination (KRK) durch die gegenseitige Aktivierung des Atemzyklus und der Herzschläge verursacht. Zur Bestimmung der KRK wird ein Koordigramm erstellt und analysiert. In der Abbildung 3.5 ist die Berechnung der zeitlichen Abstände zwischen den Herzschlägen und dem Beginn der Einatmung dargestellt.

Die Herzschläge vor und nach einem Beginn des Atemzyklus werden anschließend in einem Diagramm aufgetragen. Auf die x-Achse werden die Beginns der Atemzyklen aufgereiht. Auf der Vertikalen werden die Herzschläge mit ihren zeitlichen Abständen zum Beginn eingetragen. In der Abbildung 3.6 ist der Prozess beispielhaft dargestellt. Bei einer starken Kopplung treten



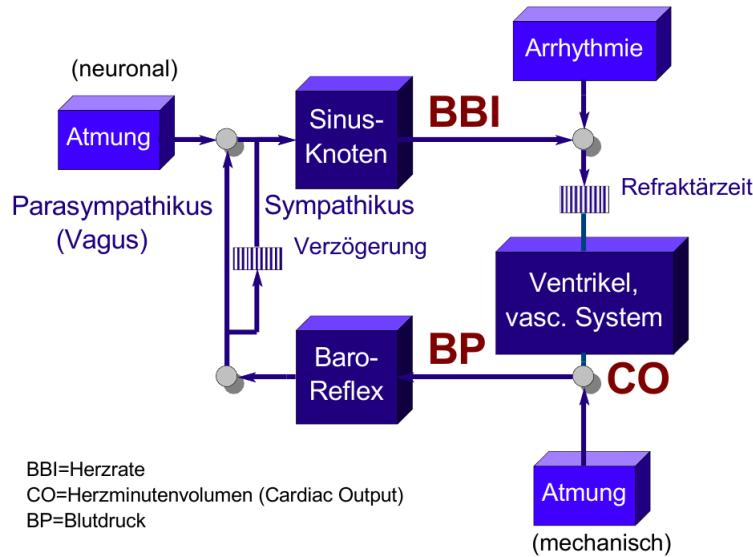
**Abbildung 3.5.** Feststellung einer RSA [Ras86]



**Abbildung 3.6.** Konstruktion des Koordigramms [RMK+14]

die Herzschläge bei ähnlichen zeitlichen Abständen auf und bilden horizontale Linien auf dem Koordigramm. Über mehrere Atemzyklen hinweg kann eine Verteilung der Punkte erstellt werden. Aus dieser lassen sich anschließend Parameter berechnen, die ein Maß für die KRK darstellen.

Die KRK tritt unter entspannten Bedingungen wie Anästhesie [GL97], Schlaf [CBL+04] und kontrollierter Atmung [CVL+04] auf. Im Falle der Schlafapnoe kann man dieses Phänomen auch bei hohem autonomen Stress beobachten [RMK+14].



**Abbildung 3.7.** Kardiovaskuläre Regulation nach Berger und Saul aus der Vorlesung der AG CVP [ASBC89]

### 3.4 Die kardiovaskuläre Regulation

Die Regulation der Herzrate kann man als nicht-lineares System beschreiben in dem der Sinusknoten als Haupttaktgeber dient. In Abbildung 3.7 finden Sie eine bildliche Darstellung des Modells. Der Sinusknoten gibt einen elektrischen Impuls an die Herzmuskel, die sich darauf hin kontrahieren. Durch die Kontraktion wird Blut in die Adern gepumpt und wird als ein Herzzeitvolumen gemessen. Das Herzzeitvolumen wird zusätzlich von der Atmung mechanisch beeinflusst. Der Anstieg des Blutdrucks wird von den Baroreflexen registriert und diese Aktivierung wird an den Sympathikus und den Parasympathikus weitergeleitet. Diese beiden Nervensysteme sind Teil des autonomen Nervensystems und können im Zusammenspiel die Herzrate beschleunigen oder verlangsamen, indem sie auf den Sinusknoten einwirken. [Es192]

Die Wechselwirkung dieser Faktoren ist bei gesunden und erkrankten Patienten unterschiedlich und kann sich in der Variabilität der Herzrate niederschlagen. Je nach Erkrankung weichen unterschiedliche Faktoren von der Norm ab und bilden erkrankungsspezifische Herzratenvariabilitäten. [ABS+89; SBA+91; VSH+15]

# 4 Statistische Methoden

## 4.1 Herzratenvariabilität

Die Variationen der Herzrate im Laufe einer Zeitreihe werden mit dem Begriff Herzratenvariabilität beschrieben. Die Variationen sind die Konsequenzen der kardiovaskulären Regulation wie in 3.4 beschrieben. Die HRV variiert stark zwischen einzelnen gesunden Versuchspersonen [JSB+97], deutet jedoch bei hohen Werten auf eine gute Anpassungsfähigkeit bezüglich körperlichen Belastungen und Veränderungen in der Umgebung hin. Im Laufe des Alterungsprozesses und Krankheitsverläufen reduziert sich die HRV und auch die Komplexität der Herzrate nimmt ab [VSS+09]. Die HRV kann durch verschiedene Faktoren beeinflusst werden, so z.B. chemische und hormonelle Mittel, dem zirkadianen Rhythmus, körperlicher Aktivität, emotionalem Stress und Körperhaltung. Der Einfluss dieser Faktoren wird über regulatorische Systeme wie dem ventralen respiratorischen Gruppe, den Barorezeptoren oder dem Nervus vagus vermittelt. Die große Variation an kardiovaskulärer Modulation besteht aus linearen und nicht-linearen Elementen, daher ist eine rein lineare Analyse der Herzrate nicht angemessen und sollte durch nicht-lineare Methoden ergänzt werden [GAH+02; HMP03; SDH+05].

### 4.1.1 Tachogramm

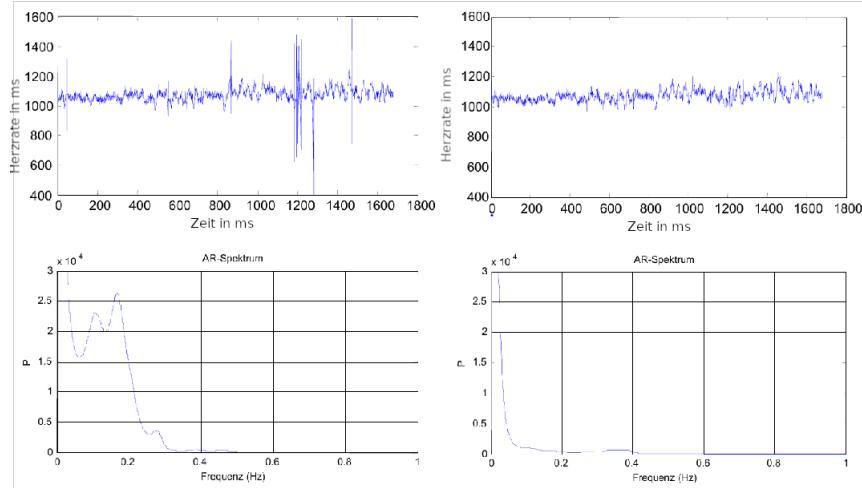
Die Herzrate wird am zeitlichen Abstand zweier aufeinanderfolgender R-Zacken oder anderen Merkmalen eines Herzschlag im EKG festgemacht. Damit kann man jedem Herzschlag eine Herzrate zuordnen und eine Zeitreihe bilden. Die Abtastrate der Schlag-zu-Schlag-Zeitreihe variiert mit der Herzrate und liegt bei einem gesunden, ruhenden Menschen zwischen 0,8 und 1,6 Hz. Durch die niedrige Abtastrate gestaltet sich die Analyse von Anteilen über der Nyquist-Frequenz in der Spektralanalyse der Schlag-zu-Schlag-Zeitreihe schwierig.

Eine höhere Abtastrate erhält man durch eine Interpolation der Herzrate zwischen den Schlägen. Die Herzschläge werden zeitlich am R-Zacke festgemacht, wobei der R-Zacke die zweite Zacke im QRS-Komplex ist. Die daraus resultierende Zeitreihe wird Tachogramm genannt und wird schematisch in Abbildung 4.3a dargestellt. Die feste Abtastrate der Zeitreihe vereinfacht zudem die Handhabung in den statistischen Analysen. In der Praxis finden sich im Tachogramm oft Artefakte technischer und physiologischer Natur wie nicht erkannte R-Zacken, Fehlerkennungen und Arrhythmien. Die Bereinigung dieser Fehlmessungen ist in der HRV-Analyse sehr wichtig, da hierdurch die HRV punktuell stark zu- oder abnimmt. Insbesondere in der Spektralanalyse werden hierdurch Peaks verursacht, die das physiologische Signal überdecken. In der Abbildung 4.1 finden Sie ein Beispiel für diesen Effekt.

## 4 Statistische Methoden

---

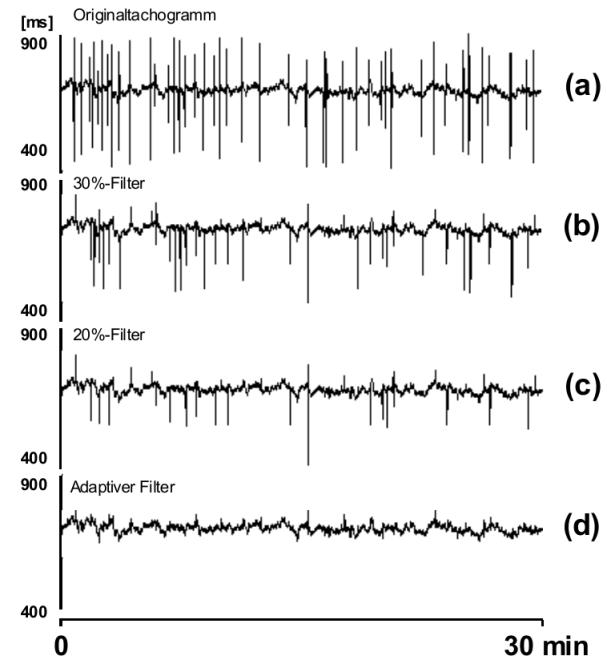
**30-min Tachogramm und dessen Fouriertransformation vor und nach Filterung**



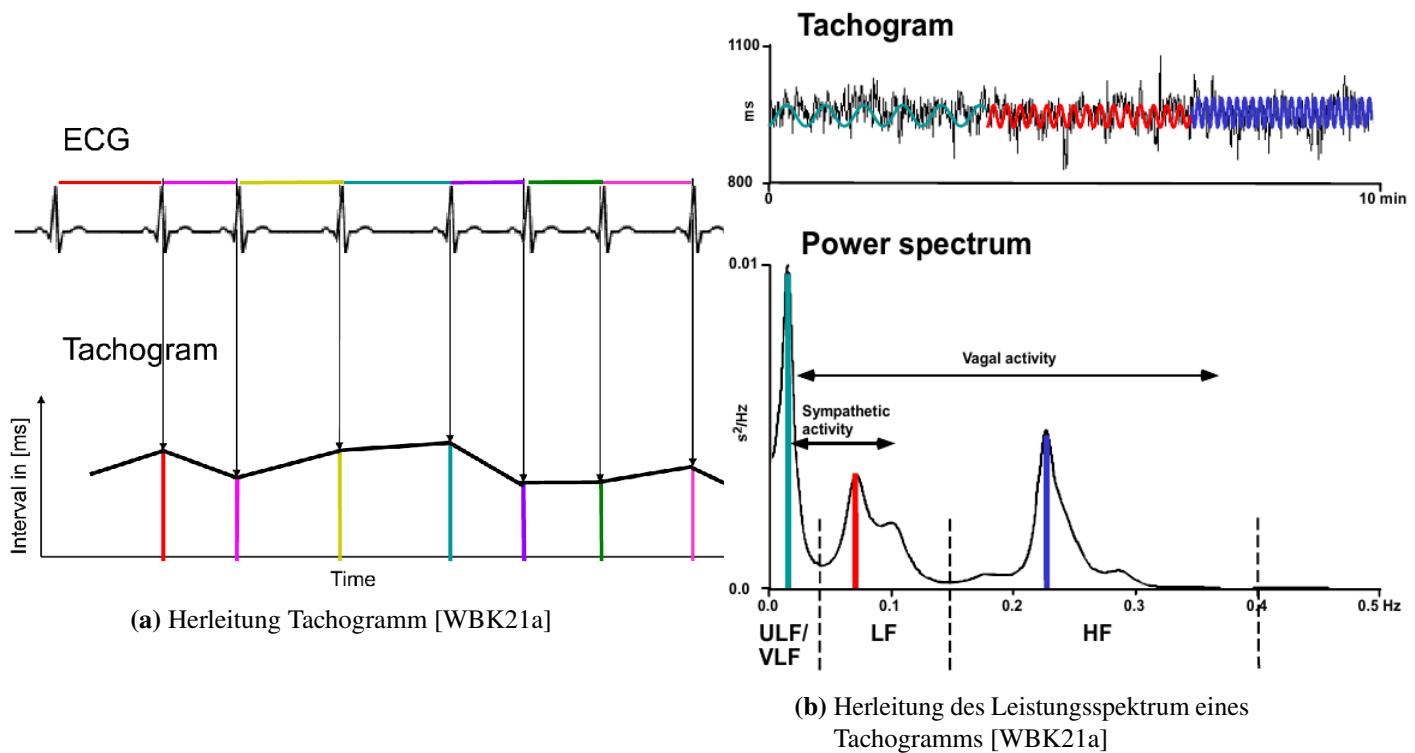
**Abbildung 4.1.** Auswirkung von Artefakten auf Spektralanalyse [WBK21b]

Diese Schwankungen verfälschen die nachfolgenden Analysen und verringern deren Aussagekraft. In der Behandlung der Artefakte muss unter mehreren Methoden ausgesucht werden, wobei eine Abwegung zwischen technischer Komplexität und die Einbringung von nicht-physiologischen Eigenschaften berücksichtigt werden muss. In der Vorverarbeitung wird der adaptive Filter [WMBK07] zur Erkennung und Ersetzung von Artefakten eingesetzt. Im ersten Schritt durchläuft das Tachogramm einen binomialen Filter, der als Tiefpassfilter fungiert. Anschließend wird aus dem gefilterten Tachogramm ein adaptiver Mittelwert und Standardabweichung berechnet, wobei mit einem Koeffizienten die Anpassungsgeschwindigkeit auf Veränderungen im Tachogramm moduliert wird. Die beiden Werte werden durchgehend für jeden Zeitschritt im Tachogramm berechnet. Aus diesen beiden Wertereihen lassen sich dann ein Prozentfilter und Kontrollfilter definieren, die in Domänen hoher bzw. niedriger Abweichung größere bzw. kleinere Intervalle passieren lassen. Abschließend werden die als Artefakte erkannten Datenpunkte mit einem Wert ersetzt, welches um den adaptiven Mittelwert liegt, aber maximal eine halbe Standardabweichung davon abweicht. Der adaptive Filter erkennt zuverlässig Artefakte auch unter variierenden Bedingungen und ersetzt diese ohne eine Phasenverschiebung oder lokale Konstanz einzuführen. Einen Vergleich der Artefakterkennung zwischen Prozentfiltern und dem adaptiven Filter finden Sie in der Abbildung 4.2.

Das Tachogramm wird anschließend mit linearen Verfahren im Zeit- und Frequenzbereich und im nicht-linearen Bereich wie den Poincaré-Abbildungen analysiert.



**Abbildung 4.2.** Vergleich von unterschiedlichen Filtern [WBK21b]



**Abbildung 4.3.** Schematische Darstellung des Tachogramms und dessen Fouriertransformation

#### 4.1.2 Spektralanalyse

In der Spektralanalyse werden die drei Frequenzbänder sehr niedrige Frequenz (VLF), niedrige Frequenz (LF) und hohe Frequenz (HF). In der Abbildung 4.3b ist eine schematische Darstellung der Spektralkurve im Frequenzbereich zu finden. Zur Analyse werden die Leistungen in Bereichen als Parameter genutzt. Der VLF-Bereich liegt unterhalb von 0,04 Hz und spiegelt den Einfluss relativ langsamer Körperprozesse auf die Herzrate wieder wie zum Beispiel der Thermoregulation. Das Intervall des LF-Bereichs liegt zwischen 0,04 Hz und 0,15 Hz. Den Leistungsanteil im LF kann man auf die regulatorischen Mechanismen des Baroreflexes zurückführen. Die Leistung des HF-Bereichs berechnet man durch eine Integration der Spektralkurve zwischen 0,15 Hz und 0,4 Hz. Dieser Parameter wird hauptsächlich durch die respiratorische Sinusarrhythmie beeinflusst. Eine einfache Anwendung der Spektralanalyse liegt in der Stressmessung des Patienten anhand des Quotienten LF/HF [WBK21a].

Des Weiteren kann man die Kopplung zwischen Atmung und Herzschlag anhand der Peakhöhe der Spektralkurve quantifizieren.

#### 4.1.3 Nicht-Linearität

Die Analyse der nicht-linearen Anteile der HRV hat einen hohen Stellenwert, da die Herzrate und die Einflüsse darauf als nicht-lineares dynamisches System beschrieben werden können. Eine nicht-lineare Analysemethode beinhaltet die Erstellung eines Poincaré-Diagramms von

## 4 Statistische Methoden

---

aufeinanderfolgenden Herzraten, dargestellt in Abbildung 4.4. Die beiden Durchmesser im Diagramm SD1 und SD2 geben den Einfluss des Parasympathikus und Sympathikus wieder. Aus den Werten lässt sich ein Score für den Stress der Versuchsperson ableiten.

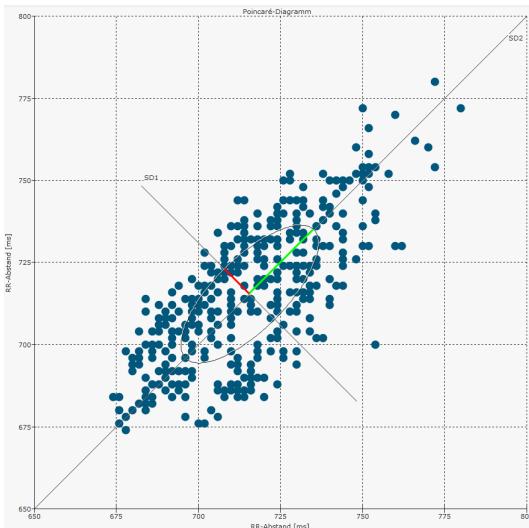


Abbildung 4.4. Poincaré-Diagramm [Fra23]

Eine weitere nicht-lineare Methode ist die symbolische Dynamik, welches in Rahmen der Masterarbeit angewendet wird [KVS+95; VKK+96; VSS+09]. Hierbei werden die Datenpunkte eines Tachograms zu diskreten Buchstaben transformiert. Die Abbildung auf die Buchstaben hängt von der Änderung aufeinanderfolgender Herzraten ab. Dazu werden mehrere Intervalle definiert und jedem wird ein Buchstabe zugeordnet. Anschließend werden die Änderungen der Herzraten den Intervallen und Buchstaben zugeordnet. Darauffolgend werden die Buchstaben zu Wörtern zusammengefasst und die Wortverteilung wird in einem Histogramm erfasst. Je nach Definition der Intervalle, Anzahl an Buchstaben und Länge an Wörtern lassen sich unterschiedliche Parameter berechnen, die verschiedene Aspekte der kardiovaskulären Regulation widerspiegeln.

Die vielfältigen Analysemethoden und die vielen lineare und nicht-lineare Parameter lassen sich für Klassifikationen und Diagnosen nutzen, wobei je nach Problemstellung unterschiedliche Parameter zufriedenstellende Lösungen bieten. [ABS+89; SBA+91; VSH+15]

## 4.2 Cardiac Autonomic Dysfunction and Incidence of de novo Atrial Fibrillation

Das Ziel dieses Papers ist es die Zusammenhänge zwischen den *de novo* Vorhofflimmern, den Störungen vor Einsetzen eines anfallartigen Vorhofflimmerns und der 7-Tage Herzratenvariabilität zu untersuchen. Dazu wird der Datensatz ReactDX herangezogen, welches aus Daten von Patienten mit dem implantierten Defibrillator BIOTRONIK Lumax VR-T DX besteht. Im Paper werden zwei Gruppen von Patienten mit Hilfe von nicht-linearen Parametern der HRV klassifiziert. Der Datensatz wird im Kapitel 5.1.1 näher beschrieben. Die nicht-linearen Parameter zur Klassifikation der beiden Gruppen wird aus der symbolischen Dynamik berechnet, wobei der Parameter forbidden words die Gruppen an allen Tagen der 7-Tage-EKGs signifikant unterscheiden konnte. Der Parameter forbidden words ist ein Maß für die Komplexität der Herzrate und ist in der Gruppe de novo VHF niedriger als in der Kontrollgruppe. Somit kann man eine geringere Herzratenkomplexität in Verbindung setzen mit einem höheren Risiko für Vorhofflimmern.

## 4.3 Maschinelles Lernen

In der computergestützten Lösung von Aufgabenstellung kann man unter zwei Formen unterscheiden. Ein Problem kann in einer unkomplizierten Umgebung mit überschaubaren Regeln existieren, wodurch die Lösung formal einfach beschrieben werden kann. Hierbei ist die Größe der Umgebung

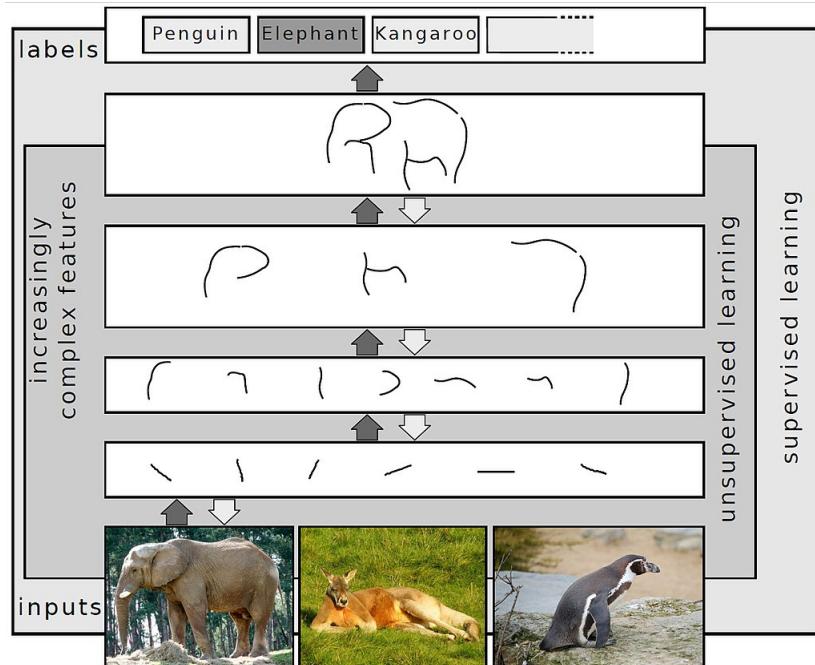
für die Schwierigkeit der Aufgabenstellung irrelevant. Ein gutes Beispiel ist Schach bei dem menschliche Großmeister die anspruchsvollen Schachprogramme seit Jahrzehnten nicht mehr schlagen können. Auf der anderen Seite stellen unkomplizierte Aufgabenstellungen aus der realen Welt eine große Herausforderung für klassische Algorithmen dar. Solche Probleme wie die Erkennung von Objekten in Bildern, die Menschen intuitiv und schnell lösen, können, falls möglich, nur unter viel Aufwand vollständig beschrieben werden. Erst in den letzten Jahren mit dem Aufkommen des Maschinellen Lernens können solche Aufgaben von Computern auf menschlichem Niveau gelöst werden [GBC16]

Im Alltag ermöglichen computergestützte Lösungen eine Automatisierung und damit den Einzug in den Alltag. Mit der Erfindung des Computers war es zunächst möglich nur Aufgaben, welche für Menschen schwierig auszuführen sind, jedoch algorithmisch einfach zu beschreiben sind, im großen Stil zu automatisieren. Die Automation algorithmisch einfacher Aufgaben hat große technologische Fortschritte gebracht und hat eine fortschreitende Digitalisierung hervorgerufen. Die Verfügbarkeit und Präsenz der Automation in dieser Form ist im Alltag unentbehrlich geworden.

Durch die Erforschung neuer algorithmischer Methoden, dem Zuwachs an Datenmengen und der Fortschritte in der Prozessortechnologie werden Automatisierungen von Aufgaben, welche für Menschen einfach zu lösen sind, jedoch schwierig mit formalen Regeln beschrieben werden können, möglich. Das Konzept des Maschinellen Lernens beschreibt eine Reihe von algorithmischen Methoden, die die Suche nach einer Lösung in einer Aufgabenstellung automatisieren sollen. Eines dieser Methoden ist das Erlernen von Repräsentationen eines Datensatzes, im Englischen Representation Learning genannt. Hierbei werden Eigenschaften aus einer Datenmenge extrahiert und zu komplexeren Konzepten zusammengefügt. Eine schematische Darstellung dieses Konzeptes ist in der Abbildung 4.5 zu finden. Die begrenzte Kapazität der verwendeten Modelle machen es notwendig sich auf Eigenschaften und Konzepte zu konzentrieren, die zur Lösung der Aufgaben beitragen. Daher ist die Implementation einer Funktion zur Optimierung der Auswahl an Eigenschaften und Konzepten essenziell. Dazu können unterschiedliche Modellarten eingesetzt werden, Beispiele hierfür sind künstliche neuronale Netze, Entscheidungsbäume, Support Vektor Maschinen oder Regressionsanalysen. Die Modelle werden in Aufgabenstellungen wie der Spracherkennung, dem computerbasierten Sehen und bei Spamfiltern eingesetzt.

Zwei verwandte Konzepte sind die Wissensentdeckung in Datenbanken, im Englischen Data-Mining genannt, und die Statistik. Die Hauptunterschiede zum Maschinellen Lernen ist die Zielsetzung und weniger die eingesetzten Methoden. Bei der Wissensentdeckung in Datenbanken steht die Untersuchung eines Datensatzes im Mittelpunkt, wobei unbekannte Eigenschaften und Zusammenhänge aus einem Datensatz extrahiert werden sollen.[FPS96] Das Ziel hierbei ist es Wissen aus den Datenmengen zu schaffen. Im Maschinellen Lernen hingegen werden bekannte Eigenschaften eines Datensatzes zur Lösung einer Aufgabe genutzt.

In der Statistik werden Eigenschaften einer großen Population geschätzt, wobei eine Extrapolation basierend auf den Eigenschaften einer Stichprobe und den Annahmen über die Population durchgeführt wird. Im Gegensatz zum Maschinellen Lernen, hier werden verallgemeinerte vorhersagbare Muster zur Vorhersage erlernt.[BAK18]



**Abbildung 4.5.** Visualisierung des Erlernen von Repräsentationen am Beispiel der Klassifikation von Tieren an Bilder [Beh23]

Das Training des neuronalen Netzes wird mit einem gelabelten Datensatz durchgeführt und fällt somit unter die Kategorie Überwachtes Lernen. Der Datensatz im Lernprozess wird Trainingsdatensatz genannt und besteht aus gepaarten Input- und Outputdaten, wobei die Outputs die Aufgabenlösung abhängig vom Input wiedergeben. Diese Outputs werden vorgegeben, ermöglichen ein überwachtes Lernen und werden im Folgenden Wahrheit genannt.[RN16]

### 4.3.1 Neural Network

Die Datensätze umfassen in der Regel Tausende Datenpunkte, welche über Dutzende Dimensionen verteilt sind. Die Repräsentation in dieser hoch-dimensionalen Rohform ist unübersichtlich und schwer auszuwerten. Jedoch liegen die Datenpunkte, sofern sie miteinander korrelieren, auf einer niedrig-dimensionalen Mannigfaltigkeit innerhalb des hoch-dimensionalen Datenraumes. Daher werden in vielen Lernalgorithmen Transformationen der Inputdaten auf diese Mannigfaltigkeit erlernt.

Konkret wird der Rohinput in der ersten Schicht zu einer Repräsentation niedrigerer Dimension transformiert, indem sehr simple Muster im Input erkannt werden. In der darauf folgenden Schicht wird diese Repräsentation erneut transformiert, wobei die erkannten Muster miteinander in Beziehung gebracht werden. Dieser Vorgang wird Repräsentationslernen genannt und in jeder Schicht wiederholt, wobei man immer abstraktere Repräsentationen erhält. Die Abstraktion führt zwangsläufig zu Informationsverlusten, vereinfacht jedoch die Lösung der Aufgabe durch Komprimierung der Information. Im Lernprozess werden die Transformationen soweit angepasst bis die letzte Schicht zufriedenstellende Ausgaben präsentiert.[BCV13]

In dieser Masterarbeit wird das Repräsentationslernen mit neuronalen Netzen realisiert. Diese bestehen aus Schichten, welche wiederum aus künstlichen Neuronen aufgebaut sind. Diese Neurone, genannt Perzeptoren, sind einem vereinfachten Modell der biologischen neuronalen Netzen nachempfunden. Ein Perzepron erhält eine oder mehrere Eingaben und gibt eine Ausgabe an eine oder mehrere Verbindungen weiter. Die Eingaben werden vom Neuron einzeln gewichtet, miteinander summiert und mit einem weiteren eingabeunabhängigen Wert des Neurons addiert. Diese Summe wird in eine Aktivierungsfunktion eingegeben. Die Ausgabe dieser Funktion wird allen Neuronen der nachfolgenden Schicht präsentiert.

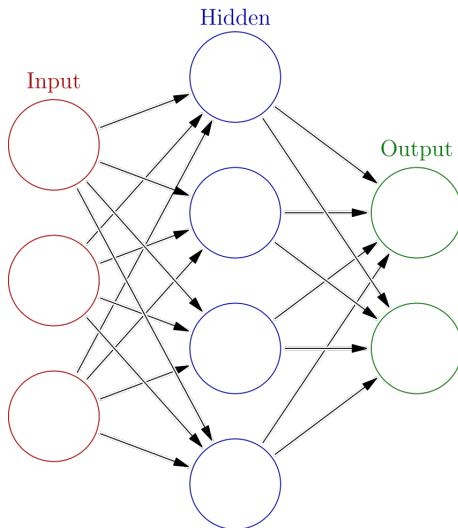
Die Aktivierungsfunktionen haben in neuronalen Netzen oft die zentrale Aufgabe die Nicht-Linearität in das neuronale Netz einzuführen. Oft können komplexe Zusammenhänge in der realen Welt mit linearen Modellen nur unzureichend nachgebildet werden. Weshalb neuronale Netze neben linearen Elementen auch nicht-lineare versteckte Einheiten besitzen, um insgesamt ein nicht-lineares Modell abilden zu können. Dazu werden nicht-lineare Aktivierungsfunktionen wie die rektifizierte lineare Einheit (Abbildung 4.7b), die Heaviside- oder die logistische Sigmoidfunktion verwendet. Ein Nachteil der Nicht-Linearität des Modells ist die nicht-konvexe Kostenfunktion im Gegensatz zu linearen Modellen. Die schrittweise Optimierung der Gewichte im Modell auf die Lösung der Aufgabe führt bei nicht-konvexen Kostenfunktion nicht zwangsläufig zu einem globalen Minimum. Es ist sogar möglich, dass bedingt durch ungünstige Anfangsbedingungen das Training in einem lokalen Minimum endet, welches keine zufriedenstellende Lösung der Aufgabenstellung darstellt [GBC16].

Die Netze bestehen aus jeweils einem Eingabe- und Ausgabeschicht und beliebig vielen versteckten Schichten, wobei alle Schichten aus einzelnen Neuronen bestehen und von unterschiedlicher Breite und Höhe sein können. Die Ausgabe aller Neuronen einer Schicht stellt in ihrer Gesamtheit eine nicht-lineare Transformation der Eingabe der Schicht dar. Die wichtigste Netzarchitektur ist die der Feedforward-Netze. In dieser Architektur sind alle Neurone in einer Schicht, wie in Abbildung 4.6 dargestellt, mit allen Neuronen der benachbarten zwei Schichten verbunden. Die Verbindungen stellen Einbahnstraßen zwischen der Ausgabe und Eingabe zweier Neuronen dar und habe jeweils ihre eigene Gewichtung. Im Netz gibt es keine Rückkopplungen des Informationsflusses, die Informationen werden stets in Richtung Ausgabe weitergereicht [GBC16].

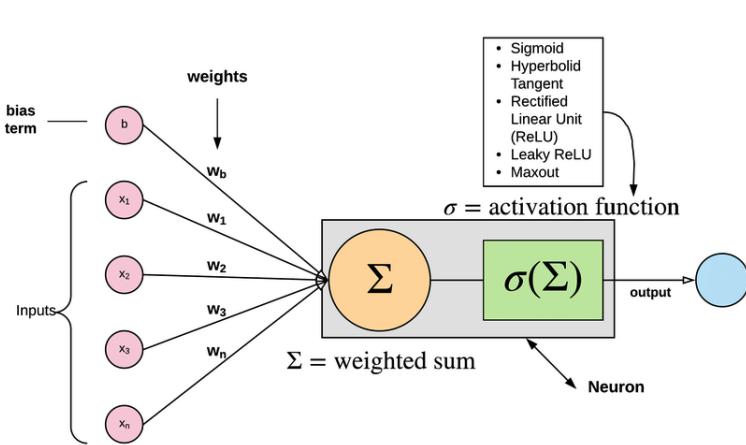
### 4.3.2 Training

Die erfolgreiche Lösung der Aufgabe liegt in der richtigen Auswahl der Gewichte der Verbindungen und des Bias der Neurone. In realen Anwendung bestehen die Modelle aus Hunderttausenden bis Millionen von Parametern und deren Zahlenwerte sind im Allgemeinen reell. Daraus resultiert eine enorme Menge an möglichen Konfigurationen von Parametern, wovon nur ein Bruchteil die Aufgabe des Modells zufriedenstellend lösen kann.

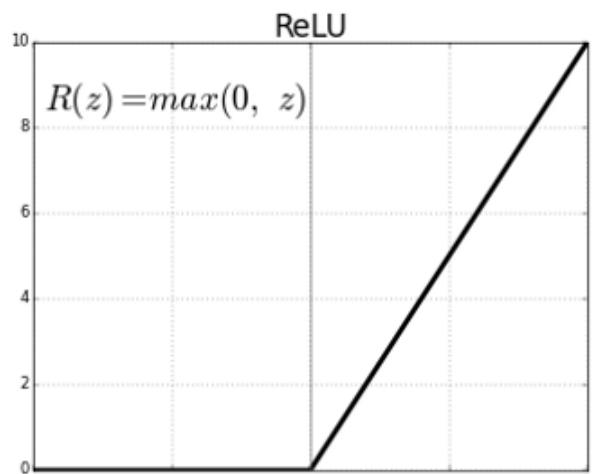
Zur Beurteilung der Qualität einer Konfiguration wird eine Kostenfunktion definiert, die einen Zahlenwert aus dem Abstand der Modellausgabe mit der Wahrheit berechnet, wobei beide Werte mit dem gleichen Input in Beziehung stehen. Die Kostenfunktion entspricht nicht zwangsläufig der Problemstellung, da die Leistungsbewertung des Problems oft auf dem Testdatensatz basiert oder nicht praktikabel berechnet werden kann [GBC16]. Die Ausgabe der Kostenfunktion stellt im Allgemeinen keine reale Größe dar und dient nur zum Vergleich der Konfigurationen untereinander. Der Abstand zwischen Modellausgabe und Wahrheit kann beliebig definiert werden und wird meist



**Abbildung 4.6.** beispielhaftes neuronales Netz [Glo13]



(a) schematische Darstellung eines Perzeptrons [Chi23]



(b) Rectified Linear Unit [Sha23]

**Abbildung 4.7.** Beispiele für ein künstliches Neuron und eine Aktivierungsfunktion

individuell zur Lösung der Aufgaben formuliert. Im theoretischen Modell ist die Kostenfunktion nur von den Gewichten im neuronalen Netz abhängig und spannt eine Landschaft in den Raum der Konfigurationen an Modellgewichten. Eine schematische Darstellung dieser Loss-Landschaft über zwei Gewichte finden Sie in der Abbildung 4.8.

Die Parameter werden bei Initialisierung des neuronalen Netzes entweder auf zufällige oder ausgesuchte Werte gesetzt. Mit dieser Anfangsgewichtung wird die Eingabe des Trainingsdatensatzes in der Forwardpropagation ausgewertet. Die Forwardpropagation beschreibt die Übertragung von Informationen von der Eingabe durch das Netz zur Ausgabe und die anschließende Auswertung der Ausgabe. Die Ausgabe wird mit der Wahrheit in die Kostenfunktion eingegeben und die resultierenden Kosten werden zur weiteren Auswertung genutzt [GBC16].

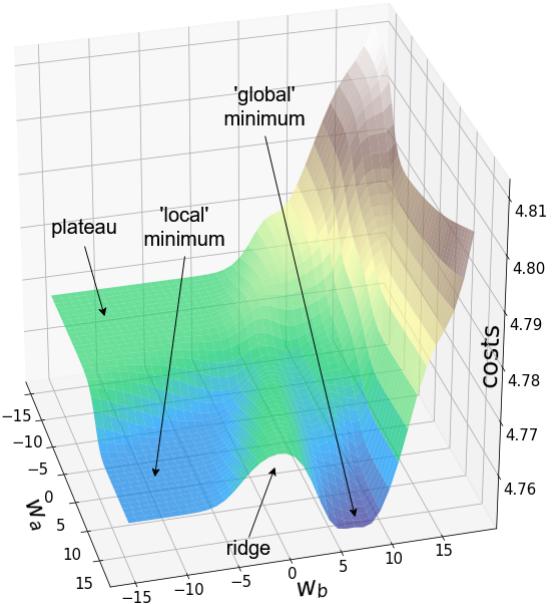
Vom Kostenwert ausgehend wird in entgegengesetzter Richtung die Backpropagation ausgeführt. Hierbei wird der Informationsfluss zur Eingabe zurückverfolgt und der Gradient der Kostenfunktion bezüglich der Gewichte berechnet. Da ein neuronales Netz nur eine Verkettung von differenzierbaren Funktionen ist, kann der Gradient an jeder Stelle des Netzes aus der Kettenregel und den partiellen Ableitungen berechnet werden [GBC16].

Der berechnete Gradient der Kostenfunktion wird anschließend mit Gradientenabstiegsverfahren zur Optimierung der Gewichte an den verschiedenen Stellen des Netzes genutzt. Die Änderung der Gewichte hat das umgekehrte Vorzeichen des Gradienten, um eine Minimierung des Kostenwerts zu bewirken. Der Betrag der Änderung hängt vom Gradienten und der Lernrate  $\epsilon$  ab. Die Lernrate wird der einfachsten Form konstant gehalten, kann jedoch adaptiv gestaltet werden. Die hohe Flexibilität dieses Algorithmus erhöht die Wahrscheinlichkeit einer erfolgreichen Suche nach einem akzeptablen Minimum der Kostenfunktion [GBC16].

Ein Durchgang der Forward-, Backpropagation und des Gradientenabstiegverfahrens über den gesamten Trainingsdatensatz wird Epoche genannt. In der Regel werden Trainings über mehrere Epochen durchgeführt bis das Netz zufriedenstellende Ausgaben berechnet. Eine Epoche kann aus hunderttausenden Beispielen bestehen, wodurch ein Durchlauf sehr viel Rechenzeit in Anspruch nimmt und ein Training damit unpraktikabel wird. Daher werden Trainingsdatensätze in Mini-Batches aufgeteilt, worauf dann die Gewichtsanpassungen basieren. Auf diese Weise werden je Epoche mehrmals die Forward-, Backpropagation und der Gradientenabstiegverfahren durchgeführt. Die stochastische Abschätzung der Werte im Optimierungsalgorithmus auf kleineren Stichproben bringt Ungenauigkeiten ein im Gegensatz zur Berechnung auf dem gesamten Datensatz. Jedoch führt die mehrmalige Optimierung mit ungenauereren Werten effizienter zu den Minima der Kostenfunktion. In der Praxis muss bei der Wahl der Stichprobengröße zwischen Rechenzeit und Genauigkeit abgewogen werden [GBC16].

### 4.3.3 Test

Nach dem Training des Modells, welches in der Regel für eine feste Anzahl an Epochen durchgeführt wird, wird eine Inferenz an einem Testdatensatz durchgeführt. Der Testdatensatz besteht ebenfalls aus gepaarten Input- und Outputdaten, wobei die Daten nicht im Trainingsdatensatz enthalten sind. Idealerweise stammen die Daten in beiden Datensätzen aus einer ähnlichen Verteilung. Der Loss der Inferenz des Testdatensatzes fällt höher aus, da in der Regel die Gewichte auf die Beispiele im Trainingsdatensatz optimiert sind. Falls der Test einen viel schlechteren Loss ergibt, nimmt man an, dass das Modell überangepasst ist. Die Ursache kann in zu vielen Epochen, einer zu hohen Modellkapazität oder in einer zu geringen Variabilität der Trainingsdaten liegen. Die Überanpassung von Modellen stellt ein großes Problem in der Erprobung von neuronalen Netzen dar und kann bei zu ähnlichen Test- und Trainingsdatensätzen schnell übersehen werden.[GBC16; RN16]



**Abbildung 4.8.** schematische Losslandschaft  
[Roe23]

## 4 Statistische Methoden

---

Da der Losswert allgemein keinen Bezug zu realen Größen hat, ist es schwer daran die Qualität des Modells abzuschätzen und es mit Modellen anderer Methoden zu vergleichen. Aus diesem Grund wird gerne eine weitere Aufgabe zur Testung definiert, die auf den Outputs der Modelle basiert und einen Bezug zu realen Problemstellungen aufweist. Auf diese Weise ist eine quantitative Einschätzung der Modellqualität möglich.

### 4.3.4 Deep Learning

Neuronale Netze mit einer großen Zahl an Schichten werden unter Deep Learning zusammengefasst. Die hohe Zahl an Schichten garantiert eine hohe Zahl an Transformationen, womit eine hohe Abstraktheit in der Datenrepräsentation erreicht werden kann. Als Resultat ist es Deep-Learning-Algorithmen möglich sehr komplexe Zusammenhänge zu erfassen.[LBH15]

Daten mit hoher Korrelation zwischen den Datenpunkten wie Bilder und Zeitreihen erfordern eine hohe Kapazität der Modelle. Die hohe Kapazität resultiert aus der hohen Zahl an Neuronen der Inputschicht zur Aufnahme der großen Datenbeispiele und der hohen Zahl an Schichten zur Erfassung langreichweiter und komplexer Korrelationen in den Daten.

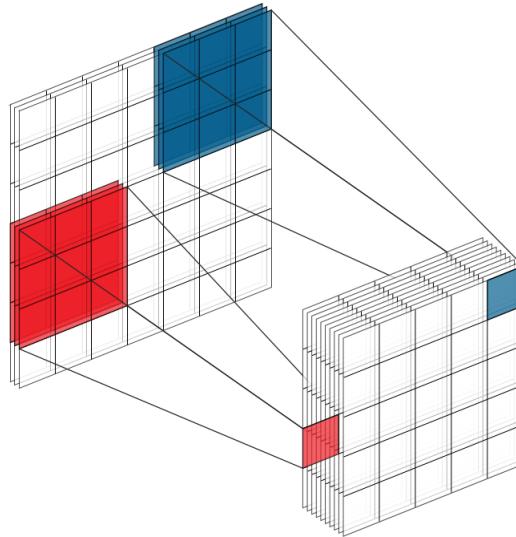
Beim Training mit Bildern und Zeitreihen beschreiben viele Gewichte im voll vernetzten Modell die gleichen Zusammenhänge und sind damit redundant. Trotz der Redundanz und damit ähnlichen numerischen Werten werden alle diese Gewichte separat in der Backpropagation variiert. Daraus resultieren hohe Rechenzeiten und Instabilitäten ohne eine entsprechende Steigerung der Modellqualität. Die Instabilität begrenzt die Größe der Beispiele und Batches im Training der Modelle. Relevante Problemstellungen jedoch weisen große Einzelbeispiele und Datensätze auf, wodurch sich voll vernetzte Modelle als sehr unpraktisch erweisen.

### 4.3.5 Faltungsschichten

Zur Verringerung der Anzahl an variablen Gewichten werden die redundanten Gewichte parallel geschaltet. Dazu wird die Architektur der versteckten Schichten unter Annahme von Symmetrien in den Daten für Faltungen bzw. Rekurrenzen ausgelegt.

In Bilddaten gibt es viele Eigenschaften, die unabhängig von ihrer Position im Bild sind. Daher kann man in der Netzarchitektur translationsinvariante Faltungen nutzen, um ohne großen Informationsverlust die Anzahl an variablen Gewichten zu verkleinern. In der Theorie werden dazu Faltungskerne begrenzter Größe eingesetzt, die schrittweise über das gesamte Bild geschoben werden und an jeder Position einen Output erzeugen. In der Praxis wird für eine Faltungsschicht eine Wahrnehmungsreichweite definiert und alle Gewichte eines Neurons außerhalb der Reichweite werden auf Null gesetzt. Dadurch werden nur Outputs der räumlich benachbarten Neurone der vorherigen Schicht aufgenommen. Die Gewichte für diese Verbindungen sind über die Faltungsschicht hinweg gleichgeschaltet und werden daher nicht separat variiert. Die Faltungsschichten verringern die Anzahl variabler Gewichte pro Schicht stark, ermöglichen tiefere Netzarchitekturen und sind in Abbildung 4.9 exemplarisch dargestellt.

Zur Analyse von Zeitreihen mit neuronalen Netzen kann man zeitinvariante Faltungen nutzen, welche ähnlich wirken wie CNNs und die Zahl an variablen Gewichten stark reduzieren. Jedoch setzen diese Faltungen eine Fensterung der Sequenz voraus, wodurch die zeitliche Reichweite



**Abbildung 4.9.** beispielhafte zweidimensionale Faltungsschicht [Knu]

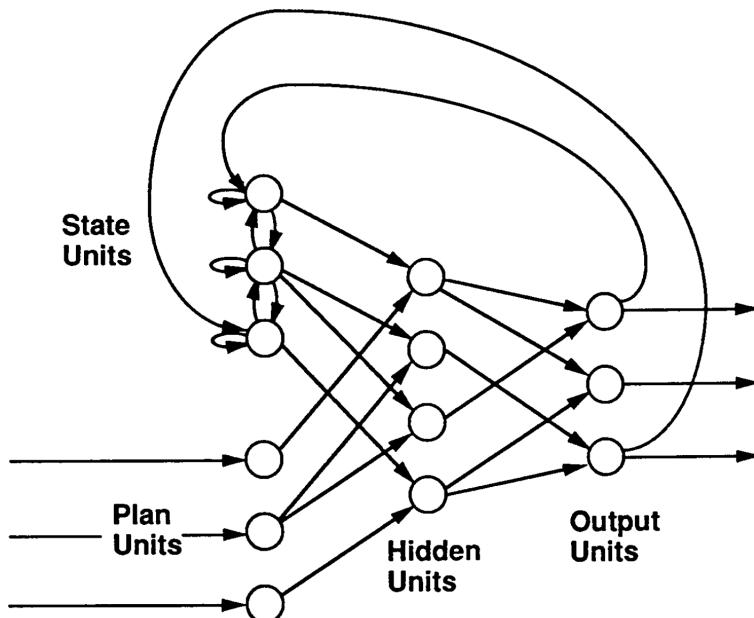
der erfassten Korrelationen im Vorhinein begrenzt wird. Des weiteren filtern die zeitinvarianten Faltungen die nicht-stationären Prozesse der Zeitreihe aus und beschränken die Analyse zusätzlich. Diese Einschränkungen müssen nicht von Nachteil sein, besonders wenn man sich mit Stochastik befasst, die stationäre Eigenschaften voraussetzt.

#### 4.3.6 rekurrente neuronale Netze

Eine Alternative zu den Faltungsschichten sind die rekurrenten neuronalen Netze, die große Fortschritte in der maschinellen linguistischen Datenverarbeitung ermöglicht haben. In der ursprünglichsten Form dieser Methode werden Zeitreihen, wie in Abbildung 4.10 dargestellt, schrittweise in das neuronale Netz gespeist und die Ausgabe des Netzes für ein Zeitschritt wird zur Eingabe des Netzes im nächsten Zeitschritt geleitet. Auf diese Weise sind alle variablen Gewichte identisch für alle Zeitschritte, also zeitinvariant und parallel geschaltet. Hierdurch ist auch die Anzahl an variablen Gewichten unabhängig von der Länge der Zeitreihe und das gleiche Netz kann in der Theorie Zeitreihen mit unterschiedlicher Länge verarbeiten.

Spätere Formen der rekurrenten neuronalen Netze haben Schleifen an beliebigen Stellen des Netzes ermöglicht. Die Schleifen in den folgenden Versuchen starten und enden in der gleichen Schicht, womit eine rekurrente neuronale Schicht die ganze Zeitreihe durchläuft bevor es die Ausgabe an die nächste Schicht weitergibt.

In der einfachsten Form von rekurrenten neuronalen Netzen wird die Ausgabe des vorherigen Zeitschrittes mit der aktuellen Eingabe verkettet und in die Aktivierungsfunktion gespeist. Diese Verkettung zeitlich naher Werte überschreibt Wirkungen aus weit zurückliegenden Zeitschritten und verschlechtert damit das Langzeitgedächtnis des Netzes. Des Weiteren wird mit der unregulierten wiederholten Verkettung ein großes Problem der rekurrenten neuronalen Netze erzeugt, namentlich die explodierenden und verschwindenden Gradienten in der Backpropagation. Eine Lösung für das schlechte Langzeitgedächtnis ist die Einführung des versteckten Zustandes, der moduliert



**Abbildung 4.10.** Die Ur-RNN-Schicht [Jor97]

von Zeitschritt zu Zeitschritt geleitet wird. Hierbei werden die vergangenen Ausgaben und die aktuelle Eingabe weiterhin verkettet, aber durch unterschiedliche Pforten gefiltert, welche den Informationsfluss regulieren. Diese Filter sind kleine voll vernetzte Schichten mit unterschiedlichen Aktivierungsfunktionen je nach dem Zweck. Die Pforten entscheiden basierend auf der Verkettung, welche Werte im Zustand gelöscht, verändert oder konstant gehalten werden. Anschließend wird basierend auf dem Zustand und der Verkettung eine Ausgabe erzeugt. Auf diese Weise wird in jedem Zeitschritt eine Ausgabe erzeugt ohne den Zustand stark verändern zu müssen und trotzdem Wirkungen aus der fernen und nahen Vergangenheit zu erfassen.[GBC16]

#### 4.3.7 Long-Short-Term-Memory

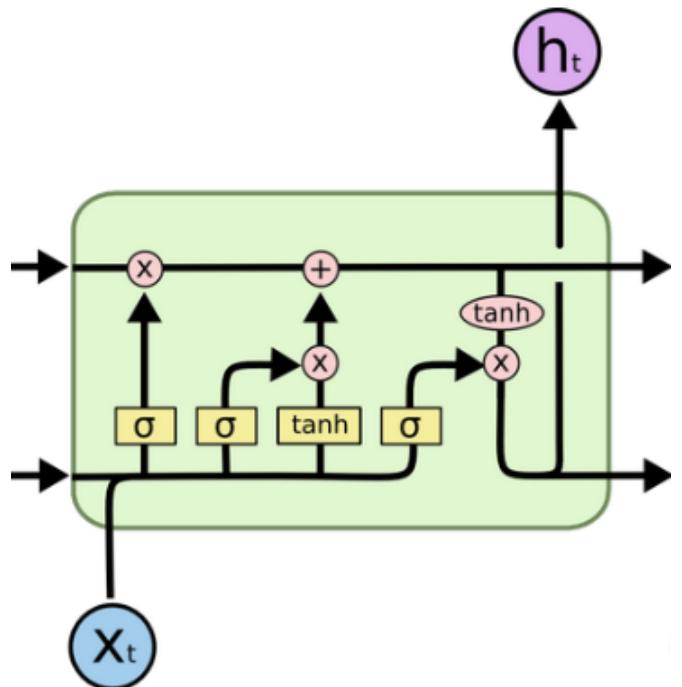
Die rekurrenten neuronalen Netze in den folgenden Experimenten bestehen aus LSTM-Einheiten, Long short-term-memory, welche drei Eingaben bestehend aus der Eingabe des aktuellen Zeitschritts, dem versteckten Zustand und der Ausgabe des vergangenen Zeitschritts aufnimmt. Die Ausgabe und die Eingabe werden verkettet und parallel in drei Pforten geführt. Die Pforten bestehen aus voll vernetzten Neuronen mit Sigmoid- oder tanh-Aktivierungsfunktionen.

Die Vergessenspforte summiert die Verkettung gewichtet und speist die Summe in eine Sigmoidfunktion ein. Die Sigmoidfunktion gibt elementweise reelle Werte zwischen 0 und 1 aus, wobei 0 für Vergessen und 1 für Erinnern steht. Die Ausgabe aus dieser ersten Sigmoidschicht wird elementweise mit dem Zustand multipliziert und das Produkt stellt den neuen Zustand dar. Die Eingabepforte reguliert den Informationsfluss von der Verkettung zum Zustand. Dazu wird die Verkettung parallel durch eine zweite Sigmoid- und eine tanh-Schicht geführt. Die Sigmoidschicht gibt aus welche Werte aktualisiert werden sollen und die tanh-Schicht gibt das Vorzeichen und den Betrag an um den Wert geändert werden sollen. Die Ausgaben beider Schichten werden elementweise multipliziert und anschließend mit dem Zustand addiert. Mit diesen beiden Pforten

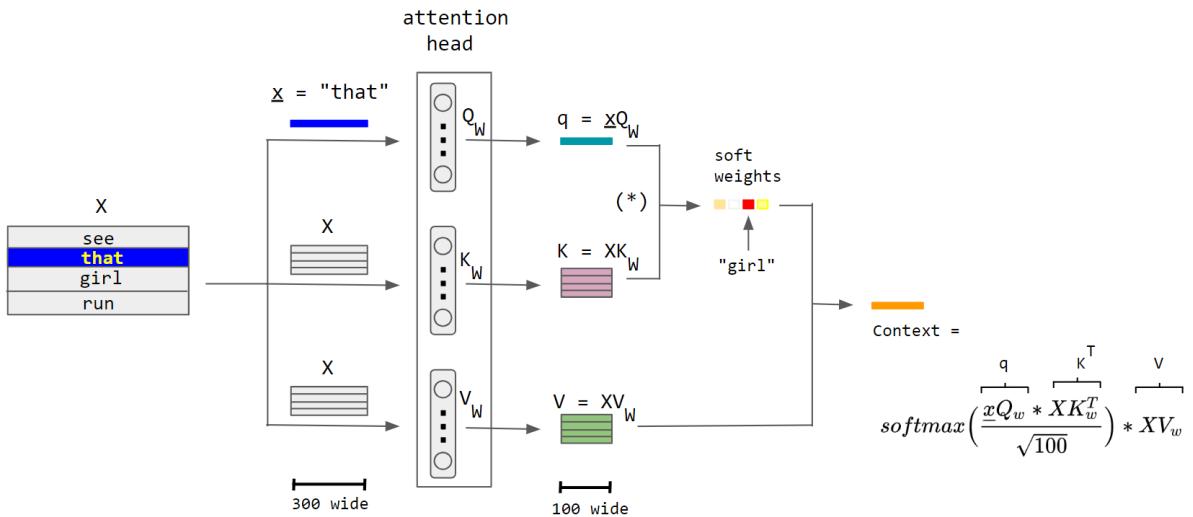
werden die Werte im Zustand aktualisiert ohne der aktuellen Eingabe zu viel Gewicht zu geben und weit zurückliegende Wirkungen zu überschreiben. Die dritte Pforte dient zur Erzeugung der Ausgabe der LSTM-Einheit und heißt dementsprechend AUsgabepforte. Hier wird von einer dritten Sigmoidschicht und der Verkettung bestimmt, welche Werte des Zustandes als Ausgabe definiert werden. Der Zustand wird elementweise in eine tanh-Funktion gespeist, wodurch die Ausgabewerte zwischen -1 und 1 liegen. Die Ausgabe der dritten Sigmoidschicht und der tanh-Funktion werden elementweise miteinander multipliziert. Das Produkt stellt die Ausgabe der LSTM-Einheit dar und wird der nächsten Schicht und/oder dem nächsten Zeitschritt präsentiert.[GBC16]

### 4.3.8 Attention

Die Modelle zur Sprachanalyse wie ChatGPT und LaMDA bestehen hauptsächlich aus Attention-Schichten. Das Prinzip der Attention-Mechanik nach [BCB16] wird am Beispiel der linguistischen Datenverarbeitung erklärt. Die Mechanik nach [BCB16] ist die Antwort auf das Problem fester Sequenzlängen und Fensterungen in Encoder-Decoder-Architekturen. Feste Sequenzlängen werden einem neuronalen Netz vorgegeben und können hinsichtlich der Vorhersage der nächsten Worte in einer Sequenz zu fehlendem Kontext oder zur Berücksichtigung von irrelevanter Information führen. Die Attention-Mechanik ermöglicht eine Modellierung der Gewichte im Netz, welches relevante Informationen aus dem gesamten Beispiel miteinander in Beziehung setzen kann. Bahdanau et al. haben in ihrem Paper eine Attention-Mechanik beschrieben, welches zwischen dem Encoder und Decoder den Informationsfluss moderiert. Dazu werden die Ausgaben des Encoders und Decoders im Training miteinander korreliert und es wird ein Ausrichtungsscore mit Hilfe einer voll vernetzten Schicht vergeben. Der Score gibt wieder wie relevant jeder einzelne Zeitschritt aus dem Encoder für den nächsten Zeitschritt im Output ist. Die Scores werden in einer Matrix festgehalten, welches im Naten transformiert wird. Diese Gewichte werden an der Encoderausgabe für die Decodereingabe zu einer allgemein drei Eingaben in eine Attention-Schicht. Die Queries Q sind analog zu den Decoder-Ausgaben und die Encoder-Ausgaben entsprechen den Keys. Sie werden an unterschiedlichen Stellen in der Mechanik mit Q eingegeben und V wird in der gewichteten Summe der Eingaben ermöglicht eine flexiblere Definition.



**Abbildung 4.11.** Eine LSTM Einheit  
[Jor97]



**Abbildung 4.12.** Schematische Darstellung eines Heads in einer multi-head-self-attention-Schicht [Num23]

In meiner Forschung werden die multi-head-attention- und self-attention-Mechanismen genutzt. Bei der self-attention wird eine Sequenz für die drei Eingaben  $Q$ ,  $K$  und  $V$  verwendet und durch drei getrennte voll vernetzte Schichten geführt. Die Gewichte werden über ein Skalarprodukt von  $Q$  und  $K$  ermittelt und abschließend werden die Attention-Scores in einer Matrixmultiplikation mit  $V$  verrechnet. Die Idee hinter der multi-head-attention-Mechanik ist es mit Hilfe von Masken unterschiedliche Konfigurationen von  $Q$ ,  $K$  und  $V$  zu erstellen und jeweils in ein Head des Attention-Layers einzugeben. In jedem Head werden die Attention-Scores parallel zueinander berechnet und später zusammen geführt. Auf diese Weise können mehrere Beziehungen in einer Sequenz innerhalb einer Attention-Layer erfasst werden.

### 4.3.9 Data Leakage

Unter dem Begriff Data Leakage ist ein fehlerhafter Umgang mit den Datensätzen für das Training und den Test des Modells im Maschinellen Lernen beschrieben, welches zu verfälschten Testergebnissen führt. Die ungültigen Ergebnisse führen zur Überschätzung der Modellqualität für die Anwendung in realen Problemstellungen. Es gibt zwei Formen des Data Leakage.

Zum einen können Merkmale in der Eingabe des Trainingsdatensatzes enthalten sein, die eigentlich zur vorgegeben Ausgabe gehören und in der Inferenz bei Anwendungen unter realen Bedingungen nicht vorhanden sein werden. Ein Beispiel hierfür wäre der Merkmal Monatsgehalt in der Eingabe beim Training, wenn das Modell das Jahresgehalt vorhersagen soll.

Die zweite Form sind falsche Zuordnungen von Beispielen in Training und Test. Beispiele und deren Transformationen dürfen nicht sowohl im Trainingset als auch im Testset vorkommen. Falls Beispiele zu Gruppen zusammengefasst werden können, dürfen die Gruppen nicht sowohl im Trainingset als auch im Testset vertreten sein.

In den folgenden Experimenten wird jeder Patient mit mehreren 5 Minuten Segmenten im Datensatz vertreten. Da das Netz theoretisch die Patienten anhand der Segmente erkennen kann und seine Vorhersage dementsprechend anpassen kann, müssen die Patienten in Trainings- und Testpatienten getrennt werden. Auf diese Weise ist das Testergebnis valide für eine Einschätzung der Modellqualität. Zusätzlich zur Training-Test-Einteilung wird eine dritte Einteilung des Datensatzes eingeführt, denn das trainierte Modell dient zur Analyse der *de novo*- und Kontrollgruppe aus dem Paper [WBK+20]. Die Patienten aus diesen beiden Gruppen dürfen nicht im Training oder im Test vorkommen, um Data Leakage zu vermeiden. Anschließend werden die Segmente den zugehörigen Einteilungen zugeordnet und eine feste Anzahl an Segmenten wird zufällig herausgezogen.

Die strikte Trennung unterbindet einen ungewollten Informationsfluss zwischen den einzelnen Phasen des Experiments und erhält die Aussagekraft der Resultate.

#### 4.3.10 Inductive transfer oder Pseudo-Aufgabe

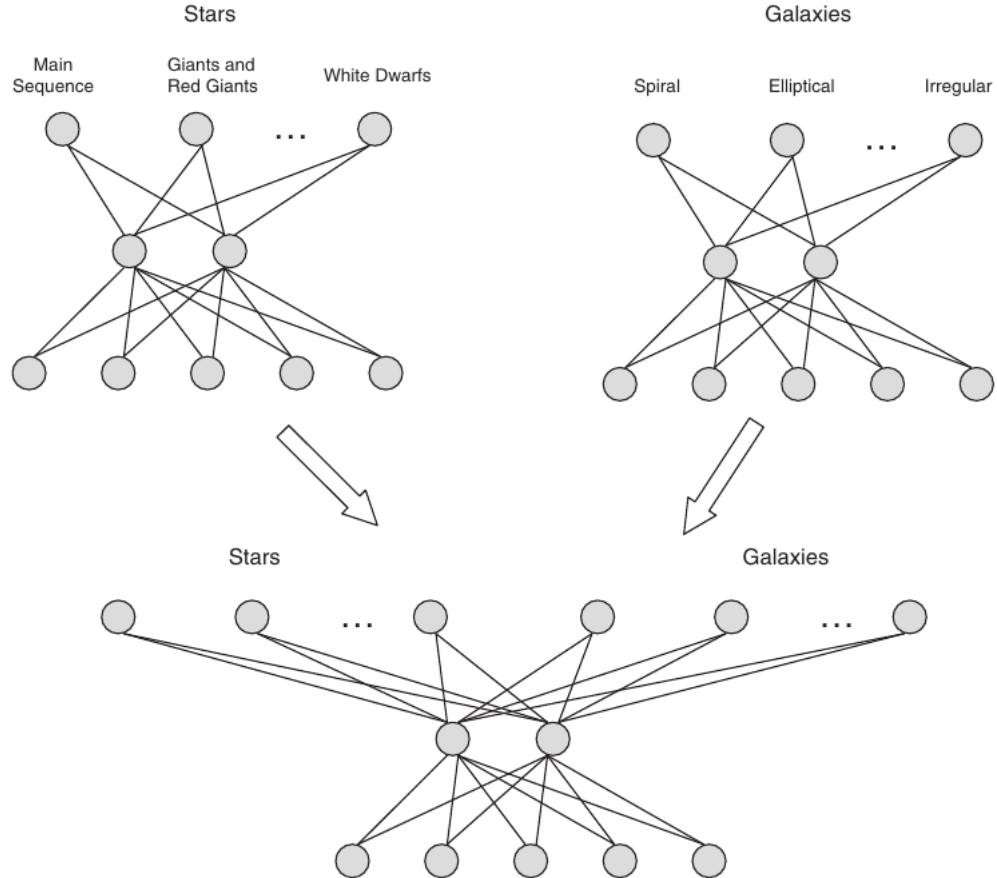
Im maschinellen Lernen ist das Ziel eine Abbildung zwischen der Eingabe und der vorgegebenen Wahrheit anhand von Beispielen zu modellieren. Die Konfiguration der Gewichten in den Modellen kann man als Wissen über eine Problemstellung und dessen Umgebung auffassen. Das Wissen in einem Modell über eine andere Problemstellung kann theoretisch zur Lösung von anderen Aufgaben genutzt werden. Die Praxis Wissen, von einem Modell auf ein anderes zu übertragen, wird Inductive transfer genannt. Die Durchführung wird in aufeinander folgenden oder parallelen Trainings ausgeführt [UCK+11; YCBL14].

In der aufeinanderfolgenden Methode wird ein Quellenmodell vorab auf eine Aufgabe trainiert. Anschließend werden die Gewichte genutzt, um ein Zielmodell auf eine ähnliche Aufgabe zu trainieren. Hierbei kann auch nur ein Teil der Gewichte aus dem Quellenmodell genutzt werden. Diese Form des Vortrainings ist nützlich bei schwierigen Aufgaben, die anfangs einen niedrigen Gradienten aufweisen. Die Kenntnisse aus dem Vortraining erlauben früh eine teilweise Lösung der Aufgabe und das Zielmodell spezialisiert sich zügiger. [YCBL14]

Bei einem parallelen Training teilen sich zwei Modelle, die auf ähnliche Aufgaben trainiert werden, einen Teil ihrer Gewichte miteinander. Das Training der Modelle wird zeitgleich und gleichberechtigt durchgeführt. Durch die gleichgeschalteten Gewichte ist es möglich, dass die Netze Informationen austauschen. Die Idee ist, dass das Training auf ähnliche Probleme die Netze besser generalisiert und eventuell schneller zur Lösung führt [Car97].

In den folgenden Versuchen werden aus der selben Eingabe mehrere Ausgaben generiert und unterschiedlichen Aufgaben zugewiesen. Daher werden nicht mehrere Modelle codiert, die unterschiedliche Aufgaben lösen, sondern ein Modell mit mehreren Ausgaben implementiert. Diese Methode entspricht dem Inductive transfer mit parallelem Training und wird pseudo-task genannt. In der Abbildung 4.13 ist das Prinzip am Beispiel der Galaxieklassifikation in astronomischen Bildaufnahmen dargestellt. Der Vorteil ist, dass insgesamt weniger Gewichte angepasst werden müssen und die Hyperparametersuche übersichtlich bleibt.

Das Modell wird mit dem Ziel eine Hauptaufgabe zu lösen konstruiert und es werden Nebenaufgaben definiert, die der Hauptaufgabe ähneln. Die Ähnlichkeit in den Aufgaben setzt ähnliche Modelle und Informationen zur erfolgreichen Lösung voraus. Das Wissen, das zur Lösung aller Aufgaben benötigt wird, wird in Layern abgespeichert, die die Ausgaben miteinander teilen und den Kern



**Abbildung 4.13.** Schematische Darstellung des Inductive Transfer anhand von Galaxie-Klassifikationen in astronomischen Bildern [UCK+11]

des neuronalen Netzes bilden. Aus diesem Kern gehen für jede Aufgabe eigene Zweige ab, die unabhängig voneinander sind. In diesen Zweigen kann das Wissen, das zur Lösung der einzelnen Aufgabe benötigt wird, abgespeichert werden.

Auf diese Weise konkurrieren die Informationen nicht um Kapazität im Kern und es ist dennoch ein Wissenstransfer möglich. Darüberhinaus tragen die Pseudo-Aufgaben verschiedene Sichtweisen ein und legen den Fokus auf unterschiedliche Punkte. Die Annahme ist, dass das Netz hierdurch besser generalisiert trainiert wird und beim Training mehr Stabilität aufweist.

# 5 Aufbau

## 5.1 Daten

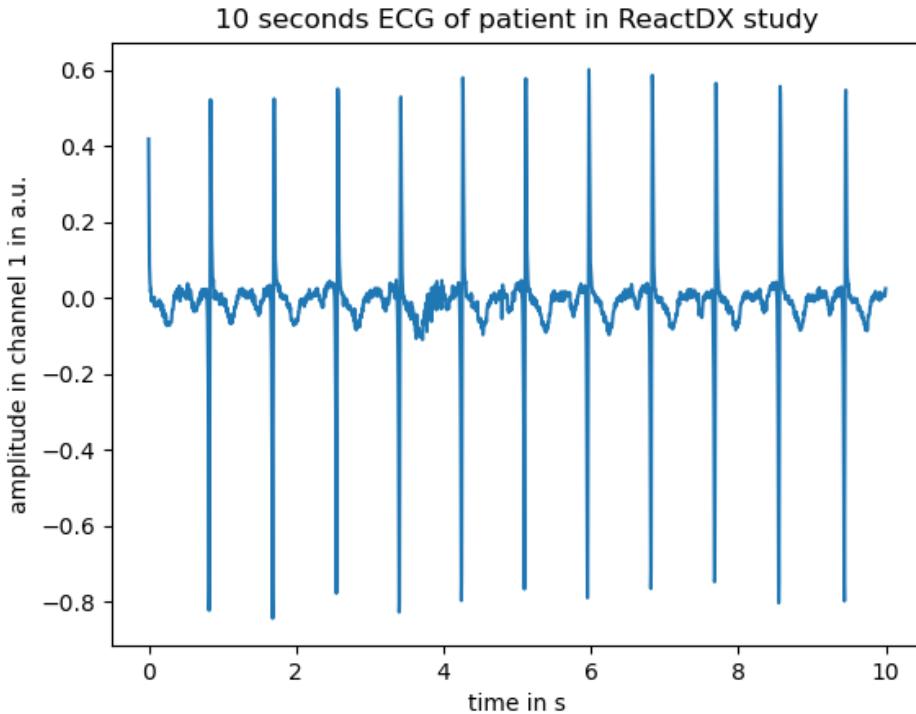
### 5.1.1 ReactDX

Im Rahmen der Studie zur Wirksamkeit des implantierbaren Kardioverter-Defibrillators (ICD) BIOTRONIK Lumax VR-T DX wurde der Datensatz React DX aufgebaut. Nach der Implantation des ICD wurde ein 7-Tage-EKG der Patienten aufgenommen. Anschließend wurden die Patienten, um das Auftreten von lang anhaltenden Vorhofflimmern vom ICD zu registriert, weiterbegleitet.

Im ReactDX Programm haben 234 Patienten teilgenommen, wobei die EKG-Messung maximal einen Monat nach der Operation stattfand. Die Patienten wurden zwischen 12 und 24 Monaten im Follow-up betreut. 199 der Patienten waren männlich und bei 180 wurde das Implantat zur Vorbeugung eines plötzlichen Herztodes eingesetzt. Die Patienten litten unter koronarer Herzerkrankung, dilative Kardiomyopathie und Bluthochdruck. Alle Patienten erhielten Medikamente zur Behandlung ihrer Herzerkrankungen.

Während des Follow-ups entwickelten 14 Patienten ein lang anhaltendes Vorhofflimmern. Von den 14 Patienten liegen alle klinischen Daten und das 7-Tage-EKG bei 10 Patienten vor. Diese 10 Patienten wurden im Paper von Prof. Wessel als *de novo* VHF Gruppe definiert. Die Kontrollgruppe, bestehend aus 10 Patienten, wurde von 166 Patienten gewählt, die das ICD zur Vorbeugung erhielten und kein lang anhaltendes VHF entwickelten [WBK+20]. Die Auswahl der Patienten in der Kontrollgruppe basiert auf dem Propensity Score Matching [IR15]. Die Idee des PSM ist es die Kontrollgruppe aus Patienten zusammenzustellen, die eine ähnliche Risikoeinschätzung für ein VHF aufweisen wie die Patienten aus der *de novo* VHF Gruppe. Die Einschätzung basiert dabei auf bereits bekannten Risikofaktoren wie Alter, Geschlecht, BMI, Krankheiten und Behandlungstherapien. Auf diese Weise wird bereits vorhandenes Wissen über die Vorhersage eines VHF für die Bewertung der Methode berücksichtigt, denn basierend auf den Kriterien des PSM haben die Patienten die gleiche Wahrscheinlichkeit für ein VHF. Die Unterschiede in den ermittelten Parametern müssen daher aus bisher unbekannten Zusammenhängen und Informationen resultieren.

Die EKGs der Patienten liegen in 5 Minuten Segmenten vor. In der Abbildung ?? ist ein 10 Sekunden Segment als Beispiel visualisiert. Aus den EKGs wurde vorab von Dipl.-Inf. Krämer die Annotationen der R-Zacken, das Tachogramm und verschiedene Signal-to-Noise-Verhältnisse (SNR) berechnet und zu den Segmenten als zusätzliche Merkmale hinzugefügt. Aus dem Datensatz werden neben den EKGs die Annotationen, die SNR aus 1-Sekunden-Fenstern auf weißem Rauschen, die Patienten-ID und das Tachogramm des Segments für die Experimente genutzt.



**Abbildung 5.1.** 10 Sekunden langes EKG aus dem Datenset ReactDX

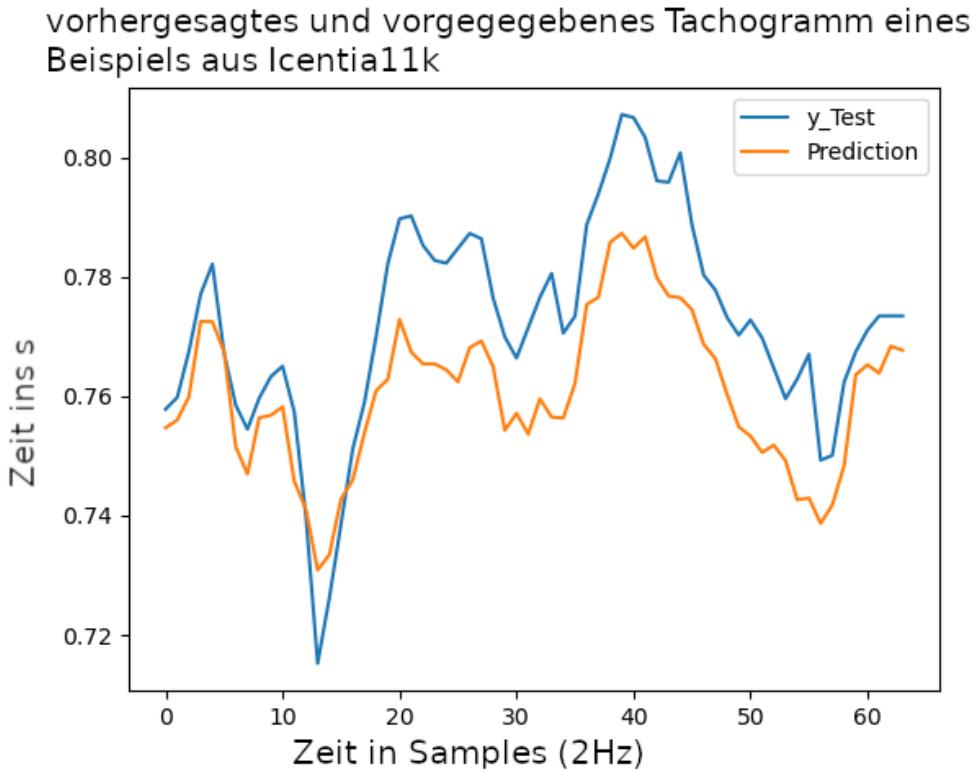
### 5.1.2 Vorverarbeitung

Die neuronalen Netze in den Experimenten werden auf die Lösung der Hauptaufgabe und Pseudoaufgaben trainiert. Die Lösungen der Aufgaben werden als Merkmale in den Trainingsbeispielen abgebildet. Die Merkmale werden zum Großteil nicht in den Datensätzen bereitgestellt und müssen aus den vorab berechnet werden. Die berechneten Merkmale entweder in Form von Zeitreihen mit unterschiedlichen Abtastraten vor, wobei die einzelnen Datenpunkte kontinuierliche oder diskrete Werte haben, oder es sind Skalare, welche kontinuierliche Parameter oder diskrete Klassen darstellen. Um die vielfältigen Formen der Merkmale zu berücksichtigen, werden die Merkmale der Beispiele in Dictionaries gespeichert. Die einzelnen Werte in den Dictionaries sind dann in Arrays oder Lists gespeichert, die der Form des Merkmals am besten dient.

### Tachogramm

Der Datensatz ReactDX enthält das Tachogramm der Segmente, wobei die Zeitreihe mit dem adaptiven Filter von Ausreißern und Artefakten bereinigt wurde.[WMBK07]

Die Qualität der HRV-Analyse wird durch Arrhythmien und Artefakten im Tachogramm verschlechtert, weshalb eine Bereinigung der Zeitreihe vorab sehr wichtig für die Aussagekraft der Analyse ist. Jedoch sind Arrhythmien normalen Schlägen morphologisch sehr ähnlich, weshalb gängige Detektionsmethoden oft fehlschlagen. Darüber hinaus hat das simple Entfernen der Artefakte



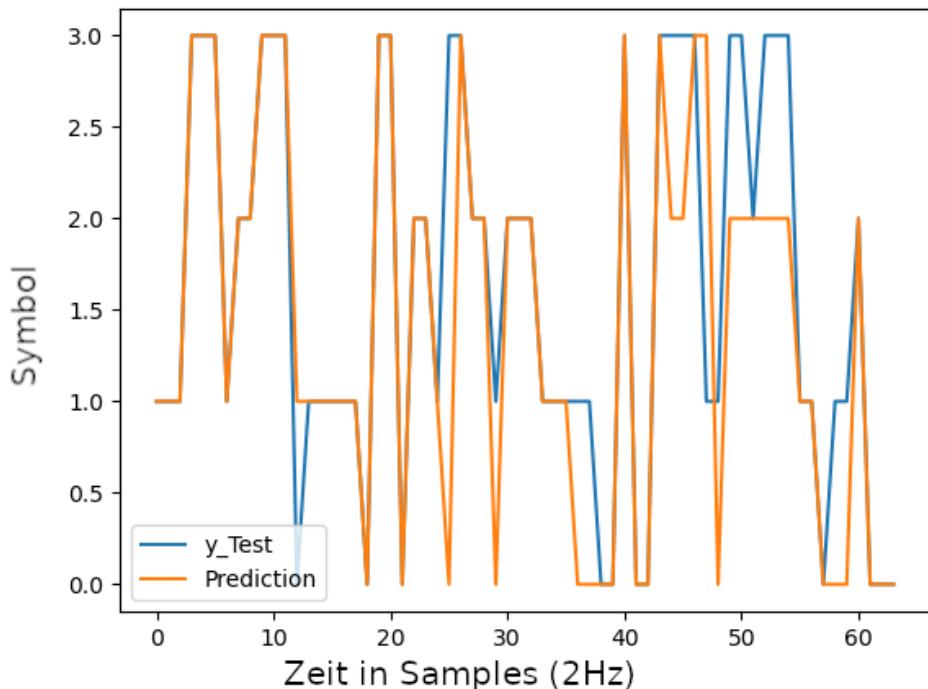
**Abbildung 5.2.** 32 Sekunden lange Zeitreihe der Vorhersage eines Attention-Modells und der Vorgabe des Tachogramms für ein Beispiel aus dem Datenset Icentia11k

einen zu großen Einfluss auf die ermittelten HRV-Parameter, weshalb jedes Typ Artefakt mit dem passenden Tool ersetzt werden muss. Viele dieser Probleme können unter Einsatz des adaptiven Filters gelöst werden [WMBK07]. Der große Vorteil liegt in der schnellen Anpassung des Filters an Veränderungen der Variabilität.

### symbolische Dynamik

Die Herzratenvariabilität wird durch viele komplexe Beziehungen im Herzkreislaufsystem moduliert, die wie im Kapitel 3.4 beschrieben in einem kreisförmigen System vorliegen. Hierdurch weist die Herzratenvariabilität viele Nicht-Linearitäten auf, die entsprechend analysiert werden müssen. Eine Methode die Nicht-Linearitäten zu analysieren ist die Dynamik der HRV zu untersuchen. Hierzu wird die symbolische Dynamik bei der Analyse von Tachogrammen eingesetzt [KVS+95; VKK+96]. In der symbolischen Dynamik wird die zeitliche Differenz zwischen den Herzraten zweier aufeinanderfolgender Herzschläge in vier Klassen kategorisiert. Die Klassen entsprechen steigenden und abfallenden Herzraten und der Stärke der Änderung. Die feinen Details der Dynamik gehen durch die Vergrößerung verloren, jedoch werden im Gegenzug nicht-lineare Analysen der Dynamik möglich. Die Abbildung 5.3 enthält eine vorgegebene Zeitreihe der symbolischen Dynamik und die Vorhersage eines Attention-Modells, welches versucht die Vorgabe aus der Eingabe nachzubilden.

vorhergesagte und vorgegebene symbolische Dynamik eines Beispiels aus Icentia11k



**Abbildung 5.3.** 32 Sekunden lange Zeitreihe der Vorhersage eines Attention-Modells und der Vorgabe der symbolischen Dynamik für ein Beispiel aus dem Datenset Icentia11k

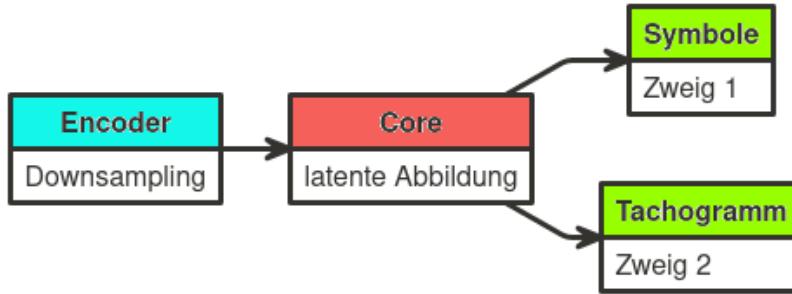
Die Klassen werden mit Buchstaben symbolisiert und in der Analyse zu Wörtern der Länge drei zusammengefügt. Anschließend wird eine Verteilung der Wörter erstellt und diese wird zur Berechnung von unterschiedlichen nicht-linearen Parametern herangezogen.

### Parameter

In der HRV-Analyse werden Parameter zur Diagnose von Krankheiten und zur Unterscheidung von Gruppen herangezogen. Mit linearen Parametern sind in den folgenden Analysen statistische Messgrößen wie arithmetisches Mittel, Varianz oder die Häufigkeit von Herzschlägen mit einer Herzrate niedriger als 10ms gemeint. Die nicht-linearen Parameter werden in den folgenden Analysen aus Transformationen der Dynamik der Zeitreihe definiert.

Die symbolische Dynamik in den folgenden Versuchen basiert auf vier bzw. zwei Symbolen. Anschließend wird die Symbolfolge zu Wörtern zusammengefügt, wobei die Schrittänge eins beträgt. Die Häufigkeiten der Wortkombinationen werden in einer Verteilung dargestellt. Aus dieser Statistik werden anschließend die Shannon-Entropie der normierten Verteilung, die Parameter forbidden words (FW) und Polvar 10 berechnet.

Die Shannon-Entropie und forbidden words werden aus der Verteilung von 64 Wortkombinationen der Länge 3 aus vier Symbolen ermittelt. FW ist die Anzahl an Wortkombinationen, welche einzeln weniger als ein Tausendstel an der Gesamtmenge an Wörtern in der Zeitreihe auftreten. Da es



**Abbildung 5.4.** Schematische Darstellung der verzweigten Netzarchitektur

64 Wortkombinationen gibt, kann der Parameter maximal den Wert 63 annehmen und ist positiv ganzzahlig. Ein hoher Wert dieses Parameters tritt auf, wenn sich Symbolfolgen oft wiederholen. Diese Wiederholungen treten bei niedriger Komplexität der HRV auf. Mit der Quantifizierung der Komplexität ist es möglich Gruppen von Patienten anhand dieses Maßes zu unterscheiden. Die Shannon-Entropie nimmt in den verwendeten Beispielen Werte zwischen 0 und 4 an und der Parameter forbidden words liegt meist zwischen 30 und 60. Da neuronalen Netze der Umgang mit Werte zwischen 0 und 1 einfacher fällt, werden die berechneten Werte der Shannon-Entropie und FW in der Vorverarbeitung durch 4 bzw. 40 dividiert. Die angepassten Werte werden im Training verwendet, wodurch die neuronalen Netze Ausgaben um 1 ausgeben. Die Ausgaben der einzelnen Zweige müssen vor deren Anwendung rücktransformiert werden, sprich mit 4 bzw. 40 multipliziert werden.

Polvar 10 wird aus der Statistik einer binären Symbolfolge mit einer Wortlänge von sieben berechnet. Die Symbole kodieren absolute Herzratenänderungen über einen Grenzwert mit einer „1“ und unterhalb dieses Wertes mit einer „0“. Der Grenzwert ist ein empirisch festgelegter absoluter Wert in Millisekunden, in diesem Fall 10 ms. Der Parameter ist der relative Anteil an Wörtern mit keiner „1“ an einer beliebigen Stelle. Somit ist es ein Maß für die Stetigkeit der Herzrate. Die berechneten Werte für Polvar 10 liegen oft um 0, wodurch die Metrik MAPE irreführende Werte annimmt. Um eine Einschätzung der Qualität zu ermöglichen werden die Werte in der Vorverarbeitung mit 0, 1 addiert.

## 5.2 NN-Architektur

Das neuronale Netz besteht wie in Abbildung 5.4 aus drei Abschnitten dem Encoder, dem Kern und den Zweigen.

Im Encoder wird die EKG-Zeitreihe in einen Parameterraum abgebildet, wie in der Abbildung 5.5a schematisch dargestellt. Der Encoder setzt sich aus sechs aufeinanderfolgenden Blöcken zusammen, die jeweils die Anzahl der Filter und die Länge der Zeitreihe halbieren.. Die Blöcke wiederum bestehen aus eindimensionalen Faltungs- und Pooling-Schichten Die Faltungskerngröße der Faltungsschichten entspricht 2 Sekunden der Zeitreihe, damit mindestens ein Herzschlag im Faltungskern enthalten ist. Die Faltungskerne werden mit einer Dilatation von 2 initiiert, da

## 5 Aufbau

---

benachbarte Datenpunkte in einer Zeitreihe sehr ähnliche Informationen enthalten und damit viele Redundanzen einführen. Durch die Dilatation wird jeder zweite Datenpunkt im Fenster in die Faltung aufgenommen. Die verringerte Redundanz und damit erhöhte Informationsdichte haben ein stabileres und effizienteres Training zur Folge. Die erste Faltungsschicht wird mit 128 Filtern implementiert, um die Vielfalt an unterschiedlichen Herzschlägen abzudecken. Die Pooling-Schichten geben Mittelungen über zwei Datenpunkte aus und halbieren so die Länge der Zeitreihe. Der Encoder gibt dann eine Zeitreihe mit einer Abtastrate von 4 Hz und vier Merkmalen aus.

Im Kern sollen die Eigenschaften der EKGs zur Lösung der Aufgaben in den Zweigen abgebildet und verarbeitet werden. Hierzu besteht der Kern aus drei Attention-Schichten und mehreren vollvernetzten Schichten. Die Attention-Schichten basieren auf der Self-Attention- und der Multi-Head-Methode. Die Ausgabe aus dem Encoder wird in eine voll vernetzte Schicht mit 32 Einheiten geleitet. Die drei folgenden Attention-Schichten sind seriell geschaltet und haben jeweils zehn Köpfe. Eine schematische Darstellung des Kerns ist in Abbildung 5.5b zu finden.

Die einzelnen Zweige dienen zur Realisierung der Pseudo-Aufgaben-Methode, dazu werden die Gewichte in deren Schichten spezialisiert werden, um die jeweiligen Aufgaben zu lösen. Die spezialisierte Verarbeitung der eingehenden Informationen wird von einer Attention-Schicht durchgeführt. Die Attention-Schicht des Zweigs für die Lösung der Hauptaufgabe enthält 10 Köpfe und die der Pseudo-Aufgaben enthalten jeweils 3 Köpfe.

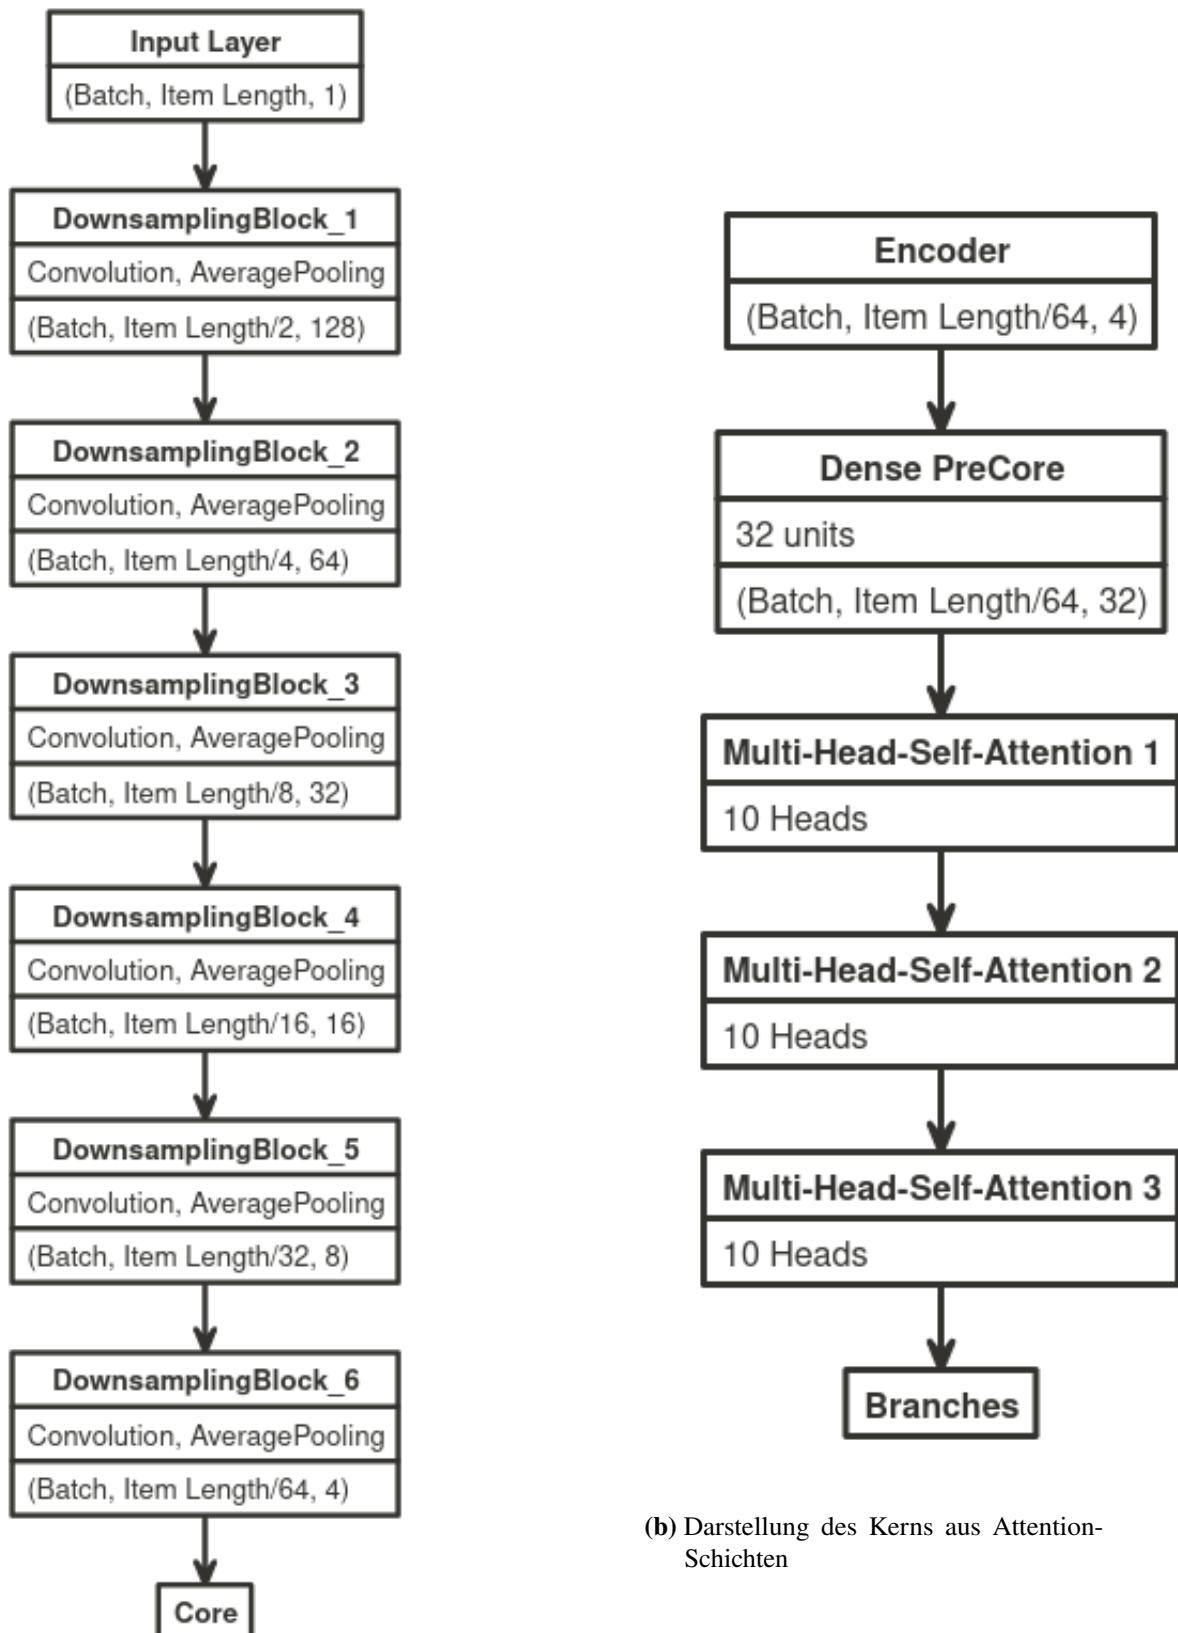
Die einzelnen Zweige berechnen Zeitreihen aus kontinuierlichen Werten und diskreten Klassen mit Abtastraten von 4Hz und kontinuierliche Parameter der HRV-Analyse. Der Fokus liegt auf der Aufgabe die Parameter der HRV-Analyse aus den rohen EKGs zu berechnen. Insbesondere der Parameter forbidden words ist von Interesse, da es die *de novo*-Gruppe am effektivsten von der Kontrollgruppe unterschieden hat. Da die Parameter aus der Verteilung der Wörter berechnet wird und diese wiederum auf der symbolischen Dynamik und dem Tachogramm basieren, sind zwei Zweige auf die Berechnung beider Zeitreihen spezialisiert. Hierbei wird eine Abtastrate von 4Hz genutzt, um Herzraten bis 240 Schlägen pro Minute hochauflösend abzudecken.

Bei der Eingabe der Beispiele im Training und Test in das Netz ist die Cachegröße auf der Grafikkarte ein limitierender Faktor. Der Speicherplatz im Cache wird von den Eingabe- und Ausgabedaten, sowie den Gewichten des neuronalen Netzes belegt. Die Komprimierung der Trainingsdaten bringt Ungenauigkeiten ein und verschlechtert die Qualität der resultierenden Modelle. Die Begrenzung der Modellkapazität wirkt sich ebenfalls negativ auf die Modellqualität aus. Aus diesem Grund wird die Batchgröße auf 10 Beispiele begrenzt. Eine derart niedrige Batchgröße verlängert die Rechenzeit und schließt die Nutzung einiger Methoden der Regularisierung aus. Perspektivisch werden GPUs mit größeren Caches Trainings mit größeren Batches ermöglichen.

### 5.3 Kostenfunktion

Die Kostenfunktion der kontinuierlichen Merkmale in den folgenden Experimenten ist der mittlere quadratische Abstand zwischen der Ausgabe und der Wahrheit. Die kontinuierlichen Merkmale sind das Tachogramm und die Parameter.

Die diskrete Zeitreihe der symbolischen Dynamik wird mit der Kostenfunktion SparseCategorical-Crossentropy dem Netz antrainiert. Die einzelnen Datenpunkte der Zeitreihe sind Klassifikationen und werden einzeln ausgewertet. Das Sparse bezieht sich auf die Form der Labels, welche als



(a) Darstellung des Encoder aus Faltungs-schichten und gefensterten Mittelungen

33

**Abbildung 5.5.** Schematische des Encoders und des Kerns

## 5 Aufbau

---

Integer angegeben werden. Das Netz gibt für jeden Zeitschritt eine Wahrscheinlichkeitsverteilung der einzelnen Klassifikationen aus. In diesem Fall haben die Zeitreihen der symbolischen Dynamik eine Tiefe von vier. Die Ausgabe und die Wahrheit der einzelnen Zeitschritte werden als Ganzes in die Kostenfunktion eingegeben und der Loss wird weitergereicht.

Die Loss zu den einzelnen Zweigen werden zu einem gesamten Loss aufsummiert.

### 5.4 Training

Die Patienten des ReactDX werden dem Training oder Test zugeordnet. Die strikte Trennung verhindert ein Data Leakage in das Testset. Die Beispiele werden anschließend aus den EKGs der Patienten gezogen und in den Dictionaries mit den anderen Merkmalen abgespeichert, die das Trainings- und Testset repräsentieren. Das Verhältnis der Patientenzahl zwischen Training und Test liegt bei 4:1.

Die EKGs sind fünf Minuten lang und bestehen aus 76.800 Datenpunkten. Die Beispiele enthalten als Merkmale der Ausgabe die Hauptaufgabe und die Pseudo-Aufgaben des neuronalen Netzes.

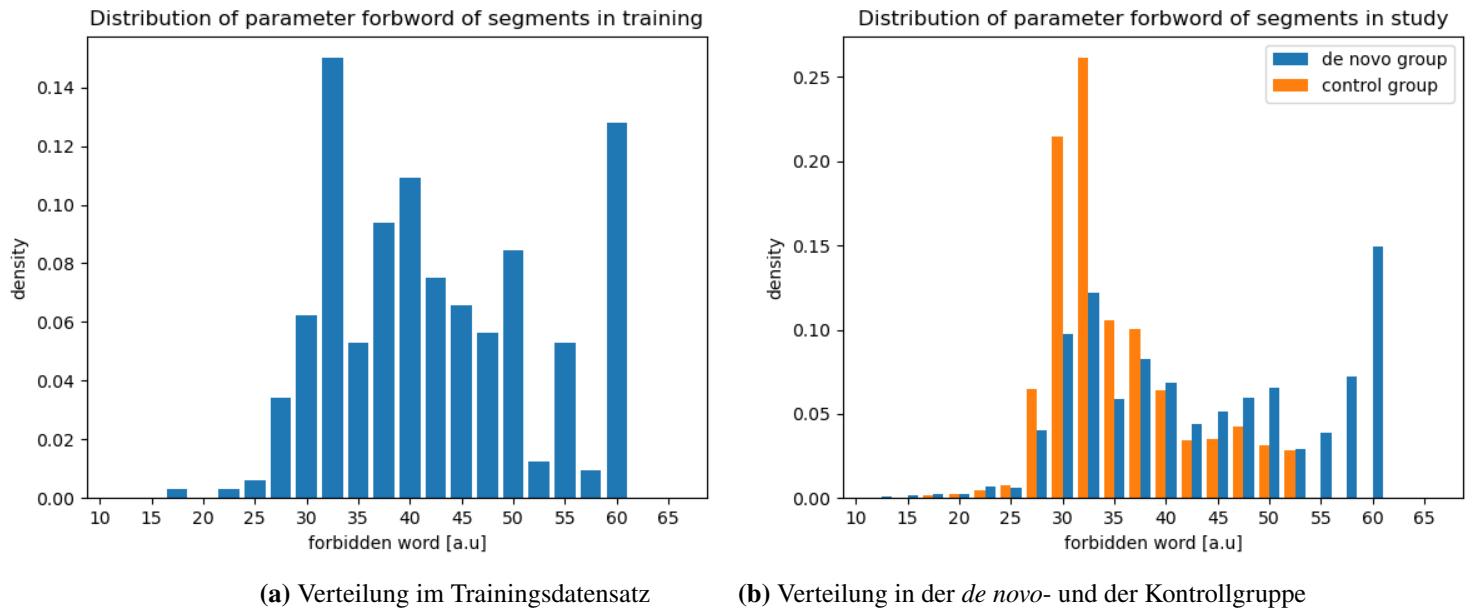
Im Training wird der Optimizer Adam [KB17] genutzt, der eine weiterentwickelte Form des stochastischen Gradientenabstiegs (SGD) darstellt. Im Gegensatz zum SGD passt Adam die Lernrate bei der Anpassung der einzelnen Gewichte der Steigung der Kostenfunktion für dieses spezifische Gewicht an. Diese Flexibilität erlaubt es dem NN einflussstarke Gewichte fein einzustellen und bei einflussschwachen Gewichten Rechenkapazität einzusparen. Die Automatisierung befreit uns von der händischen Auswahl der Lernrate, die sehr mühselig ausfallen kann.

Zusätzlich zum Loss wird der mittlere absolute Abstand des Tachogramms, die Klassifikationsgenauigkeit der symbolischen Dynamik und der mittlere absolute prozentuale Fehler (MAPE) der HRV-Parameter als Metriken berechnet. Diese Metriken kann man als Maß für die Qualität der Vorhersagen des Netzes interpretieren. Sie wird bei Trainings genutzt, um einen verfrühten Stop auszulösen. Eine beispielhafte Konfiguration des verfrühten Stops ist: Wenn sich die Vorhersage des HRV-Parameters sich innerhalb der letzten 50 Epochen nicht mehr als 0,1 Prozentpunkt verbessert hat, stoppe das Training. Falls diese Bedingung nicht eintritt, wird das Training nach 200 Epochen beendet.

Das neuronale Netz wird bei der Anwendung auf die *de novo*- und Kontrollgruppe die EKGs von Patienten mit unterschiedlichen FW-Parametern analysieren. Dies kann er nur verlässlich vollziehen, wenn es genügend Beispiele mit unterschiedlichen FW-Parametern im Training gesehen hat. Die Verteilung des FW-Parameters im Trainingsdatensatz ist in der Abbildung 5.6a dargestellt.

### 5.5 Mann-Whitney-U-Test

Das Ziel dieser Masterarbeit ist die Replikation der Ergebnisse des Papers „Cardiac Autonomic Dysfunction and Incidence of de novo Atrial Fibrillation“ mit Methoden des maschinellen Lernens und eine Automation der Datenauswertung. Im Paper hat sich der Parameter forbidden words als effektiv zur Unterscheidung zwischen der *de novo*-Gruppe und der Kontrollgruppe herausgestellt. Daher wird der Erfolg des Experiments nicht an den Metriken des Trainings und Tests gemessen,



**Abbildung 5.6.** Verteilung des Parameters FW in den Gruppen

sondern ob der Mann-Whitney-U-Test an den 20 Patienten ein valides Ergebnis liefert. Die beiden Verteilungen, die mit dem Mann-Whitney-U-Test untersucht werden, sind im Histogramm 5.6b visualisiert.

Der Mann-Whitney-U-Test wird als nichtparametrischer statistischer Test für Rangdaten bezeichnet. Die zu verwerfende Hypothese bezieht sich auf zwei Populationen aus denen jeweils ein Wert gezogen wird. Die Hypothese besagt, dass die Wahrscheinlichkeit, dass der erste Wert größer ist als der zweite Wert, gleich groß ist wie die Wahrscheinlichkeit, dass der erste Wert kleiner ist als der zweite Wert. Sprich die Werte einer Population nicht dazu tendieren größer oder kleiner zu sein als die der anderen Population. Im Falle der Verwerfung der Hypothese, ist die vorliegende Population tendenziell kleiner bzw. größer ist als die der anderen Population.

Für den Einsatz des Tests werden zunächst die Parameterwerte der 20 Patienten in einer Rangordnung aufgereiht. Die Nullhypothese besagt für das folgende Experiment, dass die Parameterverteilung der beiden Populationen gleich ist. Die mathematische Form der Hypothese ist in der Gleichung 5.1 zu finden.

$$(5.1) \quad H_0 : P(X > Y) = P(X < Y)$$

$$(5.2) \quad H_1 : P(X > Y) \neq P(X < Y)$$

Hierzu werden zuerst die Prüfgrößen der beiden Populationen berechnet. Die Formel dazu ist in der Gleichung 5.3 notiert.

$$(5.3) \quad U_{1/2} = n_{1/2} * n_{2/1} + \frac{n_{1/2} * (n_{1/2} + 1)}{2} - R_{1/2}$$

## 5 Aufbau

---

Parameter	AF day 1	CON day 1	Day 1	Day 2	Day 3	Day 4	Day 5	Day 6	Day 7
meanNN	801.3 ± 113.1	891.2 ± 80	0.060	0.063	0.143	0.346	0.312	0.242	0.189
sdNN	33.6 ± 20.3	46.7 ± 14.2	0.119	0.217	0.162	0.288	0.303	0.663	0.177
Rmssd	18.2 ± 12.2	24.3 ± 9.8	0.246	0.530	0.366	0.735	0.670	0.824	0.471
pNN50	0.04 ± 0.05	0.07 ± 0.06	0.326	0.773	0.479	0.994	0.949	0.829	0.713
Shannon	1.58 ± 0.6	1.96 ± 0.34	0.101	0.123	0.089	0.214	0.202	0.295	0.212
Renyi025	1.88 ± 0.58	2.26 ± 0.32	0.087	0.117	0.083	0.224	0.218	0.300	0.178
Renyi4	1.28 ± 0.56	1.62 ± 0.33	0.119	0.140	0.107	0.212	0.210	0.290	0.245
Renyi2	1.41 ± 0.59	1.77 ± 0.34	0.112	0.132	0.098	0.211	0.204	0.294	0.232
pNNI10	0.65 ± 0.25	0.49 ± 0.16	0.118	0.130	0.184	0.346	0.239	0.440	0.296
pNNI20	0.79 ± 0.18	0.69 ± 0.15	0.232	0.295	0.368	0.665	0.426	0.674	0.401
pNNI30	0.9 ± 0.11	0.84 ± 0.11	0.274	0.521	0.488	0.880	0.676	0.918	0.553
P	731.6 ± 706.2	1236.4 ± 694.3	0.135	0.310	0.316	0.340	0.400	0.918	0.212
ULF	75.5 ± 59.3	165.8 ± 82.5	<b>0.015</b>	0.177	0.127	0.076	0.187	0.591	0.104
VLF	415 ± 432	801.7 ± 498.6	0.090	0.235	0.281	0.255	0.343	0.623	0.233
LF	190 ± 210	202.8 ± 133.6	0.875	0.721	0.690	0.980	0.791	0.515	0.448
HF	51 ± 59	66.1 ± 36.9	0.508	0.858	0.551	0.906	0.993	0.467	0.302
LF/HF	4.9 ± 2.7	4.5 ± 2.3	0.756	0.508	0.456	0.593	0.943	0.995	0.177
LFn	0.7 ± 0.2	0.7 ± 0.1	0.915	0.508	0.360	0.582	0.676	0.666	0.356
FORBWORD	8.6 ± 9.4	2.2 ± 3.1	<b>0.049</b>	<b>0.039</b>	<b>0.046</b>	<b>0.031</b>	<b>0.049</b>	<b>0.033</b>	<b>0.036</b>
H <sub>k</sub>	3.4 ± 0.5	3.7 ± 0.2	<b>0.042</b>	<b>0.045</b>	0.092	<b>0.048</b>	<b>0.049</b>	<b>0.034</b>	0.078
Polvar10	0.4 ± 0.3	0.1 ± 0.1	<b>0.042</b>	<b>0.046</b>	0.077	0.122	0.102	0.217	0.110

The results of the Mann–Whitney-U-test are presented in the columns Day 1 to 7. No time- and frequency-domain parameters demonstrated consistent significant differences between the *de novo* AF and the control group. In contrast, the symbolic dynamics parameter Forbword and  $H_k$  demonstrated significant differences for several days (Bold font:  $p < 0.05$ ).

**Abbildung 5.7.** Tabelle der Mann-Whitney-U-Tests an sieben Tagen der Messungen

$n_1$  und  $n_2$  sind die Anzahlen an Elementen in den beiden Populationen.  $R_1$  und  $R_2$  sind die Summen der Rangzahlen in den Populationen. Die Nullhypothese wird abgelehnt, wenn die Kleinere der beiden Prüfgrößen kleiner oder gleich dem kritischen Wert ist. Der kritische Wert für zwei Populationen mit der Größe 10 und einer Signifikanz der Unterscheidbarkeit beträgt 23.

Im Paper wurde mit Hilfe des Mann-Whitney-U-Test festgestellt, dass der Parameter forbidden words in der *de novo*-Gruppe tendenziell größer ausfällt als in der Kontrollgruppe. Die Signifikanz des Tests betrug an allen sieben Tagen der Datenaufnahme weniger als 0.05. In der Abbildung 5.7 finden Sie eine Tabelle mit den einzelnen Signifikanzwerten aus der Studie.

Das Ziel ist es mit den vorhergesagten Werten aus einem trainierten neuronalen Netz den oben genannten kritischen Wert im Mann-Whitney-U-Test zu erreichen. Wichtig hierbei ist es, die 20 Patienten aus den Trainings- und Testsets auszuschließen. Hierdurch kann Data Leakage unterbunden werden und eine unbewusste Optimierung der Netzarchitektur auf die Daten der beiden Studiengruppen verhindert werden.

Die Patienten aus der *de novo*- und Kontrollgruppe haben gemeinsam über 20.000 Segmente, wobei der FW-Wert der Segmente für die einzelnen Patienten nicht gleich ist. Um einen verlässlichen Wert für den FW-Parameter eines Patienten zu erhalten, wird der Modus aller FW-Wert eines jeden Patienten für die Auswertung im Mann-Whitney-U-Test verwendet.

# 6 Experiment

Der erste Teil der Experimente konzentriert sich auf den Einsatz und die Auswirkungen der Pseudo-Aufgaben auf die Vorhersagequalität der Modelle gemessen an der Genauigkeit der berechneten Parameter für die *de novo* Gruppe und der Kontrollgruppe. Im zweiten Teil der Experimente werden Modelle mit LSTM-Einheiten und Attention-Layern trainiert. Die Performance beider Varianten werden hinsichtlich der Trainingsdauer und der Vorhersagequalität verglichen. Im dritten Teil werden die Terme der Pseudo-Aufgaben in der Kostenfunktion mit Gewichten multipliziert, die mit steigender Epochenzahl verringert werden. Die Auswirkung dieser Gewichtung auf das Training und die Qualität der Modelle wird anschließend untersucht. Im vierten Teil der Experimente werden neuronale Netze mit verzweigter und unverzweigter Architektur verglichen. Im fünften Teil der Experimente wird der Einfluss der Faltungskerngröße in der Faltungsschicht des Encoder-Abschnitts auf die Vorhersagequalität untersucht. Der sechste Teil der Experimente befasst sich mit der Untersuchung des Optimizers. Der Optimizer Adam aus den vorherigen Architekturen wird mit der erweiterten Version AdamW verglichen. Im siebten Teil der Experimente wird der Unterschied in der Vorhersagequalität der trainierten Modelle unter Einsatz unterschiedlicher EKG-Kanäle ermittelt. Die achte Versuchsreihe befasst sich mit dem Einfluss eines Gewichts auf den Lossterm des Merkmals SymbolC auf die Vorhersagequalität der Modelle au den Testdatensatz. Im abschließenden Experiment wird der Parameter forbidden words für die Patienten aus dem Papers „Cardiac Autonomic Dysfunction and Incidence of de novo Atrial Fibrillation: Heart Rate Variability vs. Heart Rate Complexity“ von mehreren neuronalen Netzen vorhergesagt und die Ergebnisse der Whitney-U-Tests der Modellvorhersagen miteinander verglichen.

## 6.1 Pseudo-Aufgaben

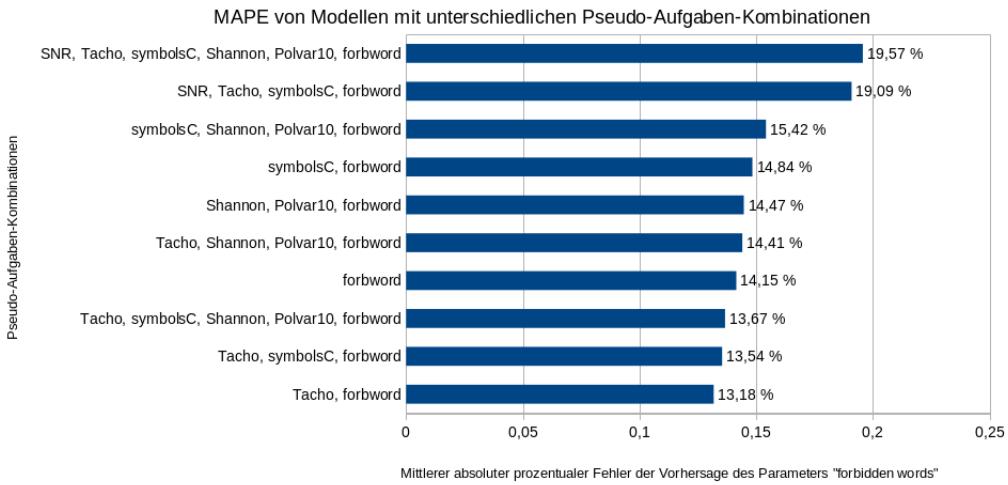
Zur Konstruktion von Modellen werden folgende Pseudo-Aufgaben herangezogen:

- Signal-to-Noise Ratio
- Tachogramm
- symbolische Dynamik
- Shannon-Entropie
- Polvar10

Die Modelle mit den unterschiedlichen Kombinationen an Pseudo-Aufgaben werden anschließend auf die Vorhersage des Parameters forbidden words hin trainiert, wobei die Pseudo-Aufgaben nicht mit gewichteten LOSS in das Training aufgenommen werden. Alle Modelle erhalten nur die EKG Zeitreihen der ReactDX-Studie als Input. Die *de novo*-Gruppe und die Kontrollgruppe aus dem Datenset werden für das Training und den Test nicht herangezogen, womit data leakage unterbunden

## 6 Experiment

---

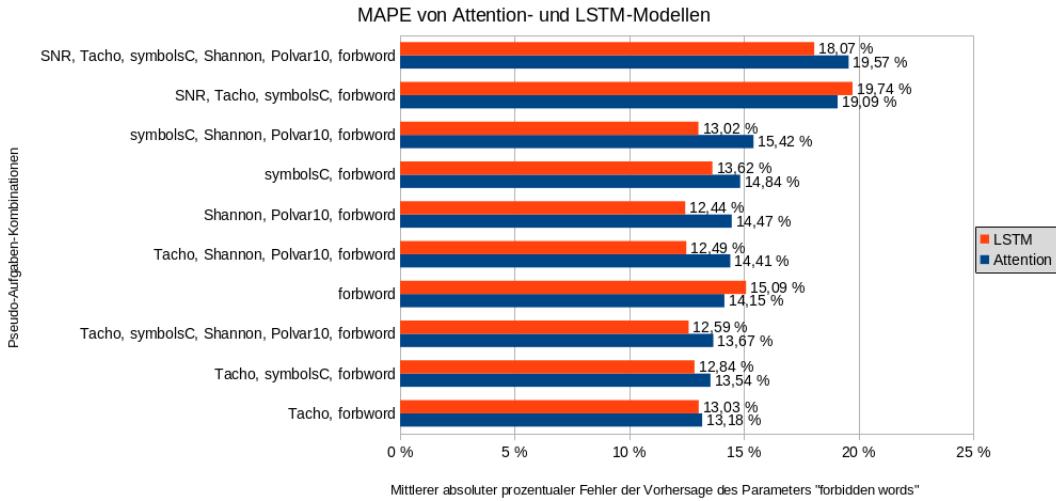


**Abbildung 6.1.** Mittlerer absoluter prozentualer Fehler (MAPE) der Vorhersage des Parameters forbidden words für unterschiedliche Pseudo-Aufgaben-Kombinationen

wird. Der verbliebene Datensatz wird im Verhältnis 80:20 aufgeteilt. Die Qualität des trainierten Modells wird anhand des mittleren absoluten prozentualen Fehlers (MAPE) der Vorhersage des Parameters forbidden words eingeschätzt. Anschließend wird die MAPE der Modelle über die Pseudo-Aufgaben-Kombination aufgetragen und in Abbildung 6.1 dargestellt.

Auffällig ist die geringe Genauigkeit des Modells mit der Pseudo-Aufgabe SNR. Zur Vorhersage des Merkmals SNR wird viel Information vom Modell benötigt, weshalb eine erfolgreiche Lösung dieser Aufgabe ein hohes Potential hat die Genauigkeit der Hauptaufgabe zu erhöhen und die Generalisierung des Modells zu verbessern. Vermutlich stellt die Vorhersage des Anteils an Rauschen auf einem Signal eine schwierige Aufgabe dar und das Modell benötigt mehr Epochen, um reliable Vorhersagen zu treffen. Des Weiteren basiert die Abschätzung des SNR im Gegensatz zu den anderen Pseudo-Aufgaben und der Hauptaufgabe nicht auf dem Tachogramm, sondern auf der Morphologie des EKG-Signals. Da für die Vorhersage des SNR andere Eigenschaften der Eingabe benötigt werden als für die anderen Aufgaben, ist mehr von der Modellkapazität im Kern nur für die Vorhersage des SNR reserviert. Hierdurch bleibt weniger Modellkapazität übrig für die Vorhersage des Parameters FW und die Qualität des Modells bleibt begrenzt.

Die Anwendung von Pseudo-Aufgaben zeigt nach 10 Epochen bei einem Teil der Modelle keine oder kaum Verbesserung der MAPE der Hauptaufgabe. Dieses Ergebnis bestätigt zunächst, dass die Verwendung von Pseudo-Aufgaben die Modelle an der Minimierung des Losses der Hauptaufgabe nicht hindern.



**Abbildung 6.2.** Mittlerer absoluter prozentualer Fehler (MAPE) der Vorhersage des Parameters forbidden words für LSTM- und Attention-Modelle

## 6.2 LSTM vs. Attention

In diesem Experiment werden Modelle auf Basis von LSTM-Layern erstellt, die im Aufbau und Kapazität vergleichbar sind mit den Attention-Modellen aus dem Kapitel 6.1. Diese werden ebenfalls für zehn Epochen trainiert und die MAPE der Modelle mit den gleichen Pseudo-Aufgaben-Kombinationen werden in der Abbildung 6.2 verglichen. Die Reihenfolge der Modelle im Diagramm wird vom ersten Experiment übernommen.

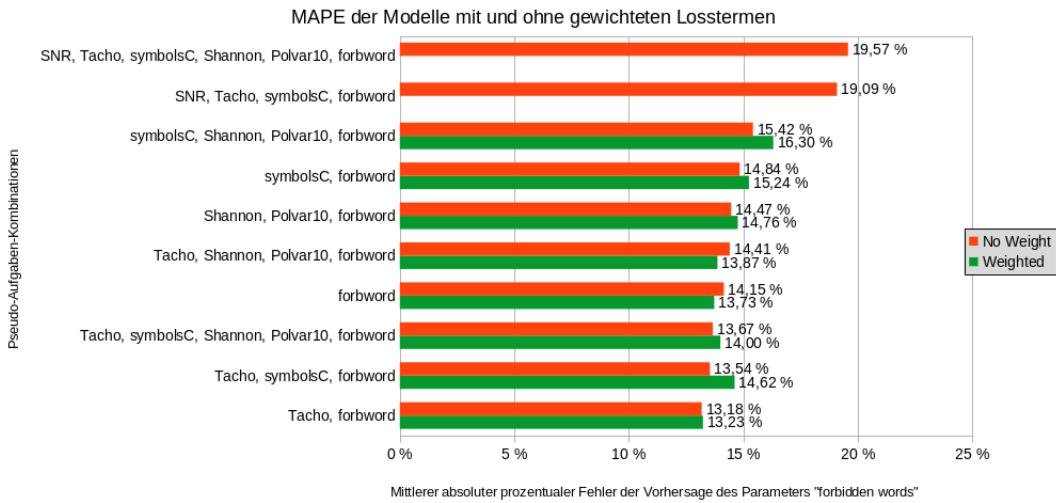
Die LSTM-Modelle liefern nach zehn Epochen Training für fast jede Pseudo-Aufgaben-Kombination ausnahmslos genauere Vorhersagen als die Attention-Modelle. Es fällt auf, dass das LSTM-Modell ohne Pseudo-Aufgaben eine schlechtere Qualität aufweist als sein Attention-Pendant. Die schnellere Anpassung der Gewichte im Modell zu besseren Vorhersagen ist mit der zehnmal geringeren Anzahl an freien Parametern in den LSTM-Modellen im Vergleich zu den Attention-Modellen zu erklären. Die Attention-Modelle bestanden in dieser Experimentierreihe im Schnitt aus 212.000 freien Parametern.

Die Trainingsepochen der LSTM-Modelle haben im Schnitt dreimal so lange in Echtzeit gedauert als die der Attention-Modelle. Die langsamere Rechengeschwindigkeit ist mit der schlechten Parallelisierbarkeit von LSTM-Layern erklärbar, welche stark rekurrent funktionieren. Die Trainings in den Experimenten werden möglichst auf der GPU ausgeführt, wobei eine hohe Parallelisierbarkeit der Modelle eine hohe Zeitersparnis einbringen kann und innerhalb praktikablen Zeitspannen größere Modelle trainiert werden können. Die Attention-Modelle benötigen im Schnitt 12,46 Minuten für eine Epoche, obwohl die Modelle in der Regel zehnmal größer sind.

Trotz der augenscheinlich besseren Ergebnisse der LSTM-Modelle wird das letzte Experiment mit den Attention-Layern durchgeführt, da neben einer optimierten Architektur eine hohe Anzahl an freien Parametern entscheidend ist für qualitativ hochwertige Vorhersagen.

## 6 Experiment

---



**Abbildung 6.3.** Mittlerer absoluter prozentualer Fehler (MAPE) der Vorhersage des Parameters forbidden words von Modellen mit ungewichteter und gewichteter Kostenfunktion

### 6.3 Gewichtete Kostenfunktion

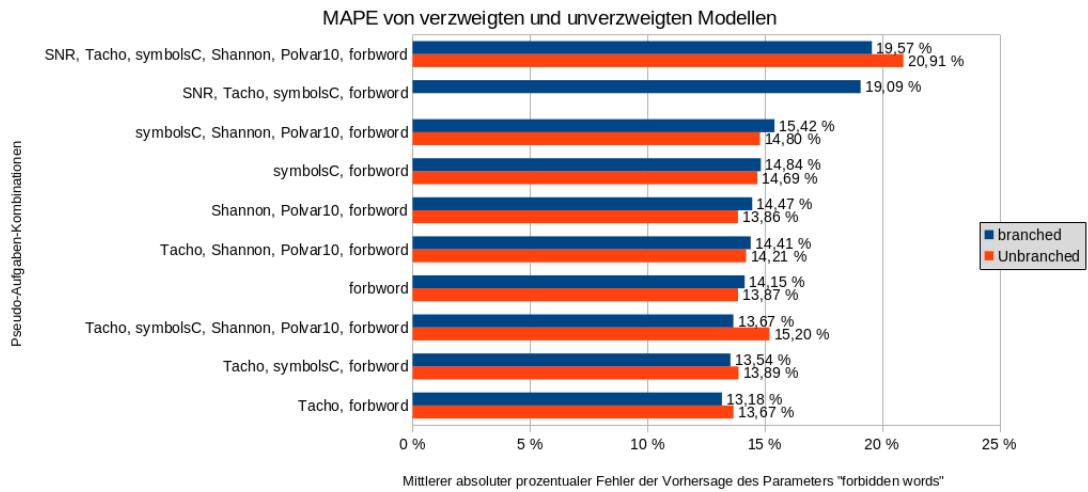
In dieser Versuchsreihe wurden die Terme der Pseudo-Aufgaben in der Kostenfunktion mit Gewichten multipliziert, die mit jeder Epoche kleiner werden. Die Idee dabei ist den Pseudo-Aufgaben mit jeder Epoche immer weniger Anteil an den Kosten zu geben und damit deren Priorität zu verringern. Hierdurch sollte die Optimierung der Gewichte anhand des Gradienten der Kostenfunktion sich immer mehr auf den Term der Hauptaufgabe konzentrieren. Das Gewicht der Pseudo-Aufgaben sind umgekehrt proportional zur Epochenzahl und werden mit dieser Formel berechnet  $\frac{1}{1+Epoche}$ . Die Ergebnisse der Tests für Modelle mit und ohne Gewichte in der Kostenfunktion sind in der Abbildung 6.3 dargestellt.

Die Vorhersagequalität der Modelle mit Gewichten in der Kostenfunktion sind nicht pauschal besser als deren Gegenstücke ohne Gewichte. Jedoch scheint das Training mit Gewichten in der Kostenfunktion weniger stabil zu verlaufen, da die Trainings der Modelle mit der Pseudo-Aufgabe SNR auf Grund explodierender Gradienten abbrechen.

Da die Implementierung der gewichteten Kostenterme keine klare Verbesserung gebracht hat und es Indizien für ein instabileres Training gibt, wird im abschließenden Experiment diese Form der Kostenfunktion nicht verwendet.

### 6.4 Unverzweigte Architektur

In diesem Teil der Experimente wird der Einfluss der verzweigten Architektur auf die Vorhersagequalität der Modelle im Test untersucht. Hierzu werden Modelle ohne Zweige implementiert und trainiert. Die Testergebnisse der beiden Varianten werden für einen einfacheren Vergleich gemeinsam im Diagramm 6.4 visualisiert.



**Abbildung 6.4.** Mittlerer absoluter prozentualer Fehler (MAPE) der Vorhersage des Parameters forbidden words von Modellen mit unverzweigter und verzweigter Architektur

Die Modelle mit unverzweigter Architektur und der Pseudo-Aufgabe haben im Vergleich zur verzweigten Variante schlechtere Ergebnisse im Test. Die Aufteilung in unabhängige Zweige scheint bei stark unterschiedlichen Aufgaben von Vorteil zu sein, da irrelevante Wissen stärker vom Berechnungspfad der Hauptaufgabe getrennt ist.

Für die Modelle im Mittelfeld der MAPE-Werte ist zu beobachten, dass eine unverzweigte Architektur bessere Ergebnisse liefert als die Modelle mit verzweigter Architektur. Dieses Verhältnis kehrt sich für die Modelle mit niedrigerer MAPE um. Dies deutet darauf hin, dass unverzweigte Modelle zwar bei suboptimaler Auswahl an Pseudo-Aufgaben schneller zu genaueren Vorhersagen kommen, jedoch können die verzweigten Modelle bei besseren Kombinationen die Vorteile der Pseudo-Aufgaben nicht ausschöpfen.

Da die verzweigten Modelle niedrigere MAPE erreichen können, wird das finale Experiment mit dieser Variante ausgeführt.

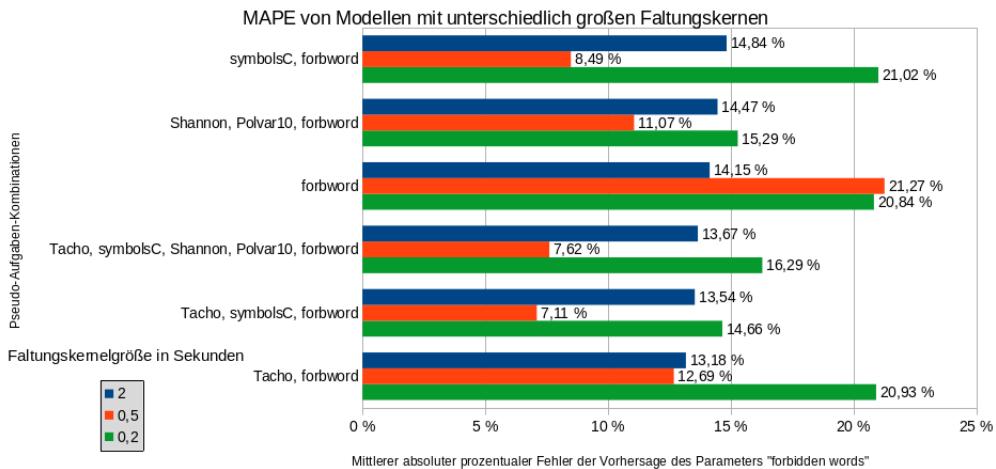
## 6.5 Faltungskerngröße

Diese Versuchsreihe dient zur Optimierung der Faltungskerngröße der Faltungsschichten im Encoderteil der Netzarchitektur. Die ursprüngliche Größe der Faltungskerne von 2 Sekunden wird auf 0, 5 und 0, 2 Sekunden variiert. Die Ergebnisse der drei Varianten werden in der Abbildung 6.5 für einen Vergleich nebeneinander dargestellt.

Die Vorhersagequalität der Modelle mit einer Faltungskerngröße von 0, 2 Sekunden ist im Vergleich zu einer Größe von 2 Sekunden für alle Pseudo-Aufgaben-Kombinationen schlechter. Insbesondere die Kombinationen „SymbolC, forbword“, „forbword“ und „Tacho, forbword“ scheinen sehr langsam zu konvergieren oder in einem relativ hohen lokalen Minimum zu verharren. Die Trainings

## 6 Experiment

---



**Abbildung 6.5.** Mittlerer absoluter prozentualer Fehler (MAPE) der Vorhersage des Parameters forbidden words von Modellen mit unterschiedlich großen Faltungskernen in den Faltungsschichten

von neuronalen Netzen unterliegen generell zufälligen Schwankungen und zeigen oft solche Verhalten, jedoch wird eine Häufung von stagnierten Minimierungen als Zeichen für suboptimale Hyperparameter und flachen Gradienten der Kostenfunktion interpretiert.

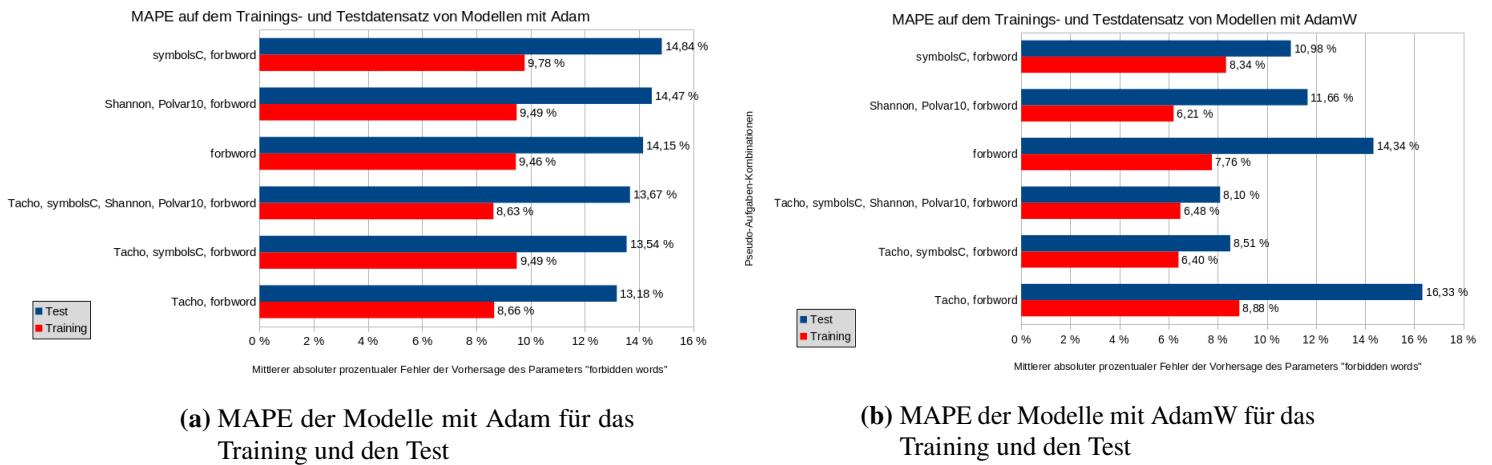
Eine Kerngröße von 0,5 Sekunden in den Faltungsschichten der Modelle resultiert bei fast allen Pseudo-Aufgaben-Kombinationen in niedrigeren MAPE der Vorhersage vom Parameter FW im Vergleich zu den Werten bei Modellen mit einer Faltungskerngröße von 2 Sekunden. Nur bei den Varianten ohne Pseudo-Aufgabe forbword ist die Vorhersagequalität der Modelle mit einer Kerngröße von 2 Sekunden besser als bei den kleineren Kerngrößen.

Aus diesen Ergebnissen lässt sich interpretieren, dass die Auswahl der Faltungskerngröße von entscheidender Bedeutung ist für die adäquate Lösung der Hauptaufgabe. Mit kleineren Kerngrößen sind niedrigere MAPE möglich, jedoch müssen die Modelle parallel dazu Pseudo-Aufgaben erfüllen, um erfolgreich trainiert werden zu können. Vermutlich verringert sich durch die kleineren Faltungskerne die extrahierte Informationsmenge in den 128 Filtern, welches zu flacheren Gradienten führt. Dem wird mit den Pseudo-Aufgaben entgegen gewirkt, weil die Modelle durch die multiplen Aufgaben animiert werden, eine größere Informationsmenge aus der Eingabe zu extrahieren. Mit dem steileren Gradienten und einem kleineren Faltungskern sind anschließend bessere Vorhersagen möglich, weil die Filter detaillierter Eigenschaften abbilden können.

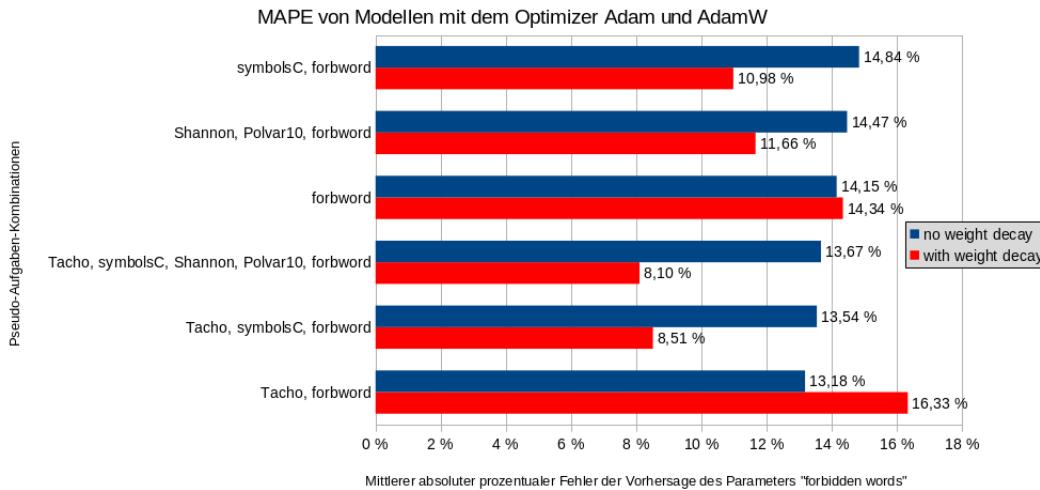
## 6.6 Weight decay

Diese Experimentierreihe befasst sich mit dem Vergleich der Optimizer Adam und AdamW [LH19]. Der AdamW hat im Gegenzug zu Adam einen Strafterm für große Beträge der Gewichte in den Schichten des neuronalen Netzes. Große Gewichte werden in neuronalen Netzen mit einer

## 6.6 Weight decay



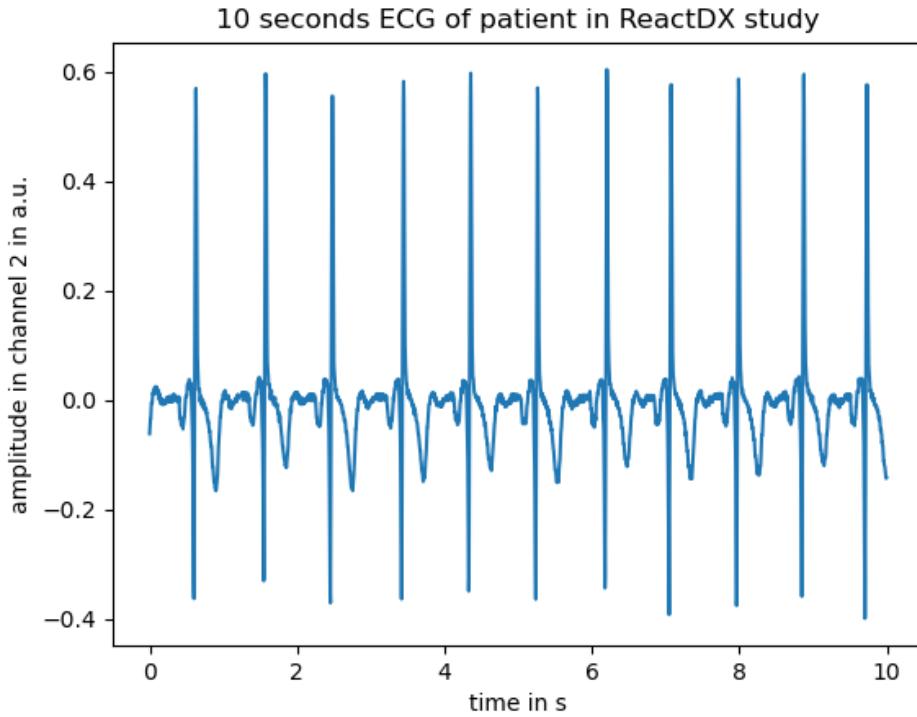
**Abbildung 6.6.** Mittlerer absoluter prozentualer Fehler (MAPE) der Vorhersage des Parameters forbidden words von Modellen mit Adam- und AdamW-Optimizer



**Abbildung 6.7.** Mittlerer absoluter prozentualer Fehler (MAPE) der Vorhersage des Parameters forbidden words von Modellen mit Adam- und AdamW-Optimizer

Überanpassung des Modells auf die Trainingsdaten in Verbindung gebracht. Durch den Strafterm werden die Beträge der Gewichte im neuronalen Netz tendenziell zu kleineren Werten hin angepasst und eine Überanpassung wird unterbunden.

In der Abbildung 6.6a sind die MAPE des Trainings und Tests für die Modelle mit dem Optimizer Adam dargestellt. Die MAPE der Vorhersagen für den Parameter FW auf den Testbeispielen sind 4 bis 5 % schlechter als die Vorhersagen auf den Trainingsbeispielen. Eine Verschlechterung des MAPE in dieser Größenordnung deutet auf eine Überanpassung des Modells auf die Trainingsbeispiele hin. Die Differenz des MAPE für die Trainings und Tests der Variante mit AdamW fallen größtenteils geringer aus als mit der Variante Adam. Die kleinere Differenz zwischen der Vorhersagequalitäten im Training und im Test deutet auf eine geringere Überanpassung der Modelle hin.



**Abbildung 6.8.** 10 Sekunden langes EKG aus dem Datenset ReactDX

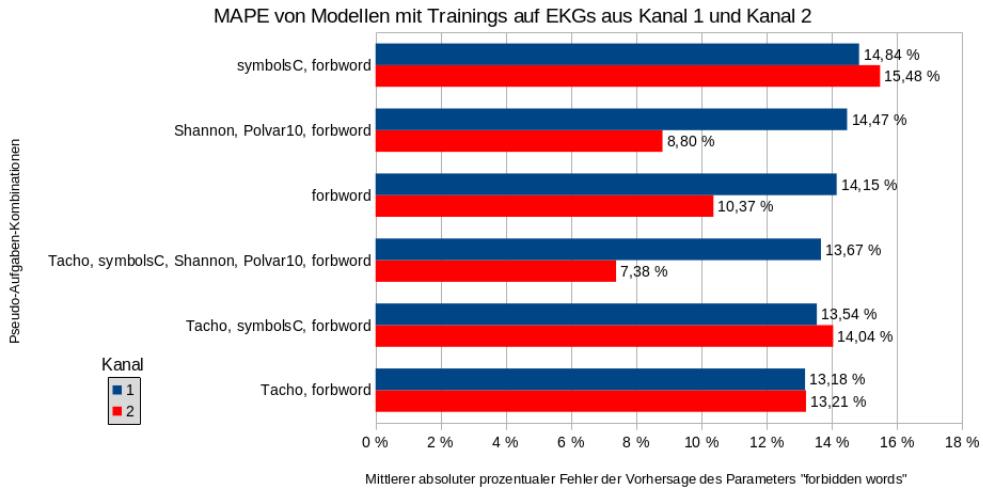
Im direkten Vergleich der Varianten mit und ohne Weight Decay lässt sich feststellen, dass die MAPE für die Testbeispiele des Modells mit AdamW um bis 5 % geringer ausfallen. Nur die Modelle mit dem Optimizer AdamW der Pseudo-Aufgabenkombination „Tacho, forbword“ und die Variante ohne Pseudo-Aufgabe haben keine bessere mittlerer absoluter prozentualer Fehler (MAPE) als die Modlle mit dem Optimizer Adam. Die deutliche Verbesserung der Vorhersagequalität bei ausgewählten Pseudo-Aufgabenkombinationen lässt zu dem Schluss kommen die Modelle im letzten Experiment mit dem Optimizer AdamW zu erstellen.

## 6.7 Kanal 2

Die bisherigen Modelle wurden auf den EKGs des ersten Kanals trainiert, wobei der Datensatz aus der Studie ReactDX zwei weitere Kanäle besitzt. Aus den drei Kanälen haben die EKGs aus Kanal 2 die markantesten R-Zacken, die vermutlich zur Bestimmung der Herzrate am hilfreichsten sind. In der Abbildung 6.8 ist ein EKG aus dem Kanal 2 des Datensatzes ReactDX abgebildet.

Die folgenden Modelle wurden auf Trainingsbeispielen trainiert, die aus den EKGs des Kanals 2 gewonnen wurden, und sind in Abbildung 6.9 dargestellt.

## 6.8 Gewichtetes Loss des Merkmals SymbolsC



**Abbildung 6.9.** Mittlerer absoluter prozentualer Fehler (MAPE) der Vorhersage des Parameters forbidden words von Modellen mit Trainingsdaten aus Kanal 1 und Kanal 2

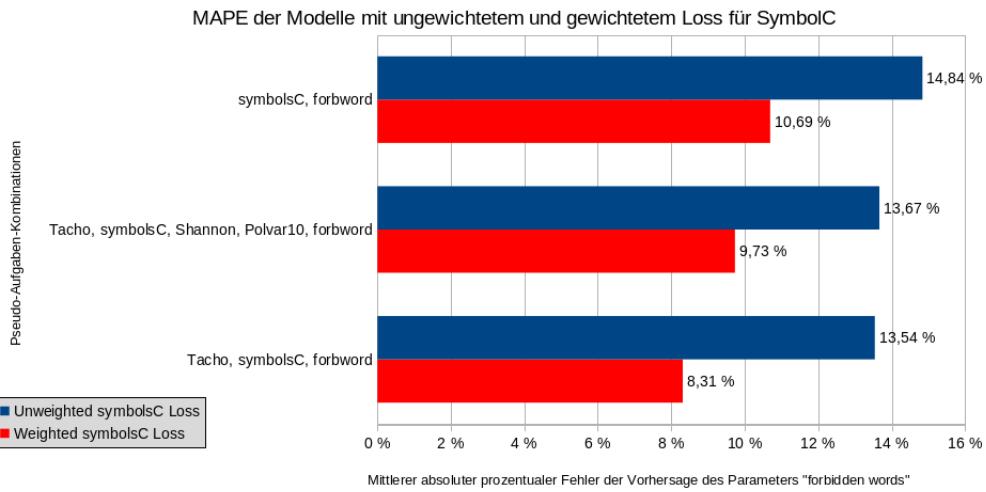
Die auf Kanal 2 trainierten Modelle erreichen auf den Testbeispielen in vier von sechs Pseudo-Aufgaben-Kombinationen niedrigere MAPE. Die bessere Qualität bei einer Mehrheit der Modelle deutet auf die Richtigkeit der Annahme, dass markantere R-Zacken im EKG zu einer genaueren Vorhersage des Parameter FW führen. Aus diesem Grund werden im finalen Versuch Trainingsbeispiele aus dem Kanal 2 genutzt.

## 6.8 Gewichtetes Loss des Merkmals SymbolsC

Die Kostenfunktion SparseCategoricalCrossentropy des Merkmals SymbolsC gibt eine Ausgabe der Größenordnung 10 – 1 aus, wobei der Loss der anderen Merkmale eine Größenordnung von 10 – 3 haben. Diese starke Differenz der Lossterme sorgt bei der Optimierung der Modellgewichte für eine Priorisierung der Pseudo-Aufgabe das Merkmal SymbolsC vorherzusagen. Die Priorisierung kann zu einer schlechteren Vorhersage des Parameter FW führen. Diese These wird mit der Gewichtung des Losses aus der Funktion SparseCategoricalCrossentropy überprüft. Die MAPE der Modelle mit und ohne gewichtetem Loss werden in der Abbildung 6.10 visualisiert.

Die Vorhersagequalität der Modelle mit Gewichtung des Losses des Merkmals SparseCategoricalCrossentropy fallen bei allen Pseudo-Aufgaben-Kombinationen besser aus. Die These, dass eine ähnliche Größenordnung der Losswerte eine Verringerung der MAPE für die Vorhersage des Parameters FW haben wird, ist mit diesen Ergebnissen bestätigt. Die Gewichtung des Lossterms SymbolsC wird im finalen Experiment eingesetzt.

## 6 Experiment



**Abbildung 6.10.** Mittlerer absoluter prozentualer Fehler (MAPE) der Vorhersage des Parameters forbidden words von Modellen mit und ohne Gewichtung des Losses des Merkmals SparseCategoricalCrossentropy

## 6.9 finale Modellarchitektur

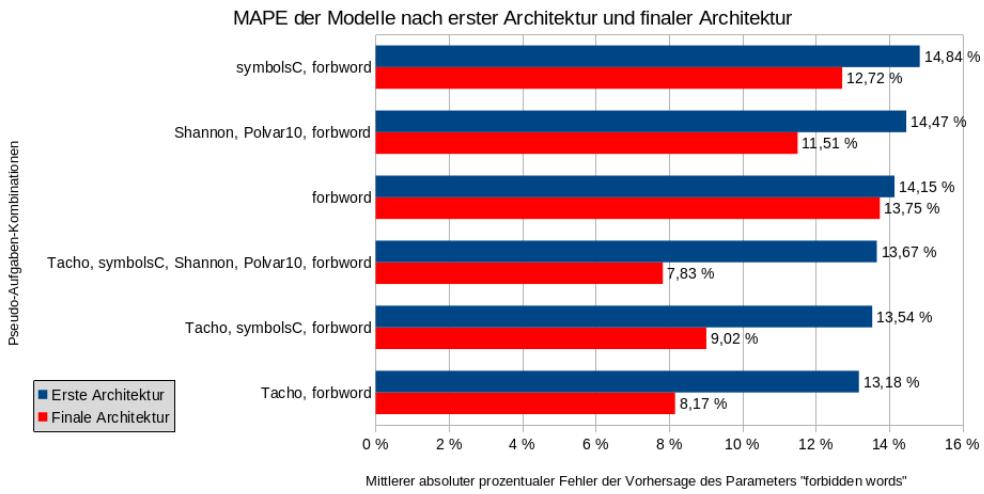
In dieser Versuchsreihe werde die Erkenntnisse aus den vorangegangenen Experimenten zusammengeführt und die Vorhersagequalität der unterschiedlichen Pseudo-Aufgaben-Kombinationen werden ausgewertet. Die finale Architektur beinhaltet folgende Verbesserung im Vergleich zum ersten Modell:

- Faltungskerne der Größe 0,5 Sekunden
- den Optimizer AdamW
- der EKG-Kanal 2
- das gewichtete Loss des Merkmals SymbolsC

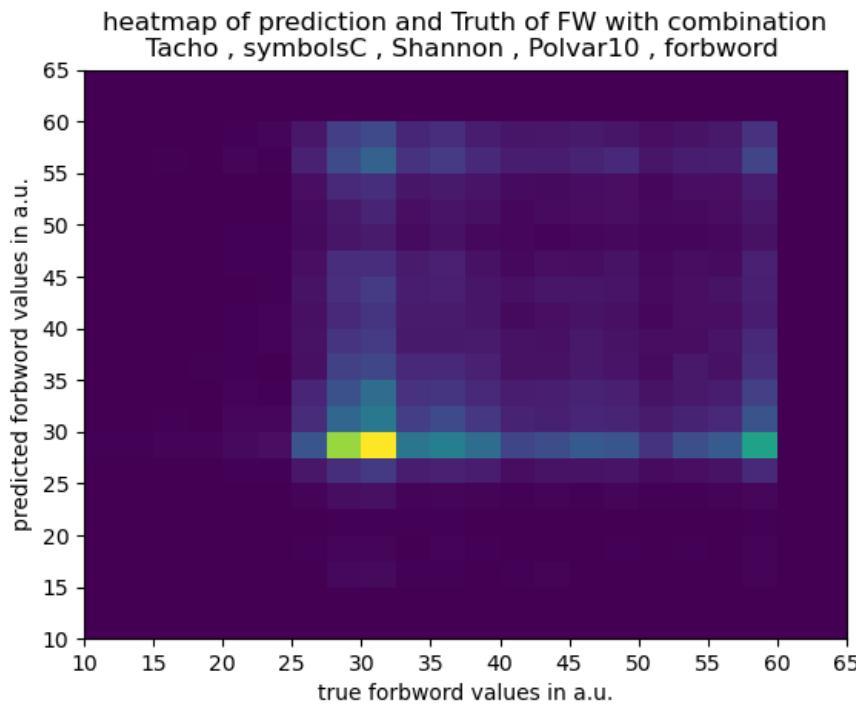
Die MAPE der trainierten Modelle sind in der Abbildung 6.11 im Vergleich zu den Modellen der anfänglichen Architektur dargestellt.

Die Modelle der finalen Architektur erzielen für jede Pseudo-Aufgaben-Kombination niedrigere MAPE als die Gegenstücke der ersten Architektur. Die einzelnen Optimierungen aus der Hyperparametersuche funktionieren nach den Ergebnissen zu urteilen in Kombination und liefern genauere Vorhersagen des Parameters FW. In der Abbildung 6.12 werden die vorhergesagten Werte für den Parameter FW gegenüber den vorgegebenen Werten der Beispiele in einer Heatmap dargestellt. Idealerweise liegt die Vorhersage nahe um die vorgegebenen Werte, wodurch sich die Datenpunkte um die Identität häufen.

Im Heatmap sind drei Häufungen zu erkennen, welche um die Punkte (30, 30), (30, 60) und (60, 30) liegen. In der Verteilung der FW-Werte der Trainingsbeispiele, siehe Abbildung 5.6a, ist die Häufigkeit der Beispiele mit FW um 32,5 und um 60 ersichtlich. Durch die Häufung



**Abbildung 6.11.** Mittlerer absoluter prozentualer Fehler (MAPE) der Vorhersage des Parameters forbidden words von Modellen der finalen Architektur

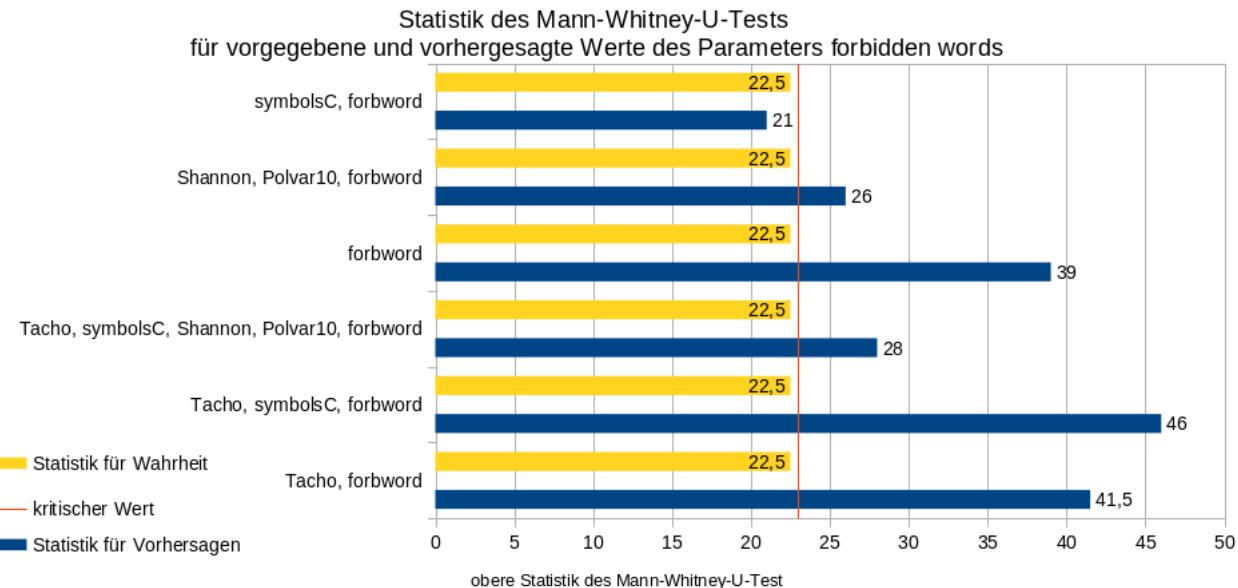


**Abbildung 6.12.** Heatmap der vorhergesagten Werte in Abhängigkeit vom echten Wert des Parameters FW

## 6 Experiment

---

Pseudo-Aufgaben-Kombinationen



**Abbildung 6.13.** untere Statistik des Mann-Whitney-U-Tests der vorhergesagten und vorgegebenen FW-Werte

der Beispiele um diese Werte neigen die Modelle zu einer Vorhersage um diese beiden Werte. Der Voreingenommenheit der Modelle kann mit einer uniformen Verteilung der FW im Training entgegengewirkt werden [RN16].

Die von den Modellen vorhergesagten FW-Werte werden im Mann-Whitney-U-Test ausgewertet und mit den Ergebnissen der vorgegebenen Werten in Abbildung 6.13 verglichen.

Die rote Senkrechte bei 23 gibt den kritischen Wert des Mann-Whitney-U-Tests für zwei Populationen mit jeweils 10 Elementen wieder. Für eine Ablehnung der Nullhypothese, dass die Verteilungen beider Populationen nicht größer oder kleiner voneinander sind, muss die untere Statistik des Mann-Whitney-U-Tests unter dem kritischen Wert liegen. Nur das Modell mit der Pseudo-Aufgaben-Kombination „SymbolC, forbword“ liefert Vorhersagen für den Parameter FW, die den Mann-Whitney-U-Test ebenfalls bestehen und einen signifikanten Unterschied zwischen der *de novo*- und der Kontrollgruppe belegen, wobei das Modell aus 980.770 freien Parametern besteht. Die Teststatistik aus den vorhergesagten FW-Werten ist um 1,5 kleiner als die Teststatistik aus den vorgegebenen FW-Werten, damit ist die Unterscheidung der beiden Gruppen anhand der vorhergesagten Werte signifikanter.

Bei einem Vergleich der MAPE der Modelle aus der Abbildung 6.11 mit den Ergebnissen des Mann-Whitney-U-Tests fällt auf, dass die beiden Werte nicht miteinander korrelieren. Dies unterstreicht den Punkt, dass die Metriken im Training und Test nur bedingt Aussagen über die Qualität der Aufgabenlösung unter Realbedingungen trifft.

## 7 Diskussion

In der Einleitung wird die Einführung von neuronalen Netzen in die Analyse der Herzratenvariabilität auf die Möglichkeit zur Automation und Erweiterung der Analysemethoden betont. Mit der erfolgreichen Reproduktion der Studienergebnisse mit einem neuronalen Netz ist das Ziel, die Vorverarbeitung der Daten zu automatisieren, erreicht. Die leicht höhere Signifikanz der Teststatistik deutet auf eine effektivere Separation von Gruppen durch neuronale Netze hin.

Jedoch ist Vorsicht bei der Verwendung von neuronalen Netzen geboten.

Die Transformationen innerhalb eines solchen Modells sind für Menschen schwierig nachzuvollziehen, da die Vielzahl an Gewichten im Modell und deren Beziehung zueinander unübersichtlich sind. Die Ausgaben aus den Modellen der Versuchsreihen ähneln den Vorgaben, jedoch kann man nur Vermutung über die inneren Vorgänge der Modelle treffen.

Die Metriken und Kostenfunktionen liefern schlechte Einschätzungen inwiefern das trainierte Modell die ursprüngliche Aufgabenstellung wie beabsichtigt löst. Die Qualität der Modelle werden in den Experimenten anhand der MAPE am Testdatensatz eingeschätzt, jedoch gibt diese Metrik keine guten Hinweise welche Pseudo-Aufgaben-Kombination die Ergebnisse der Studie besser nachbildet.

Die Ausgaben der Modelle haben nur bedingt kausalen Zusammenhang mit physikalischen Größen. Die leicht besseren Ergebnisse im Mann-Whitney-U-Test des Attention-Modells mit der Pseudo-Aufgaben-Kombination „SymbolC, forbword“ gegenüber der vorgegebenen Werte deutet auf eine genauere Klassifikation hin, jedoch ist nicht nachvollziehbar worauf die Verbesserung der Klassifikation beruht [ERS+21].

Der Erfolg der neuronalen Netze und den Deep Learning-Methoden liegt in der hohen Flexibilität der Modelle unterschiedliche Datensätze zur Lösung von Aufgabenstellungen zu verarbeiten. Der Preis für die hohe Flexibilität ist die geringe Transparenz und die begrenzte Interpretierbarkeit der Modelle. Diese Methoden werden viel Fortschritt in der medizinischen Anwendung und Forschung bringen, müssen aber wohl überlegt eingesetzt werden.

In der klassischen HRV-Analyse eines EKGs werden zunächst die R-Zacken im Signal identifiziert, wobei je nach Rauschanteil und Sonderheiten Algorithmen zur Erkennung unterschiedlich gut funktionieren. Aus dieser Information wird anschließend ein Tachogramm erstellt, welches von Artefakten wie ektopischen Herzschlägen und fehlerhaften Erkennungen von R-Zacken bereinigt werden muss. Die Erkennung der Artefakte im Tachogramm wird mit Filtern ausgeführt, die unterschiedlich gut funktionieren und sorgfältig implementiert werden sollten. In der Analyse zum Artikel „Cardiac Autonomic Dysfunction and Incidence of de novo Atrial Fibrillation“ wurde der adaptive Filter eingesetzt [WMBK07]. Einen Vergleich der Artefakterkennung zwischen dem adaptiven Filter und den üblichen Prozentfiltern ist in Abbildung 4.2 zu finden. Die Methode zur Ersetzung der Artefakte wird nach Abwägung bezüglich der Phasenverschiebung, der Verfälschung der Parameter, der Einführung von nichtphysiologischen Eigenschaften und weiteren Punkten

## 7 Diskussion

---

ausgesucht. Aus dem bereinigten Tachogramm werden die linearen Parameter ermittelt. Die Parameter der Spektralanalyse und den nicht-linearen Methoden werden aus Transformationen des Tachogramms berechnet. Diese Vorverarbeitung wird von Forschern Schritt für Schritt mit Algorithmen implementiert und für jede Studie neu angepasst. Diese Arbeit ist zeitintensiv und setzt für eine erfolgreiche Bearbeitung Kenntnisse in Statistik, praktischer Programmierung, physikalischer Modellierung und Medizin voraus.

Die klassische Vorverarbeitung kann durch den Einsatz eines Modells wie dem Modell „SymbolC, forword“ aus dem Kapitel 6.9 ersetzt werden. Der Einsatz des fertig trainierten neuronalen Netzes zur Vorverarbeitung von EKGs aus neuen Datensätzen ist arbeitsarm und Bedarf keiner interdisziplinären Wissensgrundlage. Die EKGs aus den Datensätzen müssen lediglich auf eine definierte Länge geschnitten werden. Hierbei ist es von Vorteil rauscharme Segmente zu verwenden. Die Ausgabe des Modells kann ohne weitere Bearbeitung für die Tests der Analyse verwendet werden. Diese Vereinfachung der Vorverarbeitung ermöglicht es in der Datenverarbeitung unerfahrenen Forschern neue Datensätze der gleichen Analyse zu unterziehen und Forschungsideen mit wenig Aufwand selbstständig zu prüfen.

Die Anwendung auf neue Datensätze setzt voraus, dass das Modell mit EKGs trainiert wurde, die vergleichbar sind mit den EKGs im neuen Datensatz. Die Anwendung eines Trainingsdatensatzes mit nicht-uniformer Verteilung der Parameter der EKGs erzeugt Modelle, die dazu neigen Parameter vorherzusagen, die im Training häufig vorgegeben wurden. In der Abbildung 6.12 wird die Häufung der Vorhersage um den häufigsten Parameterwert der Trainingsbeispiele der Modelle der finalen Architektur visualisiert. Dies deckt sich mit der Erwartung, dass die Modell auf Grund der ungleich verteilten Parameter eine Voreingenommenheit in ihrer Vorhersage haben werden. Die Daten der ReactDX-Studie stammen von Patienten, die einen Herzschrittmacher implantiert bekommen haben, vor weniger als einem Monat einer Operation unterzogen wurden und ein erhöhtes Risiko für Herzerkrankungen aufweisen [WBK+20]. Die Modelle werden im Training auf die Analyse von Patienten mit gleichen Eigenschaften angepasst, weshalb die Eingabe von EKGs von Patienten mit stark abweichender Vorgeschichte weniger verlässliche Vorhersagen ergeben wird. Eine bessere Verallgemeinerung der Modelle erreicht man mit einer uniformen Verteilung der Parameter im Training. Eine unkomplizierte Methode zur Verringerung der Voreingenommenheit der Modelle ist es Trainingsbeispiele mit seltenen Parameterwerten im Training stärker zu gewichten oder öfter in der Anpassung des neuronalen Netzes zu verwenden. Dieses Problem kann mit der Erweiterung der Trainingsdaten um Patienten mit unterschiedlichen Vorgeschichten tiefgreifender gelöst werden. Dieser Ansatz verringert die Voreingenommenheit der Modelle für mehrere Parameter und Eigenschaften. Auf PhysioNet sind Datensätze vieler verschiedener Studien frei zugänglich und kann für die Erweiterung der Trainingsdaten genutzt werden. Beispielsweise kann der Icientia11k-Datensatz [TAC+19; TOB+] mit 11.000 Patienten zur Erweiterung genutzt werden.

Die Modelle können sehr flexibel zur Berechnung neuer Parameter oder Lösung anderer Aufgabenstellungen angepasst werden. Hierzu müssen die erwünschten Parameter und Lösungen der Trainingsbeispiele klassisch ermittelt und dem neuronalen Netz im Training präsentiert werden. Die klassische Vorverarbeitung wird von einem erfahrenem Forscher durchgeführt und durch die Vorgabe seiner Ergebnisse im Training wird in dem Modell die Erfahrung und das Wissen des Forschers abgebildet. Abgesehen von der Anpassung des Trainingsdatensatzes muss die grundlegende Architektur des Modells nicht verändert werden. Eventuell ist eine Hyperparametersuche wie in den Versuchsreihen notwendig, um eine hinreichende Genauigkeit zu erzielen. Das neu konfigurierte und trainierte Modell kann anschließend unkompliziert auf neue Datensätze genutzt werden.

---

In der Analyse von EKGs werden neuronale Netze bereits eingesetzt und seit 2017 steigt die Anzahl an Studien in diesem Bereich exponentiell [HSI22]. Die Modelle in den Studien werden zu Prädiktoren von linksventrikulären Dysfunktionen [AKL+19] und von Vorhofflimmern [ANL+19; BLCK21] trainiert, die EKGs als Eingabe erhalten. Weitere Studien befassen sich mit der Automatisierung der EKG-Diagnostik und vergleichen die Vorhersagen der Modelle mit den Diagnosen von Ärzten [RRP+20; SWSS21; ZAJ20]. In den oben genannten Studien werden neuronale Netze auf die Verarbeitung von EKGs trainiert und es werden Vorhersagen zu Diagnosen und Krankheitsbildern ausgegeben. Im Gegensatz zu den Modellen aus dem Kapitel 6.9 werden in diesen Studien HRV-Analysen nicht explizit von den Modellen abgebildet.

Weitere Studien befassen sich mit der Analyse der HRV unter Anwendung der Methoden des maschinellen Lernens, wobei das Ziel die Vorhersage der geistigen Müdigkeit [MLDC22; MVDC22], die Einschätzung der geistigen und allgemeinen Gesundheit [CPBC20], die Abschätzung von HRV-Parametern anhand von Infrarotaufnahmen des Gesicht [DPI+22], die Diagnose eines akuten Myokardinfarktes [CBL+22] und die Stresserkennung [BN23; GMT19] ist. Die Modelle in den Studien zur HRV-Analyse mit Hilfe von Methoden aus dem maschinellen Lernen kriegen klassisch berechnete HRV-Parameter als Eingabe und geben Vorhersagen zum Zustand des Patienten aus. Die Modelle aus dem Kapitel 6.9 haben die Aufgabenstellung die Berechnung der HRV-Parameter aus den EKGs nachzubilden und die Parameter in der Ausgabe vorherzusagen. Die Attention-Modelle haben hiermit eine andere Aufgabenstellung als bereits veröffentlichte HRV-Analyse unter Anwendung vom maschinellem Lernen.

Die Attention-Schichten werden zur Analyse von EKGs in Studien zur Authentifizierung von Personen [HPWA21], zur Detektion von Myokardinfarkten [FLN+20] und Klassifikationen von Arrhythmien [RW22] verwendet. Die Modelle in diesen Studien kommen den Modellen aus dem Kapitel 6.9 am nächsten. Die positiven Ergebnisse dieser Studien unterstützen die Annahme, dass neuronale Netze aus Attention-Schichten geeignet sind EKGs auszuwerten.



## 8 Ausblick

Es gibt bereits Studien über neuronalen Netze, die auf das Screening von Patienten trainiert wurden [AKL+19; ANL+19; BLCK21]. Die Modelle aus dem Kapitel 6.9 können in Rahmen einer fortführenden Studie für diese Aufgabenstellung angepasst werden. Im Training wird dem Netz die richtige Lösung zum eingegeben EKG vorgegeben und die angepassten Gewichte im Netz modellieren die Abbildung zwischen der Eingabe und der Ausgabe. Im latenten Raum der versteckten Schichten im Netz werden die Eigenschaften und Parameter der EKGs abgebildet und bis zur Ausgabe weiterverarbeitet. Die Zusammenstellung der verwendeten Eigenschaften und Parameter richtet sich hierbei nur auf die Minimierung des Losses der gestellten Aufgaben. Dieser generative Ansatz kann sehr komplexe Abbildungen erzeugen und ermöglicht potentiell statistisch signifikantere Klassifikationen und Diagnosen als klassische Methoden der HRV-Analyse. In der Abbildung 6.13 kann man sehen, dass das Modell „SymbolC, forbword“ Vorhersagen ausgibt, die die *de novo*- und Kontrollgruppe statistisch leicht signifikanter unterscheiden.

Ein großes Problem bei neuronalen Netzen allgemein und denen in den Studien [AKL+19; ANL+19; BLCK21] ist die schwierige Interpretierbarkeit der Modelle [ERS+21]. Der Vorteil einer Architektur mit HRV basierten Pseudo-Aufgaben ist die Möglichkeit einen Einblick in das Innenleben eines Modells zu bekommen. Die parallele Ausgabe dieser Parameter neben der Hauptaufgabe der Klassifikation erlaubt anhand der Vorhersagequalität der Pseudo-Aufgaben eine Einschätzung über die verwendeten Parameter zu treffen. Die Anwendung von Pseudo-Aufgaben bietet eine gute Möglichkeit die Funktionsweise eines trainierten Modells nachzuvollziehen und Vertrauen in dessen Qualität für medizinische Anwendungen aufzubauen.



# Literaturverzeichnis

- [ABS+89] M. L. Appel, R. D. Berger, J. Saul, J. M. Smith, R. J. Cohen. „Beat to beat variability in cardiovascular variables: Noise or music?“ In: *Journal of the American College of Cardiology* 14.5 (Nov. 1989), S. 1139–1148. ISSN: 07351097. doi: [10.1016/0735-1097\(89\)90408-7](https://doi.org/10.1016/0735-1097(89)90408-7). URL: <https://linkinghub.elsevier.com/retrieve/pii/0735109789904087> (besucht am 04.08.2023) (zitiert auf S. 10, 14).
- [AKL+19] Z. I. Attia, S. Kapa, F. Lopez-Jimenez, P. M. McKie, D. J. Ladewig, G. Satam, P. A. Pellikka, M. Enriquez-Sarano, P. A. Noseworthy, T. M. Munger, S. J. Asirvatham, C. G. Scott, R. E. Carter, P. A. Friedman. „Screening for cardiac contractile dysfunction using an artificial intelligence-enabled electrocardiogram“. In: *Nature Medicine* 25.1 (Jan. 2019), S. 70–74. ISSN: 1078-8956, 1546-170X. doi: [10.1038/s41591-018-0240-2](https://doi.org/10.1038/s41591-018-0240-2). URL: <https://www.nature.com/articles/s41591-018-0240-2> (besucht am 06.09.2023) (zitiert auf S. 51, 53).
- [ANL+19] Z. I. Attia, P. A. Noseworthy, F. Lopez-Jimenez, S. J. Asirvatham, A. J. Deshmukh, B. J. Gersh, R. E. Carter, X. Yao, A. A. Rabinstein, B. J. Erickson, S. Kapa, P. A. Friedman. „An artificial intelligence-enabled ECG algorithm for the identification of patients with atrial fibrillation during sinus rhythm: a retrospective analysis of outcome prediction“. In: *The Lancet* 394.10201 (Sep. 2019), S. 861–867. ISSN: 01406736. doi: [10.1016/S0140-6736\(19\)31721-0](https://doi.org/10.1016/S0140-6736(19)31721-0). URL: <https://linkinghub.elsevier.com/retrieve/pii/S0140673619317210> (besucht am 06.09.2023) (zitiert auf S. 51, 53).
- [ANW+17] S. K. Agarwal, F. L. Norby, E. A. Whitsel, E. Z. Soliman, L. Y. Chen, L. R. Loehr, V. Fuster, G. Heiss, J. Coresh, A. Alonso. „Cardiac Autonomic Dysfunction and Incidence of Atrial Fibrillation: Results From 20 Years Follow-Up“. In: *Journal of the American College of Cardiology* 69.3 (2017), S. 291–299. ISSN: 0735-1097. doi: <https://doi.org/10.1016/j.jacc.2016.10.059>. URL: <https://www.sciencedirect.com/science/article/pii/S0735109716370358> (zitiert auf S. 4).
- [APR36] G. V. Anrep, W. Pascual, R. Rossler. „Respiratory Variations of the Heart Rate. I.—The Reflex Mechanism of the Respiratory Arrhythmia“. In: *Proceedings of the Royal Society of London. Series B, Biological Sciences* 119.813 (1936), S. 191–217. ISSN: 0080-4649. URL: <https://www.jstor.org/stable/81959> (besucht am 27.08.2023) (zitiert auf S. 2).
- [ASBC89] M. Appel, J. Saul, R. Berger, R. Cohen. *Closed-loop identification of cardiovascular regulatory mechanisms*. Sep. 1989, S. 3–8. doi: [10.1109/CIC.1989.130466](https://doi.org/10.1109/CIC.1989.130466) (zitiert auf S. 10).

## Literaturverzeichnis

---

- [BAK18] D. Bzdok, N. Altman, M. Krzywinski. „Statistics versus machine learning“. en. In: *Nature Methods* 15.4 (Apr. 2018), S. 233–234. ISSN: 1548-7091, 1548-7105. doi: [10.1038/nmeth.4642](https://doi.org/10.1038/nmeth.4642). URL: <http://www.nature.com/articles/nmeth.4642> (besucht am 20.06.2022) (zitiert auf S. 15).
- [BCB+09] E.J. Benjamin, P.-S. Chen, D.E. Bild, A.M. Mascette, C.M. Albert, A. Alonso, H. Calkins, S.J. Connolly, A.B. Curtis, D. Darbar, P.T. Ellinor, A.S. Go, N.F. Goldschlager, S.R. Heckbert, J. Jalife, C.R. Kerr, D. Levy, D.M. Lloyd-Jones, B.M. Massie, S. Nattel, J.E. Olgm, D.L. Packer, S.S. Po, T.S. Tsang, D.R.V. Wagner, A.L. Waldo, D.G. Wyse. „Prevention of Atrial Fibrillation“. In: *Circulation* 119.4 (2009), S. 606–618. doi: [10.1161/CIRCULATIONAHA.108.825380](https://doi.org/10.1161/CIRCULATIONAHA.108.825380). eprint: <https://www.ahajournals.org/doi/pdf/10.1161/CIRCULATIONAHA.108.825380>. URL: <https://www.ahajournals.org/doi/abs/10.1161/CIRCULATIONAHA.108.825380> (zitiert auf S. 4).
- [BCB16] D. Bahdanau, K. Cho, Y. Bengio. *Neural Machine Translation by Jointly Learning to Align and Translate*. 19. Mai 2016. arXiv: [1409.0473\[cs, stat\]](https://arxiv.org/abs/1409.0473). URL: [http://arxiv.org/abs/1409.0473](https://arxiv.org/abs/1409.0473) (besucht am 04.08.2023) (zitiert auf S. 23).
- [BCV13] Y. Bengio, A. Courville, P. Vincent. „Representation Learning: A Review and New Perspectives“. In: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 35.8 (Aug. 2013), S. 1798–1828. ISSN: 0162-8828, 2160-9292. doi: [10.1109/TPAMI.2013.50](https://doi.org/10.1109/TPAMI.2013.50). URL: <http://ieeexplore.ieee.org/document/6472238/> (besucht am 20.06.2022) (zitiert auf S. 16).
- [Beh23] S. Behnke. 1. Sep. 2023. URL: [https://commons.wikimedia.org/wiki/File:Deep\\_Learning.jpg](https://commons.wikimedia.org/wiki/File:Deep_Learning.jpg) (zitiert auf S. 16).
- [BLCK21] Y.-S. Baek, S.-C. Lee, W. Choi, D.-H. Kim. „A new deep learning algorithm of 12-lead electrocardiogram for identifying atrial fibrillation during sinus rhythm“. In: *Scientific Reports* 11.1 (17. Juni 2021), S. 12818. ISSN: 2045-2322. doi: [10.1038/s41598-021-92172-5](https://doi.org/10.1038/s41598-021-92172-5). URL: <https://www.nature.com/articles/s41598-021-92172-5> (besucht am 06.09.2023) (zitiert auf S. 51, 53).
- [BN23] A.R.S. Banu, V. Nagaveni. „Assessment of Sympathetic and Parasympathetic Activities of Nervous System from Heart Rate Variability Using Machine Learning Techniques“. In: *SN Computer Science* 4.5 (28. Aug. 2023), S. 646. ISSN: 2661-8907. doi: [10.1007/s42979-023-02062-y](https://doi.org/10.1007/s42979-023-02062-y). URL: <https://link.springer.com/10.1007/s42979-023-02062-y> (besucht am 06.09.2023) (zitiert auf S. 51).
- [Bun23] S. Bundesamt. 27. Aug. 2023. URL: <https://www.destatis.de/DE/Themen/Querschnitt/Demografischer-Wandel/demografie-mitten-im-wandel.html> (zitiert auf S. 1).
- [Car97] R. Caruana. „Multitask Learning“. In: *Machine Learning* 28.1 (1. Juli 1997), S. 41–75. ISSN: 1573-0565. doi: [10.1023/A:1007379606734](https://doi.org/10.1023/A:1007379606734). URL: <https://doi.org/10.1023/A:1007379606734> (besucht am 11.01.2022) (zitiert auf S. 25).
- [CBL+04] D. Cysarz, H. Bettermann, S. Lange, D. Geue, P. Van Leeuwen. „A quantitative comparison of different methods to detect cardiorespiratory coordination during night-time sleep“. In: *BioMedical Engineering OnLine* 3.1 (Dez. 2004), S. 44. ISSN:

- 1475-925X. doi: [10.1186/1475-925X-3-44](https://doi.org/10.1186/1475-925X-3-44). URL: <https://biomedical-engineering-online.biomedcentral.com/articles/10.1186/1475-925X-3-44> (besucht am 13.08.2023) (zitiert auf S. 9).
- [CBL+22] D. Chumachenko, M. Butkevych, D. Lode, M. Frohme, K. J. G. Schmailzl, A. Nechyporenko. „Machine Learning Methods in Predicting Patients with Suspected Myocardial Infarction Based on Short-Time HRV Data“. In: *Sensors* 22.18 (17. Sep. 2022), S. 7033. ISSN: 1424-8220. doi: [10.3390/s22187033](https://doi.org/10.3390/s22187033). URL: <https://www.mdpi.com/1424-8220/22/18/7033> (besucht am 06.09.2023) (zitiert auf S. 51).
- [Chi23] P. Chima. 12. Aug. 2023. URL: <https://medium.com/@preshchima/activation-functions-relu-softmax-87145bf39288> (zitiert auf S. 18).
- [Cou94] P. Coumel. „Paroxysmal Atrial Fibrillation: A Disorder of Autonomic Tone?“ In: *European Heart Journal* 15 (Apr. 1994), S. 9–16 (zitiert auf S. 4).
- [CPBC20] L. V. Coutts, D. Plans, A. W. Brown, J. Collomosse. „Deep learning with wearable based heart rate variability for prediction of mental and general health“. In: *Journal of Biomedical Informatics* 112 (Dez. 2020), S. 103610. ISSN: 15320464. doi: [10.1016/j.jbi.2020.103610](https://doi.org/10.1016/j.jbi.2020.103610). URL: <https://linkinghub.elsevier.com/retrieve/pii/S1532046420302380> (besucht am 06.09.2023) (zitiert auf S. 51).
- [CVL+04] D. Cysarz, D. Von Bonin, H. Lackner, P. Heusser, M. Moser, H. Bettermann. „Oscillations of heart rate and respiration synchronize during poetry recitation“. In: *American Journal of Physiology-Heart and Circulatory Physiology* 287.2 (Aug. 2004), H579–H587. ISSN: 0363-6135, 1522-1539. doi: [10.1152/ajpheart.01131.2003](https://doi.org/10.1152/ajpheart.01131.2003). URL: [http://www.physiology.org/doi/10.1152/ajpheart.01131.2003](https://doi.org/10.1152/ajpheart.01131.2003) (besucht am 13.08.2023) (zitiert auf S. 9).
- [CW23] O. College, K. Wilke. 13. Aug. 2023. URL: [https://5bn.wiki/wiki/Datei:Aufbau\\_Lunge.jpg](https://5bn.wiki/wiki/Datei:Aufbau_Lunge.jpg) (zitiert auf S. 7).
- [DPI+22] A. Di Credico, D. Perpetuini, P. Izzicupo, G. Gaggi, D. Cardone, C. Filippini, A. Merla, B. Ghinassi, A. Di Baldassarre. „Estimation of Heart Rate Variability Parameters by Machine Learning Approaches Applied to Facial Infrared Thermal Imaging“. In: *Frontiers in Cardiovascular Medicine* 9 (17. Mai 2022), S. 893374. ISSN: 2297-055X. doi: [10.3389/fcvm.2022.893374](https://doi.org/10.3389/fcvm.2022.893374). URL: <https://www.frontiersin.org/articles/10.3389/fcvm.2022.893374/full> (besucht am 06.09.2023) (zitiert auf S. 51).
- [ERS+21] Y. Elul, A. A. Rosenberg, A. Schuster, A. M. Bronstein, Y. Yaniv. „Meeting the unmet needs of clinicians from AI systems showcased for cardiology with deep-learning-based ECG analysis“. In: *Proceedings of the National Academy of Sciences* 118.24 (15. Juni 2021), e2020620118. ISSN: 0027-8424, 1091-6490. doi: [10.1073/pnas.2020620118](https://doi.org/10.1073/pnas.2020620118). URL: <https://doi.org/10.1073/pnas.2020620118> (besucht am 06.09.2023) (zitiert auf S. 49, 53).
- [Esl92] M. Esler. „The autonomic nervous system and cardiac arrhythmias“. In: *Clinical Autonomic Research* 2.2 (Apr. 1992), S. 133–135. ISSN: 0959-9851, 1619-1560. doi: [10.1007/BF01819669](https://doi.org/10.1007/BF01819669). URL: [http://link.springer.com/10.1007/BF01819669](https://link.springer.com/10.1007/BF01819669) (besucht am 04.08.2023) (zitiert auf S. 10).

- [FLN+20] L. Fu, B. Lu, B. Nie, Z. Peng, H. Liu, X. Pi. „Hybrid Network with Attention Mechanism for Detection and Location of Myocardial Infarction Based on 12-Lead Electrocardiogram Signals“. In: *Sensors* 20.4 (14. Feb. 2020), S. 1020. ISSN: 1424-8220. doi: [10.3390/s20041020](https://doi.org/10.3390/s20041020). URL: <https://www.mdpi.com/1424-8220/20/4/1020> (besucht am 06.09.2023) (zitiert auf S. 51).
- [FPS96] U. Fayyad, G. Piatetsky-Shapiro, P. Smyth. „From Data Mining to Knowledge Discovery in Databases“. In: *AI Magazine* 17.3 (März 1996). Section: Articles, S. 37. doi: [10.1609/aimag.v17i3.1230](https://doi.org/10.1609/aimag.v17i3.1230). URL: <https://ojs.aaai.org/index.php/aimagazine/article/view/1230> (besucht am 20.06.2022) (zitiert auf S. 15).
- [Fra23] N. Franke-Gricksch. 12. Aug. 2023. URL: <https://xn--hrv-herzratenvariabilit-dcc.de/2017/07/berechnung-des-poincare-diagramms-aus-rr-intervallen/> (zitiert auf S. 14).
- [GAH+02] A. L. Goldberger, L. A. N. Amaral, J. M. Hausdorff, P. C. Ivanov, C.-K. Peng, H. E. Stanley. „Fractal dynamics in physiology: Alterations with disease and aging“. In: *Proceedings of the National Academy of Sciences* 99 (suppl\_1 19. Feb. 2002), S. 2466–2472. ISSN: 0027-8424, 1091-6490. doi: [10.1073/pnas.012579499](https://doi.org/10.1073/pnas.012579499). URL: <https://doi.org/10.1073/pnas.012579499> (besucht am 14.08.2023) (zitiert auf S. 11).
- [GBC16] I. Goodfellow, Y. Bengio, A. Courville. *Deep Learning*. <http://www.deeplearningbook.org>. MIT Press, 2016 (zitiert auf S. 15, 17–19, 22, 23).
- [GL97] D. C. Galletly, P. D. Larsen. „Cardioventilatory coupling during anaesthesia“. In: *British Journal of Anaesthesia* 79.1 (Juli 1997), S. 35–40. ISSN: 00070912. doi: [10.1093/bja/79.1.35](https://doi.org/10.1093/bja/79.1.35). URL: <https://linkinghub.elsevier.com/retrieve/pii/S0007091217399014> (besucht am 13.08.2023) (zitiert auf S. 9).
- [Glo13] Glosster.ca. *Colored neural network.svg*. [Online; accessed July 25, 2022]. 2013. URL: [https://en.wikipedia.org/wiki/File:Colored\\_neural\\_network.svg](https://en.wikipedia.org/wiki/File:Colored_neural_network.svg) (zitiert auf S. 18).
- [GMT19] G. Giannakakis, K. Marias, M. Tsiknakis. „A stress recognition system using HRV parameters and machine learning techniques“. In: *2019 8th International Conference on Affective Computing and Intelligent Interaction Workshops and Demos (ACIIW)*. 2019, S. 269–272. doi: [10.1109/ACIIW.2019.8925142](https://doi.org/10.1109/ACIIW.2019.8925142) (zitiert auf S. 51).
- [Hel23] H. van Helvete. 11. Aug. 2023. URL: [https://commons.wikimedia.org/wiki/File:EKG\\_Complex\\_en.svg](https://commons.wikimedia.org/wiki/File:EKG_Complex_en.svg) (zitiert auf S. 5).
- [Hen23] V. Henn. *Bluthochdruck: Arteriosklerose, Herzinfarkt und andere Folgen*. 20. Apr. 2023. URL: [https://www.blutdruck-medizin.de/erkrankungen/bluthochdruck\\_arteriosklerose\\_herzinfarkt.php](https://www.blutdruck-medizin.de/erkrankungen/bluthochdruck_arteriosklerose_herzinfarkt.php) (besucht am 13.08.2023) (zitiert auf S. 6).
- [Her19] G. Herold. *Innere Medizin: eine vorlesungsorientierte Darstellung: 2019: unter Berücksichtigung des Gegenstandskataloges für die Ärztliche Prüfung: mit ICD 10-Schlüssel im Text und Stichwortverzeichnis*. Köln: Gerd Herold, 2019. 1002 S. ISBN: 9783981466089 (zitiert auf S. 2, 6).
- [Heu23] J. Heuser. 11. Aug. 2023. URL: <https://commons.wikimedia.org/w/index.php?curid=1686121> (zitiert auf S. 3).

- [HMP03] H. V. Huikuri, T. H. Mäkikallio, J. Perkiomäki. „Measurement of heart rate variability by methods based on nonlinear dynamics“. In: *Journal of Electrocardiology* 36 (Dez. 2003), S. 95–99. ISSN: 00220736. DOI: [10.1016/j.jelectrocard.2003.09.021](https://doi.org/10.1016/j.jelectrocard.2003.09.021). URL: <https://linkinghub.elsevier.com/retrieve/pii/S0022073603001092> (besucht am 14.08.2023) (zitiert auf S. 11).
- [HPWA21] M. Hammad, P. Pławiak, K. Wang, U. R. Acharya. „ResNet-Attention model for human authentication using ECG signals“. In: *Expert Systems* 38.6 (Sep. 2021), e12547. ISSN: 0266-4720, 1468-0394. DOI: [10.1111/exsy.12547](https://doi.org/10.1111/exsy.12547). URL: <https://onlinelibrary.wiley.com/doi/10.1111/exsy.12547> (besucht am 06.09.2023) (zitiert auf S. 51).
- [HSI22] W. Haverkamp, N. Strodthoff, C. Israel. „EKG-Diagnostik mit Hilfe künstlicher Intelligenz: aktueller Stand und zukünftige Perspektiven – Teil 2: Aktuelle Studienlage und Ausblick“. In: *Herzschrittmachertherapie + Elektrophysiologie* 33.3 (Sep. 2022), S. 305–311. ISSN: 0938-7412, 1435-1544. DOI: [10.1007/s00399-022-00855-x](https://doi.org/10.1007/s00399-022-00855-x). URL: <https://link.springer.com/10.1007/s00399-022-00855-x> (besucht am 06.09.2023) (zitiert auf S. 51).
- [IR15] G. W. Imbens, D. B. Rubin. *Causal inference in statistics, social, and biomedical sciences*. Cambridge University Press, 2015 (zitiert auf S. 27).
- [Jak23] Jakov. 11. Aug. 2023. URL: [https://upload.wikimedia.org/wikipedia/commons/3/33/Diagram\\_of\\_the\\_human\\_heart\\_%28cropped%29\\_de.svg](https://upload.wikimedia.org/wikipedia/commons/3/33/Diagram_of_the_human_heart_%28cropped%29_de.svg) (zitiert auf S. 3).
- [JCK18] H. F. Jelinek, D. Cornforth, A. H. Khandoker, Hrsg. *ECG time series variability analysis: engineering and medicine*. Boca Raton: CRC Press, Taylor & Francis Group, 2018. 479 S. ISBN: 9781482243475 (zitiert auf S. 4, 5).
- [Jor97] M. I. Jordan. „SERIAL ORDER: A PARALLEL DISTRIBUTED PROCESSING APPROACH“. In: *Advances in Psychology* 121 (1997), S. 471–495. DOI: [10.1016/S0166-4115\(97\)80111-2](https://doi.org/10.1016/S0166-4115(97)80111-2). URL: <https://www.sciencedirect.com/science/article/pii/S0166411597801112> (besucht am 25.07.2022) (zitiert auf S. 22, 23).
- [JSB+97] K. Jensen-Urstad, N. Storck, F. Bouvier, M. Ericson, L. E. Lindblad, M. Jensen-Urstad. „Heart rate variability in healthy subjects is related to age and gender“. In: *Acta Physiologica Scandinavica* 160.3 (Juni 1997), S. 235–241. ISSN: 0001-6772, 1365-201X. DOI: [10.1046/j.1365-201X.1997.00142.x](https://doi.org/10.1046/j.1365-201X.1997.00142.x). URL: <https://onlinelibrary.wiley.com/doi/10.1046/j.1365-201X.1997.00142.x> (besucht am 14.08.2023) (zitiert auf S. 11).
- [KB17] D. P. Kingma, J. Ba. *Adam: A Method for Stochastic Optimization*. 29. Jan. 2017. arXiv: [1412.6980\[cs\]](https://arxiv.org/abs/1412.6980). URL: [http://arxiv.org/abs/1412.6980](https://arxiv.org/abs/1412.6980) (besucht am 30.08.2023) (zitiert auf S. 34).
- [KBK+16] P. Kirchhof, S. Benussi, D. Kotecha, A. Ahlsson, D. Atar, B. Casadei, M. Castella, H.-C. Diener, H. Heidbuchel, J. Hendriks, G. Hindricks, A. S. Manolis, J. Oldgren, B. A. Popescu, U. Schotten, B. Van Putte, P. Vardas, S. Agewall, J. Camm, G. Baron Esquivias, W. Budts, S. Carerj, F. Casselman, A. Coca, R. De Caterina, S. Deftereos, D. Dobrev, J. M. Ferro, G. Filippatos, D. Fitzsimons, B. Gorenek, M. Guenoun, S. H. Hohnloser, P. Kolh, G. Y. H. Lip, A. Manolis, J. McMurray, P. Ponikowski, R. Rosenthal, F. Ruschitzka, I. Savelieva, S. Sharma, P. Suwalski, J. L. Tamargo, C. J. Taylor, I. C. Van Gelder, A. A. Voors, S. Windecker, J. L. Zamorano, K. Zeppenfeld. „,2016

- ESC Guidelines for the management of atrial fibrillation developed in collaboration with EACTS“. In: *European Heart Journal* 37.38 (7. Okt. 2016), S. 2893–2962. ISSN: 0195-668X, 1522-9645. doi: [10.1093/eurheartj/ehw210](https://doi.org/10.1093/eurheartj/ehw210). URL: <https://academic.oup.com/eurheartj/article-lookup/doi/10.1093/eurheartj/ehw210> (besucht am 27.08.2023) (zitiert auf S. 4).
- [KKMS21] E. R. Kandel, J. Koester, S. Mack, S. Siegelbaum, Hrsg. *Principles of neural science*. Sixth edition. New York: McGraw Hill, 2021. 1646 S. ISBN: 9781259642234 (zitiert auf S. 5, 6).
- [Knu] J. Knupp. „Einführung in Deep Learning - LSTM & CNN“. Proseminar Data Mining. URL: [https://www5.in.tum.de/lehre/seminare/datamining/ss17/paper\\_pres/13\\_nn\\_deep/essay.pdf](https://www5.in.tum.de/lehre/seminare/datamining/ss17/paper_pres/13_nn_deep/essay.pdf) (besucht am 25.07.2022) (zitiert auf S. 21).
- [KVS+95] J. Kurths, A. Voss, P. Saparin, A. Witt, H. J. Kleiner, N. Wessel. „Quantitative analysis of heart rate variability“. In: *Chaos: An Interdisciplinary Journal of Nonlinear Science* 5.1 (März 1995), S. 88–94. ISSN: 1054-1500. doi: [10.1063/1.166090](https://doi.org/10.1063/1.166090). eprint: [https://pubs.aip.org/aip/cha/article-pdf/5/1/88/7864647/88\\_1\\_online.pdf](https://pubs.aip.org/aip/cha/article-pdf/5/1/88/7864647/88_1_online.pdf). URL: <https://doi.org/10.1063/1.166090> (zitiert auf S. 14, 29).
- [LBH15] Y. LeCun, Y. Bengio, G. Hinton. „Deep learning“. en. In: *Nature* 521.7553 (Mai 2015), S. 436–444. ISSN: 0028-0836, 1476-4687. doi: [10.1038/nature14539](https://doi.org/10.1038/nature14539). URL: <http://www.nature.com/articles/nature14539> (besucht am 20.06.2022) (zitiert auf S. 20).
- [LH19] I. Loshchilov, F. Hutter. *Decoupled Weight Decay Regularization*. 4. Jan. 2019. arXiv: [1711.05101\[cs,math\]](https://arxiv.org/abs/1711.05101). URL: <http://arxiv.org/abs/1711.05101> (besucht am 30.08.2023) (zitiert auf S. 42).
- [LLY+16] E. O.-C. Lau, C.-Y. Lo, Y. Yao, A. F.-T. Mak, L. Jiang, Y. Huang, X. Yao. „Aortic Baroreceptors Display Higher Mechanosensitivity than Carotid Baroreceptors“. In: *Frontiers in Physiology* 7 (31. Aug. 2016). ISSN: 1664-042X. doi: [10.3389/fphys.2016.00384](https://doi.org/10.3389/fphys.2016.00384). URL: <http://journal.frontiersin.org/Article/10.3389/fphys.2016.00384/abstract> (besucht am 13.08.2023) (zitiert auf S. 6, 7).
- [LW23] P. J. Lynch, K. Wilke. 13. Aug. 2023. URL: <https://commons.wikimedia.org/wiki/File:Endbronchiole.jpg> (zitiert auf S. 7).
- [MBG+16] D. Mozaffarian, E. J. Benjamin, A. S. Go, D. K. Arnett, M. J. Blaha, M. Cushman, S. R. Das, S. de Ferranti, J.-P. Després, H. J. Fullerton, V. J. Howard, M. D. Huffman, C. R. Isasi, M. C. Jiménez, S. E. Judd, B. M. Kissela, J. H. Lichtman, L. D. Lisabeth, S. Liu, R. H. Mackey, D. J. Magid, D. K. McGuire, E. R. Mohler, C. S. Moy, P. Muntner, M. E. Mussolini, K. Nasir, R. W. Neumar, G. Nichol, L. Palaniappan, D. K. Pandey, M. J. Reeves, C. J. Rodriguez, W. Rosamond, P. D. Sorlie, J. Stein, A. Towfighi, T. N. Turan, S. S. Virani, D. Woo, R. W. Yeh, M. B. Turner. „Heart Disease and Stroke Statistics—2016 Update“. In: *Circulation* 133.4 (2016), e38–e360. doi: [10.1161/CIR.000000000000350](https://doi.org/10.1161/CIR.000000000000350). eprint: <https://www.ahajournals.org/doi/pdf/10.1161/CIR.000000000000350>. URL: <https://www.ahajournals.org/doi/abs/10.1161/CIR.000000000000350> (zitiert auf S. 4).

- [MLDC22] A. Matuz, D. V. D. Linden, G. Darnai, Á. Csathó. *Machine learning models in Heart Rate Variability based mental fatigue prediction: training on heterogeneous data to obtain robust models*. preprint. In Review, 18. Mai 2022. doi: [10.21203/rs.3.rs-1633975/v1](https://doi.org/10.21203/rs.3.rs-1633975/v1). URL: <https://www.researchsquare.com/article/rs-1633975/v1> (besucht am 06.09.2023) (zitiert auf S. 51).
- [MVDC22] A. Matuz, D. Van Der Linden, G. Darnai, Á. Csathó. „Generalisable machine learning models trained on heart rate variability data to predict mental fatigue“. In: *Scientific Reports* 12.1 (21. Nov. 2022), S. 20023. issn: 2045-2322. doi: [10.1038/s41598-022-24415-y](https://doi.org/10.1038/s41598-022-24415-y). URL: <https://doi.org/10.1038/s41598-022-24415-y> (besucht am 06.09.2023) (zitiert auf S. 51).
- [Num23] Numiri. 22. Aug. 2023. URL: <https://upload.wikimedia.org/wikipedia/commons/8/81/Attention-qkv.png> (zitiert auf S. 24).
- [Ras86] F. Raschke. „The Hierarchical Order of Cardiovascular-Respiratory Coupling“. In: *Cardiorespiratory and Cardiosomatic Psychophysiology*. Hrsg. von P. Grossman, K. H. L. Janssen, D. Vaitl. Boston, MA: Springer US, 1986, S. 207–217. isbn: 9781475703627. doi: [10.1007/978-1-4757-0360-3\\_13](https://doi.org/10.1007/978-1-4757-0360-3_13). URL: [http://link.springer.com/10.1007/978-1-4757-0360-3\\_13](http://link.springer.com/10.1007/978-1-4757-0360-3_13) (besucht am 13.08.2023) (zitiert auf S. 8, 9).
- [RMK+14] M. Riedl, A. Müller, J. F. Kraemer, T. Penzel, J. Kurths, N. Wessel. „Cardio-Respiratory Coordination Increases during Sleep Apnea“. In: *PLoS ONE* 9.4 (9. Apr. 2014). Hrsg. von J. Garcia-Ojalvo, e93866. issn: 1932-6203. doi: [10.1371/journal.pone.0093866](https://doi.org/10.1371/journal.pone.0093866). URL: <https://doi.org/10.1371/journal.pone.0093866> (besucht am 13.08.2023) (zitiert auf S. 9).
- [RN16] S. J. Russell, P. Norvig. *Artificial intelligence: a modern approach*. eng. Third edition, Global edition. Prentice Hall series in artificial intelligence. Boston Columbus Indianapolis: Pearson, 2016. isbn: 978-0-13-604259-4 (zitiert auf S. 16, 19, 48).
- [Roe23] T. Roeschl. 13. Aug. 2023. URL: <https://towardsdatascience.com/animations-of-gradient-descent-and-loss-landscapes-of-neural-networks-in-python-e757f3584057> (zitiert auf S. 19).
- [RRP+20] A. H. Ribeiro, M. H. Ribeiro, G. M. M. Paixão, D. M. Oliveira, P. R. Gomes, J. A. Canazart, M. P. S. Ferreira, C. R. Andersson, P. W. Macfarlane, W. Meira, T. B. Schön, A. L. P. Ribeiro. „Automatic diagnosis of the 12-lead ECG using a deep neural network“. In: *Nature Communications* 11.1 (9. Apr. 2020), S. 1760. issn: 2041-1723. doi: [10.1038/s41467-020-15432-4](https://doi.org/10.1038/s41467-020-15432-4). URL: <https://doi.org/10.1038/s41467-020-15432-4> (besucht am 06.09.2023) (zitiert auf S. 51).
- [RW22] T. H. Rafi, Y. Woong Ko. „HeartNet: Self Multihead Attention Mechanism via Convolutional Network With Adversarial Data Synthesis for ECG-Based Arrhythmia Classification“. In: *IEEE Access* 10 (2022), S. 100501–100512. issn: 2169-3536. doi: [10.1109/ACCESS.2022.3206431](https://doi.org/10.1109/ACCESS.2022.3206431). URL: <https://ieeexplore.ieee.org/document/9889702/> (besucht am 06.09.2023) (zitiert auf S. 51).
- [SBA+91] J. P. Saul, R. D. Berger, P. Albrecht, S. P. Stein, M. H. Chen, R. J. Cohen. „Transfer function analysis of the circulation: unique insights into cardiovascular regulation“. In: *American Journal of Physiology-Heart and Circulatory Physiology* 261.4 (1. Okt.

## Literaturverzeichnis

---

- 1991), H1231–H1245. ISSN: 0363-6135, 1522-1539. doi: [10.1152/ajpheart.1991.261.4.H1231](https://doi.org/10.1152/ajpheart.1991.261.4.H1231). URL: <https://www.physiology.org/doi/10.1152/ajpheart.1991.261.4.H1231> (besucht am 04.08.2023) (zitiert auf S. 10, 14).
- [SDH+05] P. K. Stein, P. P. Domitrovich, H. V. Huikuri, R. E. Kleiger, Cast Investigators. „Traditional and Nonlinear Heart Rate Variability Are Each Independently Associated with Mortality after Myocardial Infarction“. In: *Journal of Cardiovascular Electrophysiology* 16.1 (Jan. 2005), S. 13–20. ISSN: 1045-3873, 1540-8167. doi: [10.1046/j.1540-8167.2005.04358.x](https://doi.org/10.1046/j.1540-8167.2005.04358.x). URL: <http://doi.wiley.com/10.1046/j.1540-8167.2005.04358.x> (besucht am 14.08.2023) (zitiert auf S. 11).
- [Sha23] S. Sharma. 12. Aug. 2023. URL: <https://towardsdatascience.com/activation-functions-neural-networks-1cbd9f8d91d6> (zitiert auf S. 18).
- [She20] A. Sherstinsky. „Fundamentals of Recurrent Neural Network (RNN) and Long Short-Term Memory (LSTM) Network“. In: *Physica D: Nonlinear Phenomena* 404 (März 2020), S. 132306. ISSN: 01672789. doi: [10.1016/j.physd.2019.132306](https://doi.org/10.1016/j.physd.2019.132306). arXiv: [1808.03314\[cs, stat\]](https://arxiv.org/abs/1808.03314). URL: <http://arxiv.org/abs/1808.03314> (besucht am 27.06.2022) (zitiert auf S. 2).
- [SWSS21] N. Strodthoff, P. Wagner, T. Schaeffter, W. Samek. „Deep Learning for ECG Analysis: Benchmarks and Insights from PTB-XL“. In: *IEEE Journal of Biomedical and Health Informatics* 25.5 (Mai 2021), S. 1519–1528. ISSN: 2168-2194, 2168-2208. doi: [10.1109/JBHI.2020.3022989](https://doi.org/10.1109/JBHI.2020.3022989). URL: <https://ieeexplore.ieee.org/document/9190034/> (besucht am 06.09.2023) (zitiert auf S. 51).
- [SWW+12] R. B. Schnabel, S. Wilde, P. S. Wild, T. Munzel, S. Blankenberg. „Vorhofflimmern“. In: *Dtsch Arztebl International* 109.16 (2012), S. 293–299. doi: [10.3238/arztebl.2012.0293](https://doi.org/10.3238/arztebl.2012.0293). eprint: <https://www.aerzteblatt.de/pdf.asp?id=125010>. URL: <https://www.aerzteblatt.de/int/article.asp?id=125010> (zitiert auf S. 4).
- [TAC+19] S. Tan, G. Androz, A. Chamseddine, P. Fecteau, A. Courville, Y. Bengio, J. P. Cohen. „Icentia11K: An Unsupervised Representation Learning Dataset for Arrhythmia Subtype Discovery“. In: (2019). doi: [10.48550/ARXIV.1910.09570](https://doi.org/10.48550/ARXIV.1910.09570). URL: <https://arxiv.org/abs/1910.09570> (besucht am 04.07.2023) (zitiert auf S. 50).
- [TOB+] Tan, Shawn, Ortiz-Gagné, Satya, Beaudoin-Gagnon, Nicolas, Fecteau, Pierre, Courville, Aaron, Bengio, Yoshua, Cohen, Joseph Paul. *Icentia11k Single Lead Continuous Raw Electrocardiogram Dataset*. Type: dataset. doi: [10.13026/KK0V-R952](https://doi.org/10.13026/KK0V-R952). URL: <https://physionet.org/content/icentia11k-continuous-ecg/1.0/> (besucht am 04.07.2023) (zitiert auf S. 50).
- [UCK+11] P. E. Utgoff, J. Cussens, S. Kramer, S. Jain, F. Stephan, L. D. Raedt, L. Todorovski, P. Flener, U. Schmid, R. Vilalta, C. Giraud-Carrier, P. Brazdil, C. Soares, E. Keogh, W. D. Smart, P. Abbeel, A. Y. Ng. „Inductive Transfer“. In: (2011). Hrsg. von C. Sammut, G. I. Webb, S. 545–548. doi: [10.1007/978-0-387-30164-8\\_401](https://doi.org/10.1007/978-0-387-30164-8_401). URL: [http://link.springer.com/10.1007/978-0-387-30164-8\\_401](http://link.springer.com/10.1007/978-0-387-30164-8_401) (besucht am 22.02.2023) (zitiert auf S. 25, 26).
- [VKK+96] A. Voss, J. Kurths, H. Kleiner, A. Witt, N. Wessel, P. Saparin, K. Osterziel, R. Schurath, R. Dietz. „The application of methods of non-linear dynamics for the improved and predictive recognition of patients threatened by sudden cardiac death“. In: *Cardiovascular research* 31.3 (1996), S. 419–433 (zitiert auf S. 14, 29).

- [VSH+15] A. Voss, R. Schroeder, A. Heitmann, A. Peters, S. Perz. „Short-Term Heart Rate Variability—Influence of Gender and Age in Healthy Subjects“. In: *PLOS ONE* 10.3 (30. März 2015). Hrsg. von A. V. Hernandez, e0118308. issn: 1932-6203. doi: [10.1371/journal.pone.0118308](https://doi.org/10.1371/journal.pone.0118308). URL: <https://dx.plos.org/10.1371/journal.pone.0118308> (besucht am 04.08.2023) (zitiert auf S. 5, 10, 14).
- [VSP+17] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, I. Polosukhin. „Attention is All you Need“. In: *Advances in Neural Information Processing Systems*. Bd. 30. Curran Associates, Inc., 2017. URL: <https://proceedings.neurips.cc/paper/2017/hash/3f5ee243547dee91fdb053c1c4a845aa-Abstract.html> (besucht am 12.04.2022) (zitiert auf S. 2).
- [VSS+09] A. Voss, S. Schulz, R. Schroeder, M. Baumert, P. Caminal. „Methods derived from nonlinear dynamics for analysing heart rate variability“. In: *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences* 367.1887 (28. Jan. 2009), S. 277–296. issn: 1364-503X, 1471-2962. doi: [10.1098/rsta.2008.0232](https://doi.org/10.1098/rsta.2008.0232). URL: <https://royalsocietypublishing.org/doi/10.1098/rsta.2008.0232> (besucht am 14.08.2023) (zitiert auf S. 11, 14).
- [WBK+20] N. Wessel, K. Berg, J. F. Kraemer, A. Gapelyuk, K. Rietsch, T. Hauser, J. Kurths, D. Wenzel, N. Klein, C. Kolb, R. Belke, A. Schirdewan, S. Käab. „Cardiac Autonomic Dysfunction and Incidence of de novo Atrial Fibrillation: Heart Rate Variability vs. Heart Rate Complexity“. In: *Frontiers in Physiology* 11 (Dez. 2020), S. 596844. issn: 1664-042X. doi: [10.3389/fphys.2020.596844](https://doi.org/10.3389/fphys.2020.596844). URL: <https://www.frontiersin.org/articles/10.3389/fphys.2020.596844/full> (besucht am 02.07.2023) (zitiert auf S. iii, 4, 25, 27, 50).
- [WBK21a] N. Wessel, K. Berg, J. Krämer. *Kurs1, Vorlesung 10*. 13. Apr. 2021 (zitiert auf S. 13).
- [WBK21b] N. Wessel, K. Berg, J. Krämer. *Kurs1, Vorlesung 2*. 13. Apr. 2021 (zitiert auf S. 12).
- [WMBK07] N. Wessel, H. Malberg, R. Bauernschmitt, J. Kurths. „NONLINEAR METHODS OF CARDIOVASCULAR PHYSICS AND THEIR CLINICAL APPLICABILITY“. In: *International Journal of Bifurcation and Chaos* 17.10 (Okt. 2007), S. 3325–3371. issn: 0218-1274, 1793-6551. doi: [10.1142/S0218127407019093](https://doi.org/10.1142/S0218127407019093). URL: <https://www.worldscientific.com/doi/abs/10.1142/S0218127407019093> (besucht am 14.08.2023) (zitiert auf S. 12, 28, 29, 49).
- [YCBL14] J. Yosinski, J. Clune, Y. Bengio, H. Lipson. „How transferable are features in deep neural networks?“ In: *Advances in Neural Information Processing Systems*. Hrsg. von Z. Ghahramani, M. Welling, C. Cortes, N. Lawrence, K. Weinberger. Bd. 27. Curran Associates, Inc., 2014. URL: [https://proceedings.neurips.cc/paper\\_files/paper/2014/file/375c71349b295fbe2dcda9206f20a06-Paper.pdf](https://proceedings.neurips.cc/paper_files/paper/2014/file/375c71349b295fbe2dcda9206f20a06-Paper.pdf) (zitiert auf S. 25).
- [ZAJ20] K. Zhang, V. Aleexenko, K. Jeevaratnam. „Computational approaches for detection of cardiac rhythm abnormalities: Are we there yet?“ In: *Journal of Electrocardiology* 59 (März 2020), S. 28–34. issn: 00220736. doi: [10.1016/j.jelectrocard.2019.12.009](https://doi.org/10.1016/j.jelectrocard.2019.12.009). URL: <https://linkinghub.elsevier.com/retrieve/pii/S0022073619306582> (besucht am 06.09.2023) (zitiert auf S. 51).



### **Erklärung**

Ich versichere, diese Arbeit selbstständig verfasst zu haben. Ich habe keine anderen als die angegebenen Quellen benutzt und alle wörtlich oder sinngemäß aus anderen Werken übernommene Aussagen als solche gekennzeichnet. Weder diese Arbeit noch wesentliche Teile daraus waren bisher Gegenstand eines anderen Prüfungsverfahrens. Ich habe diese Arbeit bisher weder teilweise noch vollständig veröffentlicht. Das elektronische Exemplar stimmt mit allen eingereichten Exemplaren überein.

---

Ort, Datum, Unterschrift

### **Danksagung**

Diese Masterarbeit wäre ohne die Unterstützung meines Umfelds nicht möglich gewesen, daher vielen Dank.

**Dominik** - für deine Gesellschaft und Inspiration zum Ehrgeiz

**Jan** - für die spannenden Ideen und pointierten Fragen

**Karsten** - für deine Überlebenstipps im Unialltag

**Kiymet und Salehettin** - für das Wecken meiner Neugier und eure Geduld

**Marius** - für das Korrektur lesen und die Schreibideen

**Niels** - für die Idee zur Masterarbeit und die Chance in seiner Arbeitsgruppe zu arbeiten

**Tara, Mireille, Clarissa und Addi** - fürs kochen und mich bei Laune halten

**Yusuf und Ismail** - für euer offenes Ohr und Verständnis